Machine Learning — UAQ

Presentación

Angel Gutiérrez

9 de marzo de 2026

Contenido

1. Arranque y framing
2. Teoría: workflow de ML
3. Lab NumPy: baseline + split + métricas
4. Lab sklearn: Pipeline + CV + PR-AUC
5. Cierre y entregable

Semana 1 — Introducción + workflow de Machine Learning

Framing, generalización, overfitting, leakage, baselines y métricas (Accuracy + PR/PR-AUC)

Curso de Machine Learning — UAQ (Matemáticas Aplicadas)

Libro base: *Probabilistic Machine Learning: An Introduction* (Kevin P. Murphy)

Semana 1

Temario de la Semana 1 (qué cubrimos hoy)

1. **Arranque y framing:** dataset $\rightarrow$ modelo $\rightarrow$ predicción $\rightarrow$ decisión
2. **Teoría (slides):**
   - Problem framing (qué es X, qué es y, unidad de predicción)
   - Generalización y overfitting
   - Leakage (conceptual + ejemplos)
   - Baselines
   - Métricas: Accuracy + Precision/Recall + PR-AUC
3. **Lab NumPy:** split + baseline + accuracy + PR básico (+ mini-leakage)
4. **Lab sklearn:** Pipeline + cross_val_score + PR-AUC
5. **Entregable:** repo + notebook plantilla + checklist reproducible

Lecturas sugeridas (PML = libro base) — Semana 1

Lectura previa (fundamentos para la sesión)

- **Cap. 1 — Introduction**
  - ¿Qué es ML? (definición tipo T/P/E) y *supervised learning*
  - *Generalization* y *overfitting* (por qué separar train/test)

Lectura mínima para métricas (lo que usaremos hoy)

- **Cap. 5 — Decision theory**
  - *Precision*, *Recall*, *Precision–Recall curve*
  - *Average Precision* (PR-AUC) como resumen

Lectura posterior (para consolidar evaluación honesta)

- **Cap. 4 — Statistics**
  - *Validation set* y selección de hiperparámetros
  - *Cross-validation* (K-fold): por qué reduce varianza con N pequeño

Semana 1 — mapa del temario (progreso)

1. Arranque y framing
2. Teoría: workflow de ML
3. Lab NumPy: baseline + split + métricas
4. Lab sklearn: Pipeline + CV + PR-AUC
5. Cierre y entregable

¿Qué es "aprender" en ML? (visión de extremo a extremo)

- **Dataset** (observaciones): pares (x_i, y_i)
- **Modelo** f_θ: transforma x en una predicción $\hat{y}$
- **Métrica**: mide qué tan bien predice (Acc, AP/PR-AUC)
- **Decisión**: usar $\hat{y}$ o un score para actuar (aprobar, clasificar, alertar, etc.)

Idea central del curso

El objetivo real no es "ganar en train"; es **generalizar** con evaluación honesta y reproducible.

Semana 1 — mapa del temario (progreso)

1. Arranque y framing
2. Teoría: workflow de ML
   - Problem framing
   - Generalización y overfitting
   - Fuga de información (leakage)
   - Modelos de referencia
   - Métricas
3. Lab NumPy: baseline + split + métricas
4. Lab sklearn: Pipeline + CV + PR-AUC
5. Cierre y entregable

Problem framing: qué debes definir antes de entrenar

- **Unidad de predicción:** ¿qué entidad scoreas? (persona, cliente, imagen, transacción)
- **Features X:** información disponible **al momento de predecir**
- **Target y:** definición operacional (evento + ventana + etiqueta)
- **Salida del modelo:** clase (0/1), probabilidad, score continuo
- **Métrica:** qué significa "éxito" (accuracy, AP, etc.)

Pregunta guía

¿Qué decisión cambia si tengo este score/predicción?

Supervised vs unsupervised vs RL (solo para ubicar)

Supervised

- Tienes etiquetas y
- Objetivo: predecir y desde x
- Ej: spam, precio de casa

Reinforcement Learning

- Aprendes por recompensa acumulada
- Interacción agente–entorno
- Ej: control, juegos

Unsupervised

- No hay y
- Objetivo: estructura/representaciones
- Ej: clustering, PCA

Hoy

Nos enfocamos en **supervised** (clasificación binaria) + evaluación.

Supervised learning: esquema visual (para fijar ideas)

Supervised learning: learn $f(x)$ from labeled pairs (x, y)

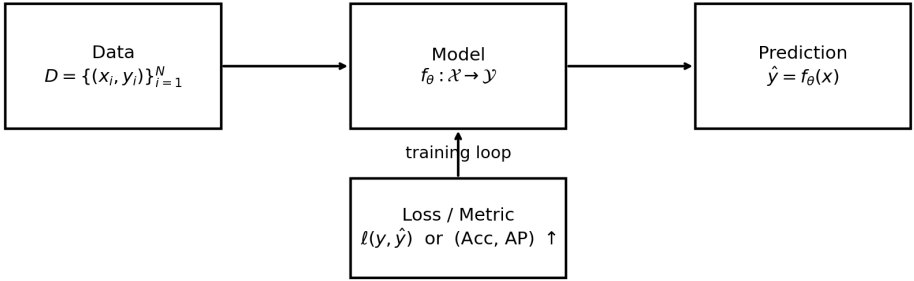

Generalización: el objetivo real

- Queremos buen desempeño en datos nuevos (out-of-sample).
- Por eso separamos datos: train / validation / test.

Intuición

Train performance es "qué tan bien memoriza".
Test performance es "qué tan bien generaliza".

Overfitting: definición + señal práctica

Overfitting = el modelo se ajusta demasiado a peculiaridades/ruido del train:

- train muy bien, test/val notablemente peor
- "se derrumba" al salir del dataset de entrenamiento

Generalization gap

Diferencia entre el desempeño en train y en val/test.

Overfitting visual (intuición con modelos de distinta complejidad)

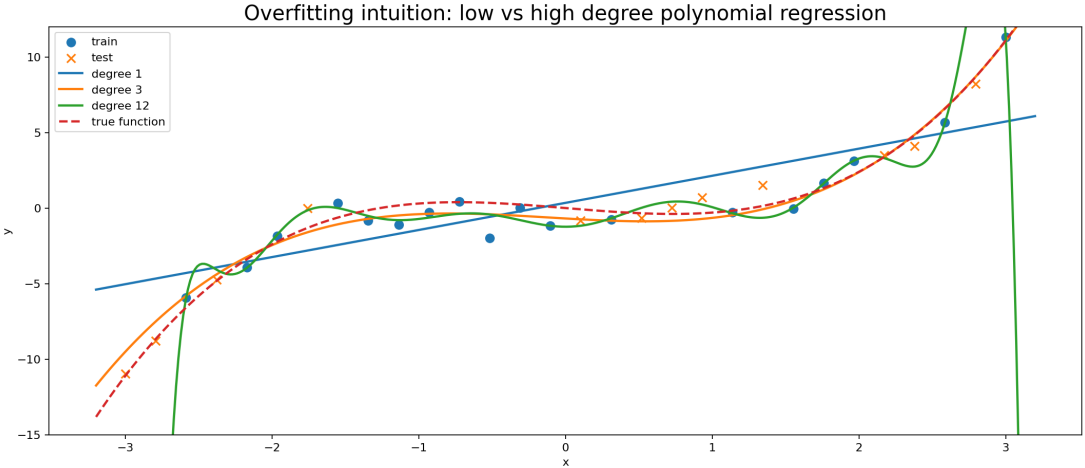

- Modelo simple: puede sub-ajustar (*underfit*)
- Modelo muy flexible: puede memorizar train y fallar en test

Complejidad vs error (por qué el test error es “U-shaped”)

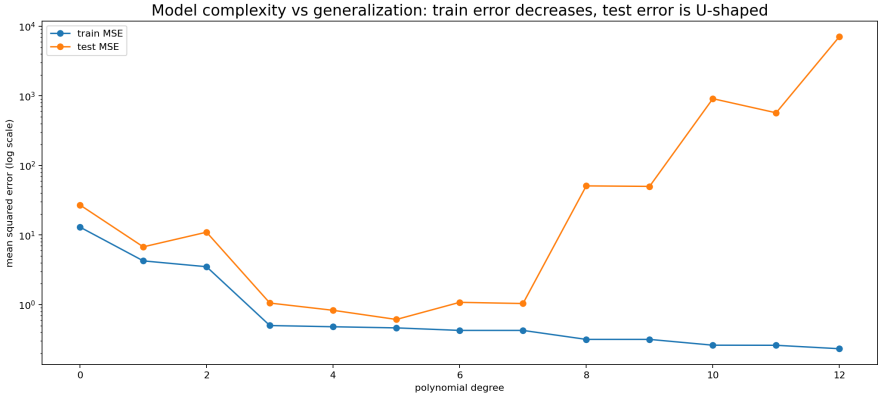

- El **train error** suele bajar con complejidad.
- El **test error** suele tener un mínimo: demasiada complejidad vuelve a empeorar.

Fuga de información: por qué las métricas pueden mentir

Pregunta guía

¿Por qué mi métrica (accuracy / AP) es alta en el cuaderno y cae en producción?

- **Objetivo**: estimar desempeño fuera de muestra (generalización).
- **Problema**: si el proceso "ve" datos del futuro, la evaluación es optimista.
- **Consecuencia**: eliges mal el modelo / umbral $\Rightarrow$ mal despliegue.

Definición operativa (en el flujo train/val/test)

- Partición: $\mathcal{D} = \mathcal{D}_{\text{train}} \cup \mathcal{D}_{\text{val}} \cup \mathcal{D}_{\text{test}}$ (disjuntos).
- En el pipeline "se aprenden":

$$\theta \text{ (modelo)}, \qquad \phi \text{ (transformaciones)}, \qquad \lambda \text{ (regularización)}, \qquad t \text{ (umbral)}.$$

Fuga de información

Ocurre si $\mathcal{D}_{\text{val/test}}$ influye (directa o indirectamente) en θ, ϕ, λ, t.

Regla de oro

Todo ajuste (`fit`) se hace solo con $\mathcal{D}_{\text{train}}$ (o dentro de cada pliegue).

Idea clave 1: cuándo el test estima el riesgo (sin sesgo)

- Riesgo (pérdida ℓ): $R(f) = \mathbb{E}[\ell(y, f(x))]$.
- Estimador en test:

$$\widehat{R}_{\text{test}}(f) = \frac{1}{n_{\text{test}}} \sum_{(x,y)\in\mathcal{D}_{\text{test}}} \ell(y, f(x)) \,.$$

Condición crítica

$\widehat{R}_{\text{test}}(f)$ es una evaluación honesta si f es **independiente** de $\mathcal{D}_{\text{test}}$.

- Si el test se usa para decidir f (modelo/umbral/variables), se rompe la independencia.
- $\Rightarrow$ la métrica en test se vuelve **optimista** (sesgo).

Idea clave 2: sesgo por selección (mirar test para elegir)

- Si usas $\mathcal{D}_{\text{test}}$ para elegir entre m opciones, el "ganador" suele ganar por **suerte**.
- Test finito: $\widehat{R}_{\text{test}}(f_j) = R(f_j) + \varepsilon_j$ (ruido de muestreo).
- Elegir por el mínimo introduce optimismo:

$$\widehat{R}_{\text{test}}(f_{j^\star}) = \min_j \{R(f_j) + \varepsilon_j\} \quad \text{(tiende a ser menor que } \min_j R(f_j)\text{)}.$$

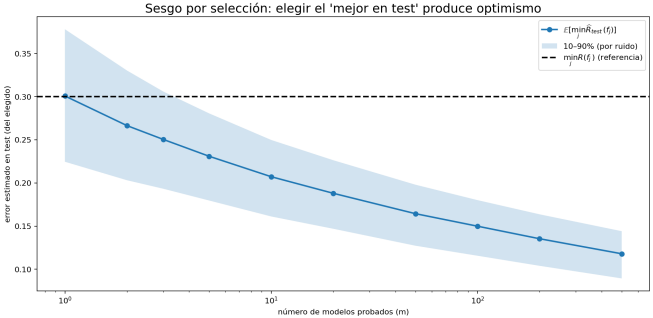

Idea clave 2 (continuación): cómo evitar el sesgo por selección

Regla práctica

El test es para auditar, no para decidir.

- Decide con $\mathcal{D}_{\text{val}}$ o validación cruzada:

$$\text{modelo},\ \lambda,\ \text{variables},\ t\ (\text{umbral}).$$

- Usa $\mathcal{D}_{\text{test}}$ **una sola vez** al final (sin "volver a mover perillas").
- Si ajustaste algo tras ver test, entonces ese test ya no es honesto $\Rightarrow$ necesitas un **nuevo test**.

Idea clave 3: fuga por preprocesamiento (por qué el pipeline importa)

- Transformación: $z = T_\phi(x)$. **Primero** se ajusta ϕ en $\mathcal{D}_{\text{train}}$.

$$\phi \leftarrow \mathrm{fit}(T, \mathcal{D}_{\text{train}}) \qquad \Rightarrow \qquad \theta \leftarrow \arg\min_\theta \widehat{R}_{\text{train}}(\theta \mid \phi).$$

- Fuga: $\phi \leftarrow \mathrm{fit}(T, \mathcal{D}_{\text{train}} \cup \mathcal{D}_{\text{test}})$.

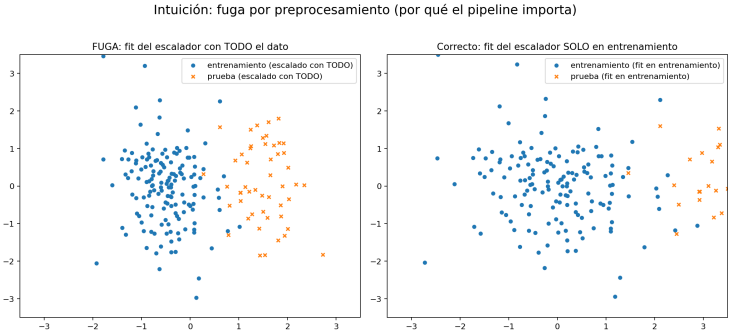

Ejemplo numérico mínimo: “elegí el mejor en test”

Mismo mundo, test finito

Supón que (en realidad) $R(f_A) = R(f_B) = R(f_C) = 0{,}30$.

$$\widehat{R}_{\text{test}}(f_A) = 0{,}28, \quad \widehat{R}_{\text{test}}(f_B) = 0{,}24, \quad \widehat{R}_{\text{test}}(f_C) = 0{,}27$$

- Si eliges y reportas f_B por tener 0.24, ya usaste el test para decidir.
- En un test nuevo, el rendimiento típico “regresa” cerca de 0.30.
- Solución: decide con $\mathcal{D}_{\text{val}}$ (o validación cruzada) y **audita** con $\mathcal{D}_{\text{test}}$.

Checklist: 3 patrones típicos de fuga de información

1. **Preprocesamiento**: ajustar transformaciones con todo el dataset $\Rightarrow$ ϕ debe salir solo de $\mathcal{D}_{\text{train}}$ (o por pliegue).
2. **Variable objetivo**: variables que "usan el futuro" o derivadas del desenlace $\Rightarrow$ la variable debe existir al momento de la decisión.
3. **Partición**: duplicados / mismo cliente-paciente en train y test / partición temporal incorrecta $\Rightarrow$ split por grupo o por tiempo cuando corresponda.

Señal de alarma: métrica "demasiado buena" + caída fuerte al desplegar.

Resumen: reglas prácticas (para no auto-engañarnos)

- **Test** se usa para **auditar** (una vez), no para elegir.
- **Validación / validación cruzada** se usa para decidir λ, variables y umbral t.
- Todo `fit` (modelo y preprocesamiento) vive dentro de train (o dentro del pliegue).
- La partición respeta estructura del dato: tiempo, grupos, duplicados.

Takeaway

Una métrica solo es creíble si el experimento imita el uso real del modelo.

Modelo de referencia: definición + por qué es obligatorio

Modelo de referencia = modelo simple que establece un "piso" de desempeño.

- **Referencia ingenua:** clase mayoritaria (predictor constante)
- **Referencia fuerte:** modelo lineal simple (regresión logística)

Disciplina

No celebramos un modelo si no supera una referencia razonable.

Métricas (clasificación binaria): matriz de confusión

	$\hat{y} = 1$	$\hat{y} = 0$
$y = 1$	TP	FN
$y = 0$	FP	TN

- TP: positivos detectados FN: positivos perdidos
- FP: falsas alarmas TN: negativos correctos

Idea

Todas las métricas de clasificación se construyen con TP, FP, FN, TN.

Precisión / Cobertura (recall): definiciones e intuición

- **Precisión** (pureza):

$$\mathrm{Prec} = \frac{TP}{TP + FP}$$

- **Cobertura** (recall):

$$\mathrm{Rec} = \frac{TP}{TP + FN}$$

Compromiso (umbral)

Al mover el umbral t, cambian $TP, FP, FN \Rightarrow$ cambia (precisión, cobertura).

Ejemplo mínimo: misma exactitud, comportamiento distinto

Dataset desbalanceado

$N = 100$: 10 positivos, 90 negativos.

Modelo A (ingenuo): $\hat{y} = 0$ siempre

$$TP = 0,\ FN = 10,\ FP = 0,\ TN = 90$$

$$\mathrm{Acc} = 0{,}90, \qquad \mathrm{Rec} = 0$$

Modelo B: detecta algunos positivos

$$TP = 6,\ FN = 4,\ FP = 6,\ TN = 84$$

$$\mathrm{Acc} = 0{,}90, \quad \mathrm{Prec} = 0{,}50, \quad \mathrm{Rec} = 0{,}60$$

Mensaje

La **exactitud** puede ocultar fallas en la clase positiva $\Rightarrow$ usamos precisión/recall y curva PR.

Exactitud (accuracy): cuándo sirve y cuándo engaña

Exactitud (accuracy):

$$\mathrm{Acc} = \frac{TP + TN}{TP + TN + FP + FN}.$$

- Útil si las clases están balanceadas y los costos de error son similares.
- Puede engañar con desbalance: puedes tener alta exactitud sin detectar positivos.

Ejemplo mental

Si 5 % son positivos, predecir siempre 0 da 95 % exactitud (pero 0 recall).

Curva Precisión–Recall y AP

- Curva PR: puntos $(\mathrm{Recall}(t), \mathrm{Prec}(t))$ al variar el umbral t.
- Se usa cuando hay **desbalance** y nos importa la **clase positiva**.
- Línea base: un clasificador no-informativo tiene $\mathrm{Prec} \approx \pi$, con $\pi = P(y = 1)$.
- **AP** (Average Precision): resumen escalar tipo "área" bajo la curva PR.

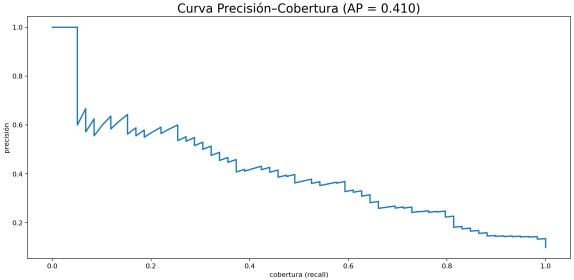

Uso práctico

Elegir t según una meta: recall mínimo o precisión mínima.

Semana 1 — mapa del temario (progreso)

1. Arranque y framing
2. Teoría: workflow de ML
3. Lab NumPy: baseline + split + métricas
4. Lab sklearn: Pipeline + CV + PR-AUC
5. Cierre y entregable

Lab NumPy — objetivo

Contexto: en teoría vimos **generalización**, **fuga de información**, **modelos de referencia** y **métricas** (precisión/recall, exactitud, PR/AP).

Objetivo del lab: construir ese workflow **sin librerías "mágicas"**, para entender qué se calcula y cuándo aparece la fuga.

Al final debes poder:

- generar un dataset binario sintético (X, y)
- hacer un split reproducible train/val/test
- comparar referencia ingenua vs un modelo con **score** + umbral
- medir exactitud, precisión, recall y ver el efecto del umbral
- reproducir una fuga por preprocesamiento (estandarizar "mal" vs "bien")

Archivo: `labs/week01_numpy_baseline.ipynb`

Lab NumPy — pasos (lo que deben implementar)

1. **Datos (reproducible):** genera $X \in \mathbb{R}^{n \times 2}$, $y \in \{0, 1\}$ (dos nubes / dos gaussianas) y grafica por clase.
2. **Split (sin fuga):** ‘rng.permutation‘ + cortes 60/20/20 en train/val/test (verifica tamaños y proporción de positivos).
3. **Referencia ingenua:** predice la clase mayoritaria (decidida con train) y reporta **exactitud** en val y test.
4. **Score + umbral:** define un score simple $s(x)$ y predice $\hat{y} = \mathbb{1}[s(x) \geq t]$.
5. **Barrido de umbral (clave):** evalúa varios t y arma una tabla en val con: t, exactitud, precisión, recall.
6. **Curva PR básica:** con el barrido, grafica puntos (recall, precisión) y elige t según una meta (p. ej. recall mínimo).
7. **Mini-fuga:** estandariza “con todo” vs “solo train” y compara cómo cambian métricas/curva; explica en 2–3 líneas por qué eso es fuga.

Output esperado: tabla de umbrales + gráfica PR + comentario corto (elección de t y nota sobre fuga).

Pausa

Pausa breve

Al volver: **Pipeline + cross-validation + PR-AUC**

Semana 1 — mapa del temario (progreso)

1. Arranque y framing
2. Teoría: workflow de ML
3. Lab NumPy: baseline + split + métricas
4. Lab sklearn: Pipeline + CV + PR-AUC
5. Cierre y entregable

Lab sklearn — objetivo

Objetivo del lab: implementar un pipeline reproducible en `sklearn` que:

- encapsule el preprocesamiento (evitar fuga),
- evalúe de forma estable (validación cruzada),
- y reporte métricas adecuadas (accuracy y AP / PR-AUC).

Al final debes poder:

- construir `Pipeline(StandardScaler, LogisticRegression)`
- evaluar con `cross_val_score` usando:
  - `scoring=.ªccuracy"`
  - `scoring=.ªverage_precision"` (AP / PR-AUC)
- entrenar en train y auditar en test con:
  - `precision_recall_curve`
  - `average_precision_score`

Regla práctica: decisiones con validación/CV; test solo auditoría final.
Archivo: `labs/week01_sklearn_pipeline_cv.ipynb`

¿Qué es cross-validation (CV) y para qué sirve?

- **Definición:** dividir $\mathcal{D}_{\text{trainval}}$ en K pliegues; repetir K veces: entrenar en $K-1$ y validar en 1; promediar la métrica.
- **Pasos (en práctica):**
  - partir $\mathcal{D}_{\text{trainval}}$ en folds $F_1, \ldots, F_K$
  - para $k = 1, \ldots, K$: `fit` en $\mathcal{D}_{\text{trainval}} \setminus F_k$, evaluar en F_k
  - promediar (y reportar variabilidad) de la métrica
  - si hay hiperparámetros (λ, C): elegir el que maximiza el promedio en CV
- **Sirve para:** estimar desempeño con menor varianza y **seleccionar** modelo/hiperparámetros (p. ej. λ, C).
- **No reemplaza al test:** el test se guarda para **auditar una sola vez** al final.
- **Cuidado con fuga:** el `Pipeline` asegura que cada pliegue haga `fit` del preprocesamiento solo con su train.

Regla práctica

Decisiones con CV; test solo auditoría final.

¿Por qué cross-validation ayuda? (intuición)

- Con pocos datos, un solo split (train/val) puede dar una métrica **muy variable**.
- K-fold CV promedia el rendimiento sobre K particiones $\Rightarrow$ estimación más **estable**.
- Para selección de modelo/hiperparámetros: elegir el que maximiza la métrica promedio en CV.
- El **test** queda fuera: sirve para auditar el sistema final (sin volver a ajustar).

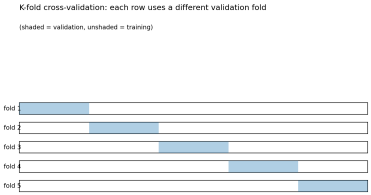

Discusión guiada (al final del lab)

Preguntas

- ¿Cuándo usarías accuracy y cuándo AP/PR-AUC?
- Si hay desbalance, ¿qué te dice AP que no te dice accuracy?
- ¿Qué evita Pipeline que es fácil "romper" si haces preprocessing a mano?

Semana 1 — mapa del temario (progreso)

1. Arranque y framing
2. Teoría: workflow de ML
3. Lab NumPy: baseline + split + métricas
4. Lab sklearn: Pipeline + CV + PR-AUC
5. Cierre y entregable

Checklist final (lo que debe quedar bien hoy)

1. Split correcto (sin contaminar test)
2. Baseline reportado (y comparado)
3. Métrica correcta (accuracy + PR/AP)
4. Evitar leakage (Pipeline / fit solo en train)
5. Reproducibilidad (semilla + requirements + README)

Entregable: repo + notebook plantilla

- Estructura mínima:
  - `slides/week01_intro_workflow.tex`
  - `slides/figs/*.png` (figuras generadas)
  - `labs/week01_numpy_baseline.ipynb`
  - `labs/week01_sklearn_pipeline_cv.ipynb`
  - `README.md` + `requirements.txt` (o `environment.yml`)
- Evidencia mínima:
  - tabla baseline vs logistic (Accuracy + AP)
  - PR curve (imagen) + interpretación (5–6 líneas)

Cierre: 3 ideas para llevarte

1. **Generalización** es el objetivo; train perfecto no impresiona.
2. **Leakage** es el enemigo silencioso; **Pipeline** es tu escudo.
3. **Baselines + métricas correctas** te mantienen honesto.

Semana 2 — Probabilidad (modelos univariados) + Bayes

Bayes, Bernoulli/Binomial, Beta, conjugación y Beta–Binomial (posterior + predictiva)

Curso de Machine Learning — UAQ (Matemáticas Aplicadas)

Libro base: *Probabilistic Machine Learning: An Introduction* (Kevin P. Murphy)

Semana 2

Lecturas sugeridas (para estos temas)

- **Capítulo 2 — Probability: Univariate Models**
  - **2.3** Bayes' rule
  - **2.4** Bernoulli and binomial distributions
  - **2.7.4** Beta distribution
- **Capítulo 4 — Statistics**
  - **4.6.1** Conjugate priors
  - **4.6.2** The beta-binomial model
  - **4.6.2.4** Posterior
  - **4.6.2.9** Posterior predictive
  - **4.6.2.10** Marginal likelihood

Temario de la Semana 2 (qué cubrimos hoy)

- **Teoría (PML)**
  - **Teorema de Bayes** y **piezas** (*prior*, *likelihood*, *posterior*, *evidencia*) **(2.3)**
  - **Modelos Bernoulli y Binomial** **(2.4)**
  - **Distribución Beta** (prior sobre probabilidades) **(2.7.4)**
  - **Conjugación** (por qué Beta es conjugada) **(4.6.1)**
  - **Modelo Beta–Binomial**: posterior y posterior predictiva **(4.6.2)**
- **Lab NumPy**
  - **Beta–Bernoulli**: posterior (actualización por conteos)
  - **Posterior predictiva**: 1 ensayo y M ensayos (simulación)
- **Lab sklearn**
  - **Umbral** (τ) y reglas de decisión
  - **Métricas**: Accuracy vs Precision/Recall vs Average Precision
- **Entregable**

¿Por qué es relevante el enfoque Bayesiano?

- **Objetivo:** inferir $\theta = \Pr(y = 1)$ (una **probabilidad**) a partir de datos D.
- **Incertidumbre explícita:** obtenemos una distribución $p(\theta \mid D)$, no solo un punto.
- **Actualización coherente:** prior + datos $\Rightarrow$ posterior.
- **Predicción robusta:** la **posterior predictiva** integra incertidumbre $\Rightarrow$ menos sobreconfianza con pocos datos.
- **Regularización interpretable:** priors como **pseudoconteos** (suavizado).
- **Comparación de modelos/priors:** evidencia $p(D) =$ **probabilidad marginal de los datos**.

Enfoque frecuentista (ejemplo: tasa de compra)

- Datos: $n = 20$, $k = 3 \Rightarrow \hat{\theta} = 0{,}15$.
- Estimación: $\hat{\theta} = k/n$ (MLE).
- IC 95 % (aprox. normal):

$$\hat{\theta} \pm 1{,}96\sqrt{\frac{\hat{\theta}(1-\hat{\theta})}{n}} = 0{,}15 \pm 0{,}156 \Rightarrow [-0{,}006,\ 0{,}306]$$

- Intervalo válido en $[0, 1]$: $[0,\ 0{,}306]$.
- Interpretación: 95 % de los ICs (en repeticiones) contienen a θ.

Enfoque Bayesiano (mismo ejemplo)

- Prior: $\theta \sim \mathrm{Beta}(2, 8)$ (creencia previa $\approx 0{,}20$).
- Posterior: $\theta \mid D \sim \mathrm{Beta}(5, 25)$.
- Media posterior: $\mathbb{E}[\theta \mid D] = \dfrac{5}{30} \approx 0{,}167$.
- Intervalo creíble 95 %: percentiles de $\mathrm{Beta}(5, 25)$.
- Interpretación: $P(\theta \in \mathrm{ICr} \mid D) = 0{,}95$.

Semana 2 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Motivación: inferir una probabilidad con pocos datos

- Problema base: estimar $\theta = \Pr(y = 1)$ a partir de pocos ensayos Bernoulli.
- Bayes da **distribución** sobre θ, no solo un número.
- Ventaja: incorpora información previa y cuantifica incertidumbre.
- Caso canónico: Bernoulli/Binomial + Beta $\Rightarrow$ actualizaciones cerradas.

Definiciones (2.3): piezas de Bayes

- **Prior:** $p(\theta)$.
- **Likelihood:** $p(D \mid \theta)$.
- **Posterior:** $p(\theta \mid D) = \dfrac{p(D \mid \theta)\, p(\theta)}{p(D)}$.
- **Evidencia:** $p(D) = \int p(D \mid \theta)\, p(\theta)\, d\theta$ (*marginal likelihood*).

Derivación 1 (2.4): likelihood Bernoulli/Binomial

- Datos iid $y_i \in \{0, 1\}$, con $k = \sum_{i=1}^{n} y_i$.
- Bernoulli: $p(y_i \mid \theta) = \theta^{y_i}(1-\theta)^{1-y_i}$.
- Likelihood agregada:

$$p(D \mid \theta) = \prod_{i=1}^{n} \theta^{y_i}(1-\theta)^{1-y_i} = \theta^k(1-\theta)^{n-k}.$$

- Binomial: $p(k \mid n, \theta) = \binom{n}{k}\theta^k(1-\theta)^{n-k}$.

Distribución Beta (2.7.4): prior sobre probabilidades

- Soporte: $\theta \in (0,1)$ (ideal para probabilidades).
- Densidad:

$$\theta \sim \mathrm{Beta}(\alpha, \beta), \qquad p(\theta) = \frac{1}{B(\alpha, \beta)} \theta^{\alpha-1} (1-\theta)^{\beta-1}.$$

- Lectura: α, β controlan **sesgo** (media) y **fuerza** (concentración).
- Interpretación útil: α, β se comportan como **pseudoconteos** de éxitos/fracasos.

Priors Beta: ¿qué "forma" de creencia estás poniendo?

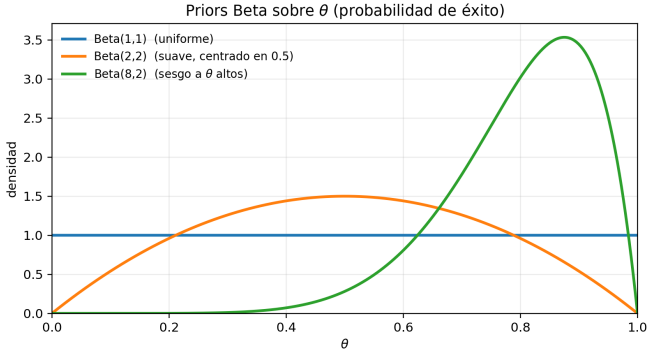

- $\mathrm{Beta}(1,1)$: uniforme.
- $\mathrm{Beta}(2,2)$: suave, centrada en 0,5.
- $\mathrm{Beta}(8,2)$: empuja hacia θ altos.
- **Idea:** el prior dice qué valores de θ son "plausibles" antes de ver datos.

Derivación 2 (4.6.1): conjugación Beta con Bernoulli/Binomial

- Usamos: $p(\theta \mid D) \propto p(D \mid \theta)\, p(\theta)$.
- Como $p(D \mid \theta) \propto \theta^k (1-\theta)^{n-k}$ y $p(\theta) \propto \theta^{\alpha-1}(1-\theta)^{\beta-1}$, el posterior queda:

$$p(\theta \mid D) \propto \theta^{k+\alpha-1}(1-\theta)^{n-k+\beta-1}.$$

- Conjugación (misma familia):

$$\theta \mid D \sim \mathrm{Beta}(\alpha + k,\ \beta + n - k).$$

- Lectura rápida: k suma a "éxitos" y $n-k$ suma a "fracasos".

¿Qué es la **posterior predictiva**?

- **Definición:** distribución de **datos futuros** dado lo observado:

$$p(D_{\text{new}} \mid D) = \int p(D_{\text{new}} \mid \theta)\, p(\theta \mid D)\, d\theta.$$

- **Idea:** en vez de fijar θ a un punto (plug-in), **promediamos** sobre la incertidumbre en θ.
- En Bernoulli/Binomial:
  - 1 paso: $p(y_{\text{new}} = 1 \mid D) = \mathbb{E}[\theta \mid D]$.
  - M pasos: $S = \sum_{j=1}^{M} y_j \mid D$ tiene una distribución (Beta–Binomial) más "ancha" que plug-in.

Predictiva *plug-in* vs predictiva Bayesiana (en una línea)

- **Plug-in:** primero estimas $\hat{\theta}$ (p.ej. MLE/MAP/media posterior) y luego predices como si fuera cierto:

$$p_{\text{plug-in}}(D_{\text{new}} \mid D) = p(D_{\text{new}} \mid \hat{\theta}).$$

- **Bayes:** no fijas θ; promedias con el posterior:

$$p(D_{\text{new}} \mid D) = \int p(D_{\text{new}} \mid \theta)\, p(\theta \mid D)\, d\theta.$$

- **Mensaje:** plug-in suele ser más "optimista"; Bayes tiende a ser menos sobreconfiante con pocos datos.

Modelo Beta–Binomial (4.6.2): posterior y predictiva

- Predictiva 1 paso:

$$p(y_{\text{nuevo}} = 1 \mid D) = \mathbb{E}[\theta \mid D] = \frac{\alpha + k}{\alpha + \beta + n}.$$

- Predictiva de conteos (m futuros):

$$p(k_{\text{new}} \mid m, D) = \binom{m}{k_{\text{new}}} \frac{B(\alpha + k + k_{\text{new}}, \beta + n - k + m - k_{\text{new}})}{B(\alpha + k, \beta + n - k)}.$$

Ejemplo numérico mínimo

- Prior uniforme: $\theta \sim \mathrm{Beta}(1, 1)$.
- Datos: $n = 4$ lanzamientos, $k = 3$ éxitos.
- Posterior: $\theta \mid D \sim \mathrm{Beta}(4, 2)$.
- Predictiva: $p(y_{\text{nuevo}} = 1 \mid D) = \dfrac{4}{6} = \dfrac{2}{3}$.

Derivación (4.6.2.10): evidencia Beta–Binomial $p(k \mid n, \alpha, \beta)$

- Definición (marginalizar θ):

$$p(k \mid n, \alpha, \beta) = \int_0^1 p(k \mid n, \theta)\, p(\theta \mid \alpha, \beta)\, d\theta.$$

- Sustituimos Binomial y Beta:

$$p(k \mid n, \theta) = \binom{n}{k} \theta^k (1-\theta)^{n-k}, \quad p(\theta) = \frac{1}{B(\alpha, \beta)} \theta^{\alpha-1} (1-\theta)^{\beta-1}.$$

- Agrupando potencias:

$$p(k \mid n, \alpha, \beta) = \binom{n}{k} \frac{1}{B(\alpha, \beta)} \int_0^1 \theta^{\alpha+k-1} (1-\theta)^{\beta+n-k-1}\, d\theta.$$

- Reconocemos la integral como $B(\alpha + k, \beta + n - k) \Rightarrow$

$$p(k \mid n, \alpha, \beta) = \binom{n}{k} \frac{B(\alpha + k, \beta + n - k)}{B(\alpha, \beta)}.$$

Evidencia $p(D)$: intuición y comparación de modelos

- **Qué es:** $p(D)$ es la **probabilidad marginal** del dataset (también *marginal likelihood*).
- **Rol en Bayes:** es el **normalizador** (no depende de θ).
- **Intuición:** promedia el likelihood sobre θ "plausibles" según el prior.
- **Comparación:** para dos modelos/priors M_1, M_2,

$$\text{Bayes factor} = \frac{p(D \mid M_1)}{p(D \mid M_2)}.$$

- **Lectura:** favorece modelos que explican bien los datos **sin** "apostar" probabilidad en demasiados θ.

Evidencia: misma data, distinto prior $\Rightarrow$ distinto $p(D)$

- Datos (Binomial): $n = 10$, $k = 7$ éxitos.
- Con prior $\theta \sim \mathrm{Beta}(\alpha, \beta)$:

$$p(k \mid n, \alpha, \beta) = \binom{n}{k} \frac{B(\alpha + k, \beta + n - k)}{B(\alpha, \beta)}.$$

- Evidencias (aprox.):
  - $\mathrm{Beta}(1, 1)$: $p(k \mid n) \approx 0{,}0909$
  - $\mathrm{Beta}(2, 2)$: $p(k \mid n) \approx 0{,}1119$
  - $\mathrm{Beta}(8, 2)$: $p(k \mid n) \approx 0{,}1486$
- **Interpretación (en simple):** estos números dicen qué tan "esperable" era ver $7/10$ *antes* de ver los datos, según cada prior.
- **Lo que importa: comparaciones.** Por ejemplo:

$$\frac{p(D \mid \mathrm{Beta}(8, 2))}{p(D \mid \mathrm{Beta}(1, 1))} \approx 1{,}63, \qquad \frac{p(D \mid \mathrm{Beta}(2, 2))}{p(D \mid \mathrm{Beta}(1, 1))} \approx 1{,}23.$$

Resumen y takeaways

- Bayes (2.3) combina prior y likelihood para obtener $p(\theta \mid D)$.
- Bernoulli/Binomial (2.4) $\Rightarrow$ likelihood $\theta^k(1-\theta)^{n-k}$.
- Beta (2.7.4) $\Rightarrow$ prior natural sobre probabilidades.
- Conjugación (4.6.1): $\mathrm{Beta}(\alpha, \beta) \to \mathrm{Beta}(\alpha + k, \beta + n - k)$.
- Predictiva (4.6.2): promedia sobre $\theta \Rightarrow$ menos sobreconfianza.
- Evidencia (4.6.2.10): $p(D)$ sirve para **comparar** priors/modelos (Bayes factor).

Semana 2 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab NumPy — objetivos (qué debes lograr)

- **Inferencia:** a partir de $y \in \{0,1\}^n$, calcular N_1, N_0 y actualizar $(\alpha, \beta) \to (\alpha', \beta')$.
- **Predicción:** calcular $p(y_{\text{new}} = 1 \mid D)$ y aproximar $p(S \mid D)$ para M futuros.
- **Comparación:** contrastar predictiva *plug-in* vs *Bayesiana* y explicar el efecto del prior (sesgo y fuerza) en 2–3 frases.

Lab NumPy — definiciones mínimas (puente con Teoría)

- **Parámetro:** $\theta = \Pr(y = 1)$.
- **Datos:** $D = \{y_i\}_{i=1}^{n}$, con conteos $N_1 = \sum_i y_i$, $N_0 = n - N_1$.
- **Prior:** $\theta \sim \mathrm{Beta}(\alpha, \beta)$.
- **Posterior (conjugación):** $\theta \mid D \sim \mathrm{Beta}(\alpha', \beta')$, donde $\alpha' = \alpha + N_1$, $\beta' = \beta + N_0$.
- **Posterior predictiva:** $p(D_{\text{new}} \mid D) = \int p(D_{\text{new}} \mid \theta) p(\theta \mid D) d\theta$.
- **Plug-in vs Bayes:** plug-in fija $\theta = \hat{\theta}$; Bayes integra sobre θ.

Lab NumPy — Pregunta 1: ¿Qué datos tengo y qué resumen necesito?

```
ENTRADA: y[1..n]  (valores 0/1)

N1 <- suma(y)
N0 <- n - N1

SALIDA: N1, N0
CHEQUEO: N1 + N0 = n
```

- Definición: N_1 = número de éxitos, N_0 = número de fracasos.

Lab NumPy — Pregunta 2: ¿Qué creía antes de ver datos? (prior)

```
ELIGE el prior (alpha > 0, beta > 0)

EJEMPLOS:
  alpha = 1, beta = 1   (uniforme)
  alpha = 2, beta = 2   (suave, centrado en 0.5)
  alpha = 8, beta = 2   (sesgo hacia theta altos)
```

- Tip: $\alpha + \beta$ controla la "fuerza" del prior.
- Pitfall: prior fuerte sin justificar.

Lab NumPy — Pregunta 3: ¿Qué creo después de ver datos? (posterior)

```
ACTUALIZA (conjugacion Beta--Bernoulli):
alpha_post <- alpha + N1
beta_post  <- beta  + N0

SALIDA: alpha_post, beta_post
CHEQUEO: alpha_post > 0 y beta_post > 0
```

- Definición: $\alpha' = \alpha + N_1$, $\beta' = \beta + N_0$.

Lab NumPy — Pregunta 4: ¿Qué predigo del siguiente ensayo? (predictiva 1 paso)

```
PREDICTIVA POSTERIOR (1 ensayo):
p1_bayes <- alpha_post / (alpha_post + beta_post)
p0_bayes <- 1 - p1_bayes

SALIDA: p(y_nuevo = 1 | D) = p1_bayes
```

- Definición: $p(y_{\text{new}} = 1 \mid D) = \mathbb{E}[\theta \mid D] = \dfrac{\alpha'}{\alpha' + \beta'}$.

Lab NumPy — Pregunta 5: ¿Qué predigo de M ensayos futuros? (predictiva de conteos)

```
FIJA M (ensayos futuros) y R (numero de simulaciones)

PARA r = 1..R:
  muestrea theta_r ~ Beta(alpha_post, beta_post)
  muestrea S_r ~ Binomial(M, theta_r)

ESTIMA p(S | D) con {S_r} (histograma / frecuencias)
CHEQUEO: suma_s p_hat(S=s | D) ~= 1
```

- Definición: $S = \sum_{j=1}^{M} y_j =$ número de éxitos futuros en M ensayos.
- Lógica Bayesiana: muestrear $\theta \sim \mathrm{Beta}(\alpha', \beta')$ y luego $S \sim \mathrm{Binomial}(M, \theta)$.

Lab NumPy — Pregunta 6: Predictiva plug-in vs Bayesiana

Objetivo: Comparar dos formas de predecir S = número de éxitos en M ensayos futuros.

	S_bayes	**S_plugin**
Qué es	Muestras de $p(S \mid D)$	Muestras de $\mathrm{Bin}(M, \hat{\theta})$
Cómo se obtiene	$\theta \sim \mathrm{Beta}(\alpha', \beta')$, luego $S \sim \mathrm{Bin}(M, \theta)$	$S \sim \mathrm{Bin}(M, \theta_{\mathrm{MAP}})$ con θ fijo
Incertidumbre sobre θ	Sí (integra sobre la posterior)	No (usa un solo $\hat{\theta}$)

Pasos:

1. **Estimador puntual:** θ_{MAP}. Si $\alpha' > 1$ y $\beta' > 1$: $\dfrac{\alpha' - 1}{\alpha' + \beta' - 2}$; si no: $\dfrac{\alpha'}{\alpha' + \beta'}$.
2. **S_plugin:** para $r = 1, \ldots, R$, muestrea $S_r \sim \mathrm{Binomial}(M, \theta_{\mathrm{MAP}})$.
3. **S_bayes:** para $r = 1, \ldots, R$, muestrea $\theta_r \sim \mathrm{Beta}(\alpha', \beta')$, luego $S_r \sim \mathrm{Binomial}(M, \theta_r)$.
4. **Comparar:** media, varianza y una probabilidad de cola (ej. $P(S \leq k)$ o $P(S \geq k)$) de S_plugin vs S_bayes. Opcional: histogramas superpuestos.

Interpretación: S_bayes suele tener más varianza y colas más pesadas; el plug-in suele subestimar la

Lab NumPy — entregables (checklist)

Tu notebook debe incluir (evaluable):

- **Resultados:** (α, β), (α', β'), N_1, N_0, y $p(y_{\text{new}} = 1 \mid D)$.
- **Predictiva:** aproximación de $p(S \mid D)$ para algún M (elige M y R y repórtalos).
- **Comparación:** Bayes vs plug-in (una figura o, mínimo, media/varianza y una probabilidad de cola).
- **Discusión (2–3 frases):** qué cambia al variar $\alpha + \beta$ (fuerza) y la media del prior (sesgo).
- **Reproducible:** semilla fija y celdas sin salidas gigantes.

Semana 2 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab sklearn — objetivo

En un problema binario:

- entrenar un modelo que produzca $\hat{p}$
- barrer umbrales τ y ver trade-offs
- comparar accuracy vs precision/recall vs average precision

Lab sklearn — Paso 1: modelo con probabilidades

```
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression

# X, y: tus datos (numpy arrays)
Xtr, Xte, ytr, yte = train_test_split(X, y, test_size=0.3, random_state=0)

clf = LogisticRegression(max_iter=1000)
clf.fit(Xtr, ytr)

p_hat = clf.predict_proba(Xte)[:, 1]  # scores en [0,1]
```

Lab sklearn — Paso 2: umbral y conteos TP/FP/TN/FN

```
def yhat_from_tau(p, tau):
    return (p >= tau).astype(int)

tau = 0.5
yhat = yhat_from_tau(p_hat, tau)

TP = int(((yhat==1) & (yte==1)).sum())
FP = int(((yhat==1) & (yte==0)).sum())
TN = int(((yhat==0) & (yte==0)).sum())
FN = int(((yhat==0) & (yte==1)).sum())
print(TP, FP, TN, FN)
```

Lab sklearn — Paso 3: métricas por umbral

```
from sklearn.metrics import accuracy_score, precision_score, recall_score

taus = np.linspace(0.0, 1.0, 101)
rows = []
for tau in taus:
    yhat = (p_hat >= tau).astype(int)
    acc = accuracy_score(yte, yhat)
    prec = precision_score(yte, yhat, zero_division=0)
    rec  = recall_score(yte, yhat, zero_division=0)
    rows.append([tau, acc, prec, rec])

rows = np.array(rows)
best_tau_acc = rows[rows[:,1].argmax(), 0]
print("best tau (accuracy):", best_tau_acc)
```

- Pitfall: escoger τ usando el test (se elige con validación).

Lab sklearn — Paso 4: Average Precision (AP) y curva PR

```
from sklearn.metrics import average_precision_score, precision_recall_curve

ap = average_precision_score(yte, p_hat)
prec, rec, thr = precision_recall_curve(yte, p_hat)

print("Average Precision =", ap)
# (Opcional) graficar: rec (x) vs prec (y)
```

Lab sklearn — preguntas guía

- ¿Qué pasa con precision y recall cuando subes τ?
- ¿Por qué accuracy puede ser engañosa con desbalance?
- ¿Qué te dice AP que no te dice un umbral fijo?

Semana 2 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Entregable (Semana 2)

Subir al repo:

- **Notebook 1 (NumPy):** Beta–Bernoulli posterior + posterior predictiva (1 y M).
- **Notebook 2 (sklearn):** umbrales + tabla de métricas + AP (y opcional curva PR).
- **README corto:** cómo correr, qué aprendiste (5–8 líneas) y una figura/tabla destacada.

Checklist de entrega (formato)

- Carpeta: `week02/`
- Nombres: `week02_beta_bernoulli.ipynb`, `week02_thresholding_metrics.ipynb`
- Celdas limpias (sin outputs gigantes) y semilla fija donde aplique.
- Commits pequeños con mensajes claros.
- Reproducible: `requirements.txt` o `environment.yml` (si ya lo estamos usando).

Cierre

- Bayes = prior $\times$ likelihood $\rightarrow$ posterior (actualización).
- Conjugación = actualizaciones simples (conteos $\rightarrow$ parámetros).
- Predicción Bayesiana integra incertidumbre $\Rightarrow$ menos sobreconfianza.
- En clasificación: el score no es la decisión; la decisión depende del umbral y del objetivo.

Semana 3 — Probabilidad (modelos multivariados)

De describir dependencia a inferir faltantes: $\Sigma/R \to$ MVN $\to$ Mahalanobis $\to$ condicionamiento $\to$ imputación (Iris) $\to$ GMM

Curso de Machine Learning — UAQ (Matemáticas Aplicadas)

Libro base: *Probabilistic Machine Learning: An Introduction* (Kevin P. Murphy)

Semana 3

Lecturas sugeridas (para estos temas)

- **Capítulo 3 — Probability: Multivariate Models**
  - **3.1.1** Covarianza
  - **3.1.2** Correlación
  - **3.1.3** No correlación $\not\Rightarrow$ independencia
  - **3.1.4** Correlación $\not\Rightarrow$ causalidad
  - **3.1.5** Paradoja de Simpson
  - **3.2.1** Definición de la MVN
  - **3.2.2** Distancia de Mahalanobis
  - **3.2.3** Marginales y condicionales de una MVN *
  - **3.2.4** Ejemplo: condicionamiento en una Gaussiana 2D
  - **3.2.5** Ejemplo: imputación de valores faltantes *
  - **3.3.1** Regla de Bayes para gaussianas
  - **3.5.1** Modelos de mezcla gaussianos (GMM)

Temario de la Semana 3 (qué cubrimos hoy)

- **Teoría (PML)**
  - **1) Describir dependencia:** $\hat{\Sigma}$ y $\hat{R}$ **(3.1.1–3.1.2)**
  - **2) Interpretar con cuidado:** $\rho = 0 \not\Rightarrow$ independencia; correlación $\not\Rightarrow$ causalidad; Simpson **(3.1.3–3.1.5)**
  - **3) Modelar:** MVN $\mathcal{N}(\mu, \Sigma)$ como baseline **(3.2.1)**
  - **4) Geometría/probabilidad:** Mahalanobis (qué tan "raro" es un punto) **(3.2.2)**
  - **5) Inferir:** marginales/condicionales y condicionamiento por bloques **(3.2.3)**
  - **6) Aplicación:** imputación (Iris) como $\mathbb{E}[X_m \mid X_o]$ **(3.2.5)**
  - **7) Extensión:** GMM para multimodalidad **(3.5.1)**
- **Lab NumPy**
  - **Condicionamiento en una MVN** (bloques + fórmulas)
  - **Imputación:** $\mathbb{E}[x_{\text{miss}} \mid x_{\text{obs}}]$
  - **Evaluación:** MSE en valores ocultados
- **Lab sklearn**
  - **GaussianMixture:** ajustar un GMM en 2D
  - **Leer parámetros:** weights, means, covariances
  - **Visualización:** puntos + elipses por componente
- **Entregable**

Hilo conductor de la semana (Iris)

- Vamos a usar **Iris** como ejemplo mental: 4 variables (sépalo/pétalo).
- **Pregunta 1 (describir):** ¿qué variables se mueven juntas? $\Rightarrow \hat{\Sigma}$, $\hat{R}$.
- **Pregunta 2 (modelar):** si aproximamos con una MVN, ¿cómo se ve la nube? $\Rightarrow$ geometría de Σ.
- **Pregunta 3 (medir rareza):** ¿qué puntos son atípicos bajo ese modelo? $\Rightarrow$ Mahalanobis.
- **Pregunta 4 (inferir faltantes):** si falta una variable, ¿qué valor es más plausible? $\Rightarrow$ condicionamiento $\rightarrow$ imputación.
- **Pregunta 5 (ir más allá):** si hay varias "nubes", ¿cómo lo modelamos? $\Rightarrow$ GMM.

Semana 3 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Punto de partida: vector aleatorio, media y covarianza

- En datos reales (p. ej. Iris), cada fila es un vector $x \in \mathbb{R}^D$ (aquí $D = 4$).
- Modelamos X como vector aleatorio: $X \in \mathbb{R}^D$.
- **Media**: $\mu = \mathbb{E}[X]$ (valor "típico" por variable).
- **Covarianza**: $\Sigma = \mathbb{E}[(X - \mu)(X - \mu)^\top]$ (escala y dependencia lineal).
- **Entrada**: $\Sigma_{ij} = \mathrm{Cov}(X_i, X_j)$ indica si dos variables tienden a subir/bajar juntas.

Construcción en práctica: $\hat{\Sigma}$ y $\hat{R}$ (pasos)

1. **Paso 1 — datos:** Tenemos n observaciones $x_1, \ldots, x_n$ (filas). Puede ser Iris (4 variables) o un ejemplo 3D.
2. **Paso 2 — covarianza muestral:** Estimamos $\hat{\Sigma}_{ij}$ como el promedio centrado de productos de desviaciones:
$$\hat{\Sigma}_{ij} = \frac{1}{n-1} \sum_{k=1}^{n} (x_{ki} - \bar{x}_i)(x_{kj} - \bar{x}_j), \quad \bar{x}_i = \frac{1}{n} \sum_{k=1}^{n} x_{ki}.$$
Diagonal = varianza muestral; fuera de diagonal = covarianza (nota: *unidades mezcladas*).
3. **Paso 3 — correlación:** Estandarizamos a escala $[-1, 1]$:
$$\hat{R}_{ij} = \frac{\hat{\Sigma}_{ij}}{\sqrt{\hat{\Sigma}_{ii}\hat{\Sigma}_{jj}}}.$$
4. **Lectura rápida:** usa $\hat{R}$ para comparar dependencias; usa $\hat{\Sigma}$ para cálculos (geometría y condicionamiento).

$\hat{\Sigma}$ vs $\hat{R}$: mismo dato, dos "lentes"

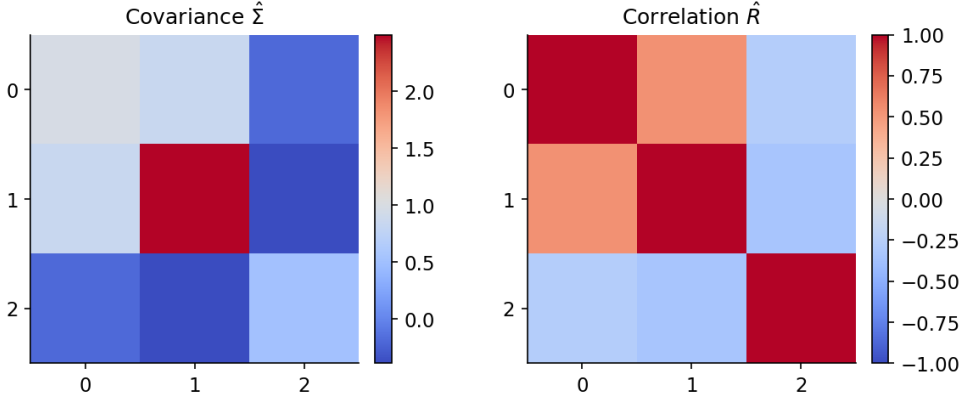

Idea: la izquierda conserva escala (varianzas grandes dominan); la derecha estandariza y hace comparables las relaciones lineales.

Izquierda: $\hat{\Sigma}$. Derecha: $\hat{R}$.

Alerta 1: $\rho = 0$ no implica independencia

- **Mensaje**: correlación mide *dependencia lineal*. Puede haber relación no lineal con $\rho \approx 0$.
- **Hecho**: $\mathrm{Cov}(X, Y) = 0 \not\Rightarrow X \perp Y$ (salvo casos especiales como gaussianas).
- **Traducción práctica**: "no hay correlación" $\neq$ "no hay relación".

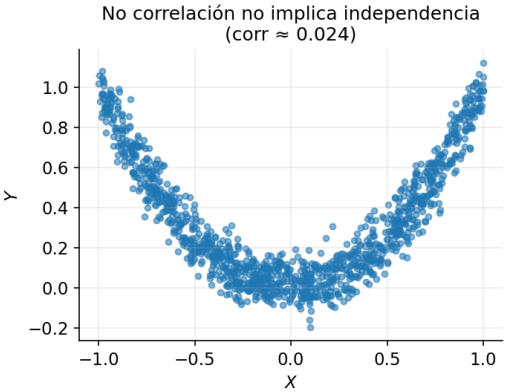

Alerta 2: correlación no implica causalidad

- Una correlación puede venir de **confusores**, **sesgo de selección** o **causalidad invertida**.
- **Pregunta guía**: ¿qué variable podría estar afectando a ambas? ¿qué estoy dejando fuera?

Paradoja de Simpson: cuando el agregado engaña

- **Definición**: una tendencia en datos **agregados** cambia (o se invierte) al **estratificar** por una tercera variable.
- **Ejemplo (Berkeley, 1973)**: al controlar por departamento, la interpretación cambia.
  - **Agregado**: parece haber sesgo.
  - **Estratificado**: aparece el rol del confusor (departamento).

Paradoja de Simpson: visualización y "checklist mental"

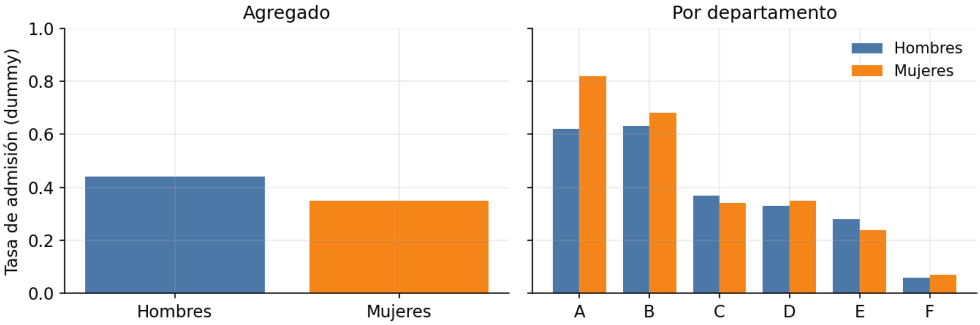

- **Checklist**: antes de concluir, pregunta "¿qué variable podría estar mezclando grupos?".
- Ejemplos de estratos: departamento, cohorte, nivel educativo, hospital/escuela, etc.

MVN: un baseline probabilístico para vectores

- Idea: aproximar una nube de datos con una sola *elipse* (2D) / *elipsoide* (D).
- Notación: $X \sim \mathcal{N}(\mu, \Sigma)$.
- μ: centro; Σ: escala + orientación (forma).
- Esto nos da dos cosas: **geometría** (elipses) y **cálculo cerrado** (condicionales).

Geometría de Σ: cómo "lee" la MVN la nube de datos

- En una MVN, las curvas de igual densidad son *elipses*/*elipsoides*.
- **Autovectores**: direcciones principales (ejes) de la nube.
- **Autovalores**: dispersión en cada dirección (eje $\propto \sqrt{\lambda}$).
- **Lectura práctica**: Σ codifica *escala* y *correlación* en una sola matriz.

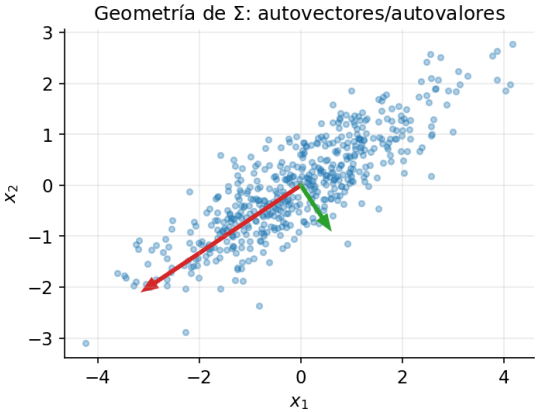

Distancia de Mahalanobis: qué es y para qué sirve

- **Definición:**

$$d_M(x, \mu) = \sqrt{(x-\mu)^\top \Sigma^{-1} (x-\mu)}.$$

- **Intuición:** mide "lejanía" en unidades que respetan *escala* y *correlación*.
- **Sirve para:**
  - detectar *atípicos* bajo una MVN (outliers),
  - entender el *log-likelihood* gaussiano (el término cuadrático),
  - conectar con GMM: cada componente usa su Σ_k para medir cercanía.
- **Puente:** la geometría que define d_M es la misma que usamos al **condicionar** (siguiente bloque).

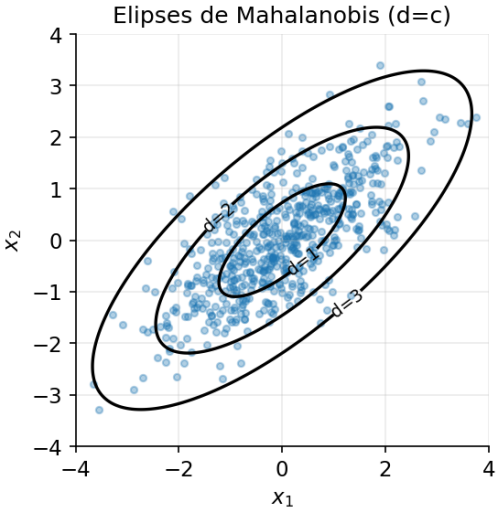

De “medir rareza” a “inferir faltantes”

- Con μ y Σ ya podemos:
  - evaluar qué tan plausible es un punto (vía d_M),
  - y también **inferir** partes faltantes de un vector.
- La herramienta clave es que en la MVN, **marginales** y **condicionales** siguen siendo gaussianas.

Marginales y condicionales en una MVN (la pieza que habilita todo)

- **Marginal**: si te quedas con algunas coordenadas, sigues en el mundo gaussiano.
- **Condicional**: si conoces parte del vector, la distribución del resto también es gaussiana.
- **Consecuencia**: podemos calcular $\mathbb{E}[X_{\text{faltante}} \mid X_{\text{observado}}]$ en forma cerrada $\Rightarrow$ imputación.

Condicionamiento por bloques: la receta (MVN)

- **Notación**: a = variables *observadas*; b = variables *faltantes* (o las que queremos predecir).
- Partición:

$$x = \begin{pmatrix} x_a \\ x_b \end{pmatrix}, \quad \mu = \begin{pmatrix} \mu_a \\ \mu_b \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{pmatrix}.$$

- Resultado: $X_b \mid X_a = a \sim \mathcal{N}(\mu_{b|a}, \Sigma_{b|a})$.
- Fórmulas:

$$\mu_{b|a} = \mu_b + \Sigma_{ba}\Sigma_{aa}^{-1}(a - \mu_a), \qquad \Sigma_{b|a} = \Sigma_{bb} - \Sigma_{ba}\Sigma_{aa}^{-1}\Sigma_{ab}.$$

- Nota: $\Sigma_{b|a}$ no depende de a. Para imputación "simple", usamos la media $\mu_{b|a}$.

Condicionamiento por bloques: ejemplo numérico (D=5)

Ejemplo: observamos 3 variables (a) y faltan 2 (b). Así "se ven" μ y Σ.

- Vector de medias: $\mu = \begin{pmatrix} 2{,}1 \\ 1{,}8 \\ 3{,}0 \\ 4{,}2 \\ 5{,}5 \end{pmatrix}$ (shape $(5,)$).
- Matriz de covarianza Σ (shape (5×5)):

$$\Sigma = \begin{pmatrix} 1{,}2 & 0{,}5 & 0{,}3 & 0{,}4 & 0{,}2 \\ 0{,}5 & 0{,}9 & 0{,}2 & 0{,}3 & 0{,}1 \\ 0{,}3 & 0{,}2 & 1{,}5 & 0{,}6 & 0{,}4 \\ 0{,}4 & 0{,}3 & 0{,}6 & 2{,}0 & 0{,}8 \\ 0{,}2 & 0{,}1 & 0{,}4 & 0{,}8 & 1{,}8 \end{pmatrix}$$

- Partición: $a =$ índices $[0, 1, 2]$ (observadas), $b =$ índices $[3, 4]$ (faltantes).

Condicionamiento por bloques: ejemplo numérico (D=5) — subbloques

- **Partir** μ en observado/faltante:

$$\mu_a = \begin{pmatrix} 2{,}1 \\ 1{,}8 \\ 3{,}0 \end{pmatrix} \quad (\text{shape } (3,)), \qquad \mu_b = \begin{pmatrix} 4{,}2 \\ 5{,}5 \end{pmatrix} \quad (\text{shape } (2,)).$$

- **Partir** Σ en 4 bloques (observado-observado, observado-faltante, etc.):

$$\Sigma_{aa} = \begin{pmatrix} 1{,}2 & 0{,}5 & 0{,}3 \\ 0{,}5 & 0{,}9 & 0{,}2 \\ 0{,}3 & 0{,}2 & 1{,}5 \end{pmatrix} \quad (\text{shape } (3 \times 3)),$$

$$\Sigma_{ab} = \begin{pmatrix} 0{,}4 & 0{,}2 \\ 0{,}3 & 0{,}1 \\ 0{,}6 & 0{,}4 \end{pmatrix} \quad (\text{shape } (3 \times 2)), \qquad \Sigma_{ba} = \Sigma_{ab}^\top, \quad \Sigma_{bb} = \begin{pmatrix} 2{,}0 & 0{,}8 \\ 0{,}8 & 1{,}8 \end{pmatrix} \quad (\text{shape } (2 \times 2)).$$

- **Lectura**: Σ_{aa} es lo que invertimos; Σ_{ba} "transporta" información de observado $\rightarrow$ faltante.
- Para imputar: $\mu_{b|a} = \mu_b + \Sigma_{ba}\Sigma_{aa}^{-1}(x_a - \mu_a)$ (shape $(2,)$).

Condicionamiento en 2D: intuición visual (rebanar la elipse)

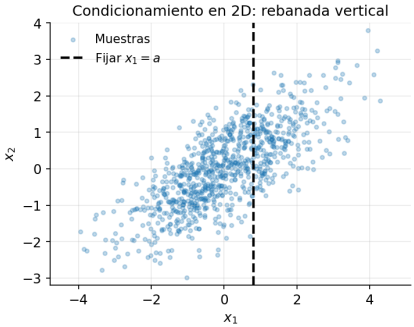

- En 2D: observado $a = x_1$, faltante $b = x_2$.
- Fijar $x_1 = a$ "rebana" la nube: queda una normal 1D para $x_2 \mid x_1 = a$.

Imputación (Iris) = condicionamiento + evaluación honesta

- **Idea**: tratar "faltante" como X_m y lo observado como X_o.
- **Regla**: imputación determinista $x_m \leftarrow \mathbb{E}[X_m \mid X_o = x_o]$ (media condicional).
- **Experimento**: ocultamos ancho del pétalo en 20 % de filas; estimamos (μ, Σ) con las filas observadas; imputamos y comparamos.
- **Gráfica**: cada punto azul = una celda ocultada (verdadero vs imputado). Diagonal $y = x$ = ideal.
- **Métrica**: MSE **solo** donde ocultaste; compara contra baseline (media marginal por columna).

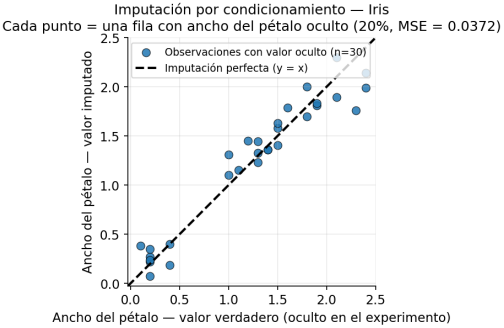

¿Por qué no basta una sola MVN? (puente a mixtures)

- Una MVN = una sola "nube elíptica".
- En Iris, distintas especies sugieren **más de una nube** (multimodalidad).
- Solución: **mezcla** = suma ponderada de varias MVNs.

GMM: varias elipses para explicar una nube compleja

- Modelo:

$$p(x) = \sum_{k=1}^{K} \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k), \qquad \sum_k \pi_k = 1,\ \pi_k \geq 0.$$

- En 2D, cada componente induce una elipse; el modelo suma "nubes".
- Interpretación: π_k (peso), μ_k (centro), Σ_k (forma).
- Conexión: "cercanía" a cada componente se relaciona con Mahalanobis y su log-likelihood.

Cierre: qué te llevas de Week03

- $\hat{\Sigma}$ conserva escala; $\hat{R}$ estandariza para comparar dependencias.
- Interpretación cuidadosa: $\rho = 0 \not\Rightarrow$ independencia; correlación $\not\Rightarrow$ causalidad; cuidado con Simpson.
- MVN + Σ da geometría; Mahalanobis mide "rareza" bajo esa geometría.
- Condicionamiento MVN es cerrado $\Rightarrow$ imputación como $\mathbb{E}[X_m \mid X_o]$.
- Si hay varias nubes, GMM (mezcla de elipses) es una extensión natural.

Semana 3 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab NumPy — objetivo general

- Implementar la **media condicional** de una MVN por bloques (la receta de Teoría).
- Aplicarla a **imputación** (p. ej. Iris: ocultar una columna y recuperarla).
- Evaluar sin engañarse: MSE **solo** en valores ocultados + baseline.
- Reproducibilidad: semilla fija, reporta N y % faltantes.

Lab NumPy — notación y shapes (traducción Teoría → código)

- `mu (D,)`: vector de medias; `mu[i]` = media de la variable i.
- `Sigma (D,D)`: covarianza; `Sigma[i,j]` = $\mathrm{cov}(X_i, X_j)$.
- `idx_a / idx_b`: índices de observado/faltante (en Iris, $D = 4$ y puedes ocultar "petal width").
- `x_a`: valores observados de una fila; es el "a" numérico de esa observación.
- Fórmula por fila (media condicional): $\mu_{b|a} = \mu_b + \Sigma_{ba}\Sigma_{aa}^{-1}(x_a - \mu_a)$.

Lab NumPy — Pseudocódigo 1: partir en bloques

```
# INPUT:
#   mu:    shape (D,)    # vector de medias
#   Sigma: shape (D,D)   # matriz de covarianza
#   idx_a: índices observados
#   idx_b: índices faltantes

mu_a = mu[idx_a]                          # (Da,)
mu_b = mu[idx_b]                          # (Db,)
S_aa = Sigma[np.ix_(idx_a, idx_a)]        # (Da,Da)
S_ab = Sigma[np.ix_(idx_a, idx_b)]        # (Da,Db)
S_ba = Sigma[np.ix_(idx_b, idx_a)]        # (Db,Da)
S_bb = Sigma[np.ix_(idx_b, idx_b)]        # (Db,Db)

# CHEQUEO: S_aa debe ser invertible (si no, regulariza: S_aa += eps*I)
```

Lab NumPy — Pseudocódigo 2: media condicional → imputación

```
# Precompute una vez (fuera del loop por filas):
S_aa_inv = inv(S_aa)   # costoso -> hazlo una sola vez

# Para cada fila i con faltantes en idx_b:
x_a = X[i, idx_a]      # valores observados de la fila (Da,)

# Fórmula MVN:
# mu_{b|a} = mu_b + S_ba @ inv(S_aa) @ (x_a - mu_a)
mu_b_given_a = mu_b + S_ba @ S_aa_inv @ (x_a - mu_a)  # (Db,)

# Imputación determinista (media condicional):
X_imputed[i, idx_b] = mu_b_given_a

# Opcional (imputación estocástica):
# S_{b|a} = S_bb - S_ba @ inv(S_aa) @ S_ab
```

Lab NumPy — Pseudocódigo 3: evaluación correcta (MSE)

```
# 1) Guarda el dato completo
X_true = X.copy()                    # (N,D)

# 2) Genera máscara de celdas a ocultar (True = oculto)
mask = make_mask(...)                # (N,D) boolean

# 3) Oculta y luego imputa
X_missing = X_true.copy()
X_missing[mask] = NaN
X_imputed = impute(X_missing)        # tu función del pseudocódigo 2

# 4) Evalúa solo donde ocultaste (para no "hacer trampa")
mse = mean( (X_true[mask] - X_imputed[mask])**2 )

# Baseline: imputar por media marginal (media de columna)
```

Semana 3 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab sklearn — objetivo general

- Ajustar un **GMM** en 2D (elige K, fija semilla).
- Leer parámetros: pesos, medias y covarianzas $\Rightarrow$ "varias elipses".
- Visualizar: puntos + elipses por componente.
- Interpretar: 2–3 frases (¿qué parte de la nube captura cada componente?).

GMM: cómo interpretar π_k, μ_k, Σ_k

- π_k: proporción de datos que "explica" el componente k.
- μ_k: centro del componente.
- Σ_k: forma/orientación (elipse) del componente.
- **Pregunta guía:** ¿el componente captura estructura real o está "partiendo" artificialmente una sola nube?

GMM en 2D: visualización (puntos + elipses)

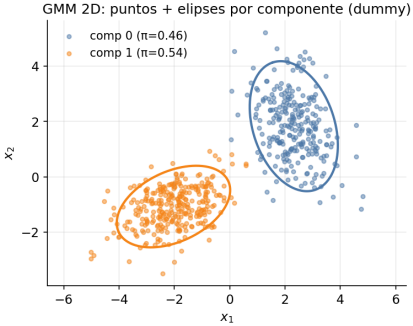

- Elipses = covarianza por componente; colores = componente más probable.
- Lectura: cada elipse es una "nube" gaussiana; el mixto suma varias nubes.

Lab sklearn — Checklist (mínimo indispensable)

```
# INPUT:
#   X: shape (N,2)   # datos 2D

# PASOS:
# 1) ajustar GaussianMixture(K)
# 2) leer weights_, means_, covariances_
# 3) predecir componente / probabilidades
# 4) graficar puntos + elipses

# OUTPUT:
#   figura 2D + breve interpretación
```

Semana 3 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Entregable — qué se evalúa

- **Notebook 1 (NumPy):** condicionamiento por bloques $\rightarrow$ imputación $\rightarrow$ MSE (con baseline).
- **Notebook 2 (sklearn):** GMM 2D $\rightarrow$ parámetros $\rightarrow$ visualización + interpretación breve.
- **Reproducible:** semilla, N, % faltantes (si aplica), y una conclusión corta por notebook.

Semana 4 — Estadística: MLE / ERM

Likelihood $\to$ log-likelihood $\to$ MLE en Bernoulli/Gaussiana $\to$ ERM y pérdidas sustitutas

Curso de Machine Learning — UAQ (Matemáticas Aplicadas)

Libro base: *Probabilistic Machine Learning: An Introduction* (Kevin P. Murphy)

Semana 4

Lecturas sugeridas (para estos temas)

- **Capítulo 4 — Statistics**
  - **4.1** Introduction
  - **4.2** Maximum likelihood estimation (MLE)
    - **4.2.1** Definition
    - **4.2.2** Justification for MLE
    - **4.2.3** Bernoulli
    - **4.2.4** Categorical
    - **4.2.5** Univariate Gaussian
    - **4.2.6** Multivariate Gaussian
    - **4.2.7** Linear regression **(vista previa)**
  - **4.3** Empirical risk minimization (ERM)
    - **4.3.1** Minimizing the misclassification rate
    - **4.3.2** Surrogate loss

Temario de la Semana 4 (qué cubrimos hoy)

- **Teoría (PML)**
  - **1) Lenguaje correcto:** probabilidad vs likelihood **(4.1)**
  - **2) MLE como optimización:** producto $\to$ suma (log) $\to$ NLL **(4.2.1)**
  - **3) Por qué MLE tiene sentido:** "mejor ajuste" dentro del modelo **(4.2.2)**
  - **4) Ejemplos canónicos:** Bernoulli, Categórica, Gaussiana 1D (y MVN) **(4.2.3–4.2.6)**
  - **5) ERM:** riesgo empírico, 0-1 y pérdidas sustitutas **(4.3.1–4.3.2)**
- **Lab NumPy**
  - **Implementar** $\ell(\theta)$, NLL y MLE analítico (Bernoulli + Gaussiana)
  - **Validar** con búsqueda por rejilla (grid) + checks numéricos
- **Lab sklearn**
  - **Equivalencias:** MLE $\leftrightarrow$ minimizar log-loss (intercept-only)
  - **ERM:** ver 0-1 vs log-loss en un barrido de probabilidades
- **Entregable**

Hilo conductor (dos preguntas "universales")

- **Pregunta A (estadística):** dado un modelo $p(x \mid \theta)$ y datos D, ¿qué θ los hace más plausibles? **(4.2)**
- **Pregunta B (ML):** dado un modelo f_θ y una pérdida ℓ, ¿qué θ minimiza el error promedio en train? **(4.3)**
- **Mensaje:** para modelos probabilísticos, MLE $\equiv$ minimizar NLL, que es un caso de ERM con log-loss.

Semana 4 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Probabilidad vs likelihood (no es solo semántica)

- **Probabilidad/densidad:** $p(x \mid \theta)$ como función de x, con θ fijo.
- **Likelihood:** $L(\theta; x) = p(x \mid \theta)$ como función de θ, con x fijo. **(4.1)**
- **Error común:** interpretar $L(\theta)$ como una distribución sobre θ (no tiene por qué sumar/integrar 1).
- Con datos iid: $p(D \mid \theta) = \prod_{i=1}^{n} p(x_i \mid \theta)$.

Definición de MLE: optimización sobre θ

- **Definición:**

$$\hat{\theta}_{\mathrm{MLE}} = \arg\max_{\theta} p(D \mid \theta). \qquad \textbf{(4.2.1)}$$

- Si los datos son iid:

$$p(D \mid \theta) = \prod_{i=1}^{n} p(x_i \mid \theta).$$

- **Intuición:** elegir el θ que hace "grandes" las probabilidades/densidades de los datos observados.

Log-likelihood y NLL: la forma computable

- Producto $\to$ suma:

$$\ell(\theta) = \log p(D \mid \theta) = \sum_{i=1}^{n} \log p(x_i \mid \theta). \qquad \textbf{(4.2.1)}$$

- **NLL (negative log-likelihood):** $\mathrm{NLL}(\theta) = -\ell(\theta)$.
- **Práctico:** evita underflow y es la forma típica de entrenamiento en ML.

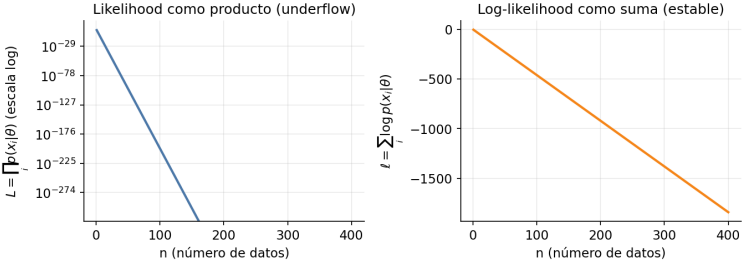

Por qué MLE "tiene sentido" (una lectura útil)

- Maximizar $\ell(\theta)$ equivale a maximizar el promedio $\frac{1}{n}\sum_i \log p(x_i \mid \theta)$. **(4.2.2)**
- **Lectura:** elige el miembro de la familia $p(\cdot \mid \theta)$ que mejor se ajusta a los datos (dentro del modelo).
- **Advertencia:** si el modelo está mal especificado, MLE aun da el "mejor" θ dentro de esa familia, pero no "arregla" el modelo.

Ejemplo MLE 1: Bernoulli (resultado = frecuencia)

- Datos $x_i \in \{0,1\}$, $p(x \mid \pi) = \pi^x (1-\pi)^{1-x}$. **(4.2.3)**
- Log-likelihood (sea $S = \sum_i x_i$):

$$\ell(\pi) = S \log \pi + (n - S) \log(1 - \pi).$$

- **MLE:** $\hat{\pi} = \dfrac{S}{n} = \bar{x}$.

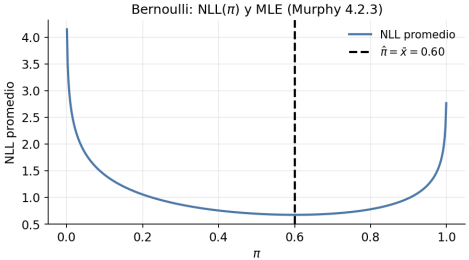

Ejemplo MLE 2: Categórica (resultado = proporciones)

- $x \in \{1, \ldots, K\}$, $p(x = k \mid \boldsymbol{\pi}) = \pi_k$, $\sum_k \pi_k = 1$. **(4.2.4)**
- Con conteos n_k: $\ell(\boldsymbol{\pi}) = \sum_{k=1}^{K} n_k \log \pi_k$.
- **MLE:** $\hat{\pi}_k = \dfrac{n_k}{n}$ (frecuencia por clase).
- **Check:** $\sum_k \hat{\pi}_k = 1$. Si $n_k = 0$, evaluar $\log \pi_k$ requiere cuidado numérico.

Ejemplo MLE 3: Gaussiana 1D (media y varianza MLE)

- $x_i \sim \mathcal{N}(\mu, \sigma^2)$. **(4.2.5)**
- NLL (ignorando constantes):

$$\mathrm{NLL}(\mu, \sigma^2) = \frac{n}{2} \log \sigma^2 + \frac{1}{2\sigma^2} \sum_{i=1}^{n} (x_i - \mu)^2.$$

- **MLE:** $\hat{\mu} = \bar{x}$, $\hat{\sigma}^2 = \frac{1}{n} \sum_i (x_i - \bar{x})^2$.
- Nota: el estimador "insesgado" usa $1/(n-1)$, pero no es el MLE.

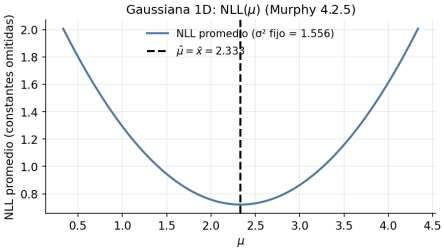

MLE en MVN: misma idea, en $\mathbb{R}^d$

- $\mathbf{x}_i \in \mathbb{R}^d$, $\mathbf{x}_i \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$. **(4.2.6)**
- **MLE:**

$$\hat{\boldsymbol{\mu}} = \frac{1}{n}\sum_{i=1}^{n} \mathbf{x}_i, \qquad \hat{\Sigma} = \frac{1}{n}\sum_{i=1}^{n} (\mathbf{x}_i - \hat{\boldsymbol{\mu}})(\mathbf{x}_i - \hat{\boldsymbol{\mu}})^\top.$$

- **Checks:** $\hat{\Sigma} \succeq 0$; puede ser singular si $n < d$.

ERM: la versión ML de "ajustar parámetros"

- Riesgo poblacional:

$$R(f) = \mathbb{E}[\ell(f(x), y)].$$

- Riesgo empírico:

$$\hat{R}(f) = \frac{1}{n} \sum_{i=1}^{n} \ell(f(x_i), y_i) \,. \qquad \textbf{(4.3)}$$

- **Mensaje:** en ML casi siempre minimizamos $\hat{R}$ (lo computable).

Misclassification rate (0-1): por qué es difícil optimizar

- Pérdida 0-1: $\ell_{0/1}(\hat{y}, y) = \mathbb{I}[\hat{y} \neq y]$. **(4.3.1)**
- Empírico: $\hat{R}_{0/1} = \frac{1}{n} \sum_i \mathbb{I}[\hat{y}_i \neq y_i]$ (tasa de error).
- **Problema:** no es suave; pequeños cambios en θ pueden no cambiar $\hat{y} \Rightarrow$ gradientes poco útiles.

Surrogate loss: hacer optimizable el problema

- Reemplazamos 0-1 por pérdidas que sean **optimizables** y correlacionen con acertar. **(4.3.2)**
- Para modelos probabilísticos, surrogate natural = **log-loss**:

$$\ell(\theta) = -\log p(y \mid x, \theta).$$

- **Puente:** minimizar NLL es ERM con log-loss:

$$\min_{\theta} \frac{1}{n} \sum_{i} -\log p(y_i \mid x_i, \theta).$$

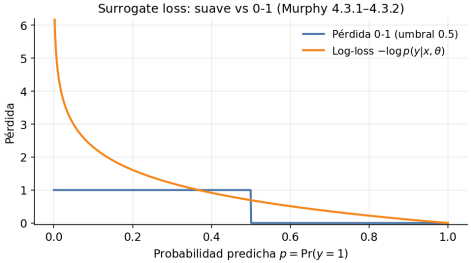

Semana 4 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab NumPy — objetivo general

- Implementar $\ell(\theta)$ y $\mathrm{NLL}(\theta)$ para Bernoulli y Gaussiana. **(4.2.1)**
- Calcular MLE **analítico** y validarlo con grid search. **(4.2.3, 4.2.5)**
- Incluir checks: clipping, $\sigma^2 > 0$, y comparación de mínimos.

Lab NumPy — checklist (qué debe aparecer en tu notebook)

- **Bernoulli:** $\hat{\pi} = \bar{x}$, curva $\mathrm{NLL}(\pi)$ por rejilla, y mínimo en $\hat{\pi}$. **(4.2.3)**
- **Gaussiana 1D:** $\hat{\mu} = \bar{x}$, $\hat{\sigma}^2$ (MLE), y validación por rejilla. **(4.2.5)**
- **Numerical hygiene:** evitar $\log 0$, evitar $\sigma^2 \leq 0$, usar NLL promedio para comparar.

Semana 4 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab sklearn — objetivo general

- Ver la equivalencia: MLE $\leftrightarrow$ minimizar log-loss (ERM con surrogate). **(4.3.2)**
- Caso simple: **logística intercept-only** $\Rightarrow$ Bernoulli (probabilidad constante). **(4.2.3)**
- Comparar 0-1 vs log-loss en un barrido de $p \in (0, 1)$. **(4.3.1–4.3.2)**

Logística intercept-only: la versión "ML" del Bernoulli

- Si el modelo predice una probabilidad constante p, el MLE Bernoulli es $\hat{p} = \bar{y}$. **(4.2.3)**
- En logística con solo intercept b: $p = \sigma(b) = \frac{1}{1+e^{-b}}$.
- Relación: $b = \log \frac{p}{1-p}$ (logit). Así, $\hat{b} = \log \frac{\bar{y}}{1-\bar{y}}$.
- **Check:** la probabilidad promedio predicha debe ser $\approx \bar{y}$ (si no hay regularización fuerte).

Semana 4 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Entregable — qué se evalúa

- **Slides:** comprensión conceptual (likelihood/log-likelihood/NLL, MLE, ERM).
- **Notebook NumPy:** implementación de NLL + MLE analítico + validación por grid + checks.
- **Notebook sklearn:** equivalencia log-loss/MLE (intercept-only) + comparación con 0-1.
- **Reproducible:** semilla fija, outputs limpios, y 5–8 líneas de interpretación.

Cierre: tres ideas para llevarte

1. **MLE** = elegir θ que maximiza $p(D \mid \theta)$ (mejor "explica" los datos). **(4.2)**
2. Trabajamos casi siempre con **log-likelihood/NLL** por estabilidad y porque suma pérdidas. **(4.2.1)**
3. **ERM** + **surrogates**: entrenar = minimizar un promedio de pérdidas; log-loss conecta directo con MLE. **(4.3)**

Semana 5 — Decision theory y evaluación de modelos

De probabilidades a decisiones: riesgo esperado, costos asimétricos, umbral $\rightarrow$ matriz de confusión, ROC/PR, AUC $\rightarrow$ validación cruzada

Curso de Machine Learning — UAQ (Matemáticas Aplicadas)

Libro base: *Probabilistic Machine Learning: An Introduction* (Kevin P. Murphy)

Semana 5

Lecturas sugeridas (para estos temas)

- **Capítulo 5 — Decision Theory**
  - **5.1** Bayesian decision theory
    - **5.1.1** Basics (acciones, estados, pérdida, riesgo)
    - **5.1.2** Classification problems (incluye costos asimétricos y reject)
    - **5.1.3** ROC curves
    - **5.1.4** Precision-recall curves
    - **5.1.5** Regression problems (repaso de pérdidas)
    - **5.1.6** Probabilistic prediction problems (log-loss, Brier)
  - **5.4** Empirical risk minimization (vista desde teoría estadística)
- **Capítulo 4 — Statistics**
  - **4.5.4** Picking the regularizer using a validation set
  - **4.5.5** Cross-validation

Temario de la Semana 5 (qué cubrimos hoy)

- **Teoría (PML)**
  - **1) Decision theory:** acciones, estados, pérdida, riesgo esperado **(5.1.1)**
  - **2) Clasificación:** pérdida 0-1, regla MAP y matriz de costos **(5.1.2)**
  - **3) Costos asimétricos:** cómo cambian los umbrales de decisión **(5.1.2.2)**
  - **4) Métricas:** matriz de confusión $\rightarrow$ precision/recall, TPR/FPR, specificity **(5.1.3–5.1.4)**
  - **5) Curvas ROC/PR y AUC:** interpretación y efecto del desbalance **(5.1.3–5.1.4)**
  - **6) Validación y CV:** riesgo empírico vs poblacional, K-fold **(1.2.3, 4.5.4–4.5.5, 5.4.3)**
- **Lab NumPy**
  - Construir matrices de confusión, TPR/FPR y precision/recall desde $\{y, s\}$
  - Generar curvas ROC/PR y calcular AUC / PR-AUC manualmente
  - Elegir umbral óptimo en función de costos asimétricos
- **Lab sklearn**
  - Pipeline de evaluación con `StratifiedKFold` (práctica externa)
  - `confusion_matrix`, `roc_curve`, `precision_recall_curve`
  - Reportar ROC-AUC, PR-AUC y métricas por fold en una tabla
- **Entregable**

Hilo conductor: de “ajustar” a “decidir y evaluar”

- Semana 4: vimos **MLE/ERM** como $\min_\theta \hat{R}(\theta)$ (ajustar parámetros al train).
- Semana 5: suponemos que ya tenemos $p(y \mid x)$ o scores, y ahora toca:
  - **(a) Decidir:** traducir probabilidades en acciones, usando *pérdidas/costos*.
  - **(b) Evaluar:** estimar qué tan bien funcionará el modelo fuera de la muestra.
- **Idea central:** *decision theory* + *evaluación* = puente entre modelos probabilísticos y problemas reales.

Semana 5 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Decision theory: ingredientes básicos

- **Estados del mundo** $h \in \mathcal{H}$: clase verdadera, valor real, etc.
- **Acciones** $a \in \mathcal{A}$: predecir una clase, un número, dar/no dar un tratamiento, elegir un modelo, etc.
- **Pérdida/costo** $\ell(h, a)$: qué tan "mala" es la acción a si la realidad es h. **(5.1.1)**
- **Riesgo posterior** dado evidencia x:

$$\rho(a \mid x) = \mathbb{E}_{p(h|x)}[\ell(h, a)].$$

- **Regla de decisión Bayesiana**:

$$\pi^*(x) = \arg\min_{a \in \mathcal{A}} \rho(a \mid x).$$

- **Ejemplo mental**: médico que decide entre "no tratar" o "dar fármaco caro con efectos secundarios" a un paciente que puede (o no) tener COVID-19.

Decision theory: ejemplo COVID-19 (tabla de pérdidas)

- **Estados** $h \in \mathcal{H}$: combinación de
  - edad (joven vs viejo),
  - estado de enfermedad (COVID-19 vs no COVID-19).
- **Acciones** $a \in \mathcal{A}$: $\{$*Nothing* (no tratar), *Drugs* (dar fármaco)$\}$.
- Usamos *QALYs* (quality-adjusted life years) como unidad de costo/beneficio:
  - joven: 60 QALYs esperados si se salva;
  - viejo: 10 QALYs esperados si se salva;
  - el fármaco "cuesta" 8 QALYs (dolor, efectos secundarios).
- **QALY** (*quality-adjusted life year*) $\approx$ "un año de vida en perfecta salud"; años con peor salud aportan menos de 1 QALY.

State	Nothing	Drugs
No COVID-19, young	0	8
COVID-19, young	60	8
No COVID-19, old	0	8
COVID-19, old	10	8

Decision theory: cómo leer la tabla de pérdidas

- La tabla no muestra los QALYs que la persona *tiene*, sino cuántos QALYs **pierde** por la combinación estado/acción.
- Fila "No COVID-19, young":
  - **Nothing = 0**: el joven sano tiene muchos QALYs de vida potencial, pero la decisión de no tratar *no le quita ninguno*.
  - **Drugs = 8**: tratarlo innecesariamente le hace perder 8 QALYs (efectos secundarios, sufrimiento, secuelas).
- Fila "COVID-19, young":
  - **Nothing = 60**: si no se trata y muere, se pierden los 60 QALYs que habría tenido.
  - **Drugs = 8**: el tratamiento le salva la vida pero "cuesta" 8 QALYs de calidad.
- Igual razonamiento para el paciente viejo con COVID-19 (10 vs 8 QALYs de pérdida).

Riesgo esperado y política óptima (ejemplo COVID-19)

- Dado lo que observamos x (p. ej. resultado del test y edad), el **riesgo** de una acción a es la pérdida esperada:

$$\rho(a \mid x) = \mathbb{E}[\ell(h, a) \mid x] = \sum_{h \in \mathcal{H}} \ell(h, a)\, p(h \mid x).$$

- En el ejemplo, una acción es $a =$ **Nothing** (*no hacer nada*). Llamamos **cost-noop** al riesgo de esa acción:

$$\text{cost-noop}(x) = \rho(\text{Nothing} \mid x).$$

- La **política óptima** elige, para cada x, la acción con menor riesgo:

$$\pi^*(x) = \arg\min_{a \in \mathcal{A}} \rho(a \mid x).$$

- Los **inputs** del ejemplo son: `test` (negativo/positivo), age (joven/viejo) y $p(\text{COVID} \mid x)$. En la siguiente slide veremos cómo se calcula cost-noop; al final tendremos la tabla con la decisión óptima.

Ejemplo COVID-19: cálculo de `cost-noop` (fórmula)

- Por definición, el cost-noop es el riesgo de la acción "no hacer nada":

$$\text{cost-noop}(x) = \mathbb{E}[\ell(h, \text{Nothing}) \mid x] = \sum_h \ell(h, \text{Nothing})\, p(h \mid x).$$

- **Paciente joven**: de la tabla de pérdidas, $\ell(\text{No COVID}, \text{young}, \text{Nothing}) = 0$ y $\ell(\text{COVID}, \text{young}, \text{Nothing}) = 60$. Entonces

$$\text{cost-noop} = 0 \cdot p(\text{No COVID} \mid x) + 60 \cdot p(\text{COVID} \mid x) = 60\, p(\text{COVID} \mid x).$$

- **Paciente mayor**: $\ell(\text{No COVID}, \text{old}, \text{Nothing}) = 0$, $\ell(\text{COVID}, \text{old}, \text{Nothing}) = 10$, luego

$$\text{cost-noop} = 10\, p(\text{COVID} \mid x).$$

- Los valores de la tabla se obtienen sustituyendo $p(\text{COVID} \mid x)$ por las probabilidades que da el test (siguiente slide).

Ejemplo COVID-19: `cost-noop` (valores numéricos)

- Con las probabilidades del test: $p(\text{COVID} \mid \text{test} = 0) \approx 0{,}014$, $p(\text{COVID} \mid \text{test} = 1) \approx 0{,}7955$.
- Sustituyendo en las fórmulas anteriores:
  - **Test negativo**: joven $60 \times 0{,}014 = 0{,}84$; mayor $10 \times 0{,}014 = 0{,}14$.
  - **Test positivo**: joven $60 \times 0{,}7955 = 47{,}73$; mayor $10 \times 0{,}7955 = 7{,}95$.

test	age	pr(covid)	cost-noop	cost-drugs	action
0	0	0.01	0.84	8.00	0
0	1	0.01	0.14	8.00	0
1	0	0.80	47.73	8.00	1
1	1	0.80	7.95	8.00	0

- **Comparación**: cost-drugs $= 8$ siempre. Si cost-noop < 8 conviene no tratar (action=0); si cost-noop > 8, tratar (action=1). Por eso, con test positivo y paciente joven, la política óptima es tratar; con test positivo y mayor, no tratar (7.95 y 8 son muy cercanos).

De pérdida a utilidad: el mismo principio

- En muchos textos se usa **utilidad** $U(h, a)$ en vez de pérdida $\ell(h, a)$.
- Relación simple: $U(h, a) = -\ell(h, a)$.
- **Máxima utilidad esperada**:

$$\pi^*(x) = \arg\max_{a \in \mathcal{A}} \mathbb{E}_{p(h|x)}[U(h, a)].$$

- En ML solemos pensar en **minimizar pérdida promedio** (riesgo) $\leftrightarrow$ **maximizar utilidad esperada**.

Clasificación binaria con pérdida 0-1

- Estados y acciones son las clases: $\mathcal{H} = \mathcal{A} = \{0, 1\}$. **(5.1.2.1)**
- **Pérdida** 0-1:

$$\ell_{0/1}(y^*, \hat{y}) = \mathbf{1}[y^* \neq \hat{y}].$$

- Riesgo posterior de predecir $\hat{y}$:

$$\rho(\hat{y} \mid x) = 1 - p(y^* = \hat{y} \mid x).$$

- **Regla óptima**: elegir la clase más probable (MAP):

$$\hat{y}(x) = \arg \max_{y \in \{0,1\}} p(y \mid x).$$

Costos asimétricos en binario: matriz de pérdida

- En muchos problemas, **no todos los errores cuestan igual**.
- Matriz de pérdida general:

$$\ell(y^*, \hat{y}) = \begin{pmatrix} \ell_{00} & \ell_{01} \\ \ell_{10} & \ell_{11} \end{pmatrix},$$

  donde filas = verdad, columnas = predicción. **(5.1.2.2)**
- Ejemplo clásico: detección de enfermedad
  - FP (decir "enfermo" cuando está sano) = costo moderado.
  - FN (decir "sano" cuando está enfermo) = costo muy alto.

Costos asimétricos $\Rightarrow$ umbral distinto de 0.5

- Sea $p_1 = p(y^* = 1 \mid x)$, $p_0 = 1 - p_1$, donde y^* es la **etiqueta verdadera** (ground truth) y $\hat{y}$ la predicción.
- Así, $p_1 =$ probabilidad de que la clase real sea 1 dado x; $p_0 =$ probabilidad de que sea 0.
- Riesgo de predecir $\hat{y} = 1$:
$$\rho(1 \mid x) = \ell_{01} p_0 + \ell_{11} p_1.$$
- Riesgo de predecir $\hat{y} = 0$:
$$\rho(0 \mid x) = \ell_{00} p_0 + \ell_{10} p_1.$$
- Caso típico $\ell_{00} = \ell_{11} = 0$: predecir 1 si
$$p_1 \geq \frac{\ell_{01}}{\ell_{01} + \ell_{10}}.$$
- Si un FN cuesta c veces más que un FP ($\ell_{10} = c\,\ell_{01}$):
$$p_1 \geq \frac{1}{1 + c}.$$
- **Ejemplo**: $c = 4 \Rightarrow$ umbral $1/5 = 0{,}2$ (somos mucho más "sensibles").

Costos asimétricos: de dónde sale el umbral

- Con $\ell_{00} = \ell_{11} = 0$ (acertar no cuesta), el riesgo de predecir 1 es $\rho(1 \mid x) = \ell_{01}(1 - p_1)$; el de predecir 0 es $\rho(0 \mid x) = \ell_{10} p_1$.
- Predecimos 1 cuando $\rho(1 \mid x) \leq \rho(0 \mid x)$, es decir

$$\ell_{01}(1 - p_1) \leq \ell_{10} p_1 \iff \ell_{01} - \ell_{01} p_1 \leq \ell_{10} p_1 \iff \ell_{01} \leq p_1(\ell_{01} + \ell_{10}) \iff p_1 \geq \frac{\ell_{01}}{\ell_{01} + \ell_{10}}.$$

- Si $\ell_{10} = c\,\ell_{01}$ (un FN cuesta c veces un FP):

$$p_1 \geq \frac{1}{1 + c}.$$

- **Interpretación**: $c = 4 \Rightarrow$ umbral 0.2. Bajamos el umbral respecto a 0.5 para ser más sensibles: preferimos más FP que perder casos reales (FN).

Costos asimétricos: umbral 0.5 vs umbral óptimo

- Con **umbral 0.5** (costos simétricos): predecimos 1 solo si $p_1 \geq 0{,}5$.
- Con **umbral** $1/(1+c)$ (FN cuesta c veces un FP): predecimos 1 si $p_1 \geq 1/(1+c)$.
- Si $c > 1$, entonces $1/(1+c) < 0{,}5$: el umbral óptimo es *menor* que 0.5.
- **Ejemplo** $c = 4$: umbral 0,2. Un modelo que da $p_1 = 0{,}3$:
  - Con 0.5: predeciríamos 0 ("sano"); con 0.2: predecimos 1 ("tratar").
  - Priorizamos no perder enfermos (menos FN), aunque haya más falsas alarmas (más FP).

Costos asimétricos: ejemplo numérico completo

- Supongamos la siguiente matriz de pérdida para un clasificador médico:

$$\ell(y^*, \hat{y}) = \begin{pmatrix} 0 & 1 \\ 5 & 0 \end{pmatrix},$$

  donde $y^* = 0 =$ sano, $y^* = 1 =$ enfermo.
- Entonces un FN (enfermo etiquetado como sano) cuesta 5 veces un FP $\Rightarrow c = 5$.
- El **umbral óptimo** según decision theory es

$$p_1^\star = \frac{1}{1+c} = \frac{1}{6} \approx 0{,}17.$$

- **Interpretación práctica**:
  - Si $p(y = 1 \mid x) = 0{,}20$: bajo 0,5 dirías "sano"; bajo 0,17 ya vale la pena tratar.
  - Si $p(y = 1 \mid x) = 0{,}05$: incluso con costos asimétricos, sigue por debajo del umbral 0,17.

Matriz de confusión: conectar decisiones con conteos

- Para un clasificador binario con umbral fijo:
  - **TP**: verdaderos positivos
  - **FP**: falsos positivos
  - **TN**: verdaderos negativos
  - **FN**: falsos negativos
- Tabla (forma de **Tabla 5.3**):

	$\hat{y} = 0$	$\hat{y} = 1$
$y = 0$	TN	FP
$y = 1$	FN	TP

Derivar métricas desde la matriz de confusión

- Normalizando por filas (condicionado en la verdad): **(5.1.3.1, 5.1.3.2)**
  - **TPR / recall / sensitivity**: $\mathrm{TPR} = \dfrac{TP}{TP + FN}$.
  - **TNR / specificity**: $\mathrm{TNR} = \dfrac{TN}{TN + FP}$.
  - **FPR**: $\mathrm{FPR} = 1 - \mathrm{TNR} = \dfrac{FP}{FP + TN}$.
- Normalizando por columnas (condicionado en la predicción):
  - **Precision / PPV**: $\mathrm{Prec} = \dfrac{TP}{TP + FP}$.
  - **NPV**: $\mathrm{NPV} = \dfrac{TN}{TN + FN}$.
- **Idea**: todas las métricas que usamos (accuracy, recall, precision, etc.) son distintas "vistas" de la misma tabla.

Matriz de confusión: ejemplo numérico

	$\hat{y} = 0$	$\hat{y} = 1$
$y = 0$	50	10
$y = 1$	5	35

- Total negativos verdaderos $N = 60$, positivos verdaderos $P = 40$.
- Accuracy $= (50 + 35)/100 = 0{,}85$.

- **Recall / TPR**:

$$\mathrm{TPR} = \frac{TP}{TP + FN} = \frac{35}{35 + 5} = 0{,}875.$$

- **FPR**:

$$\mathrm{FPR} = \frac{FP}{FP + TN} = \frac{10}{10 + 50} \approx 0{,}167.$$

- **Precision**:

$$\mathrm{Prec} = \frac{TP}{TP + FP} = \frac{35}{35 + 10} \approx 0{,}78.$$

- **NPV**:

$$\mathrm{NPV} = \frac{TN}{TN + FN} = \frac{50}{50 + 5} \approx 0{,}91.$$

Curva ROC: barrer el umbral

- Si el modelo produce un **score** $s(x)$ (p. ej. $p(y = 1 \mid x)$), definimos $\hat{y}_\tau(x) = \mathbf{1}[s(x) \geq \tau]$.
- Para cada τ calculamos TPR_τ y FPR_τ. **(5.1.3)**
- La **curva ROC** grafica TPR_τ vs FPR_τ al variar $\tau \in [0, 1]$.
- **Extremos**:
  - $\tau \to 0$: todo es positivo ($\mathrm{TPR} \approx 1$, $\mathrm{FPR} \approx 1$).
  - $\tau \to 1$: nadie es positivo ($\mathrm{TPR} \approx 0$, $\mathrm{FPR} \approx 0$).

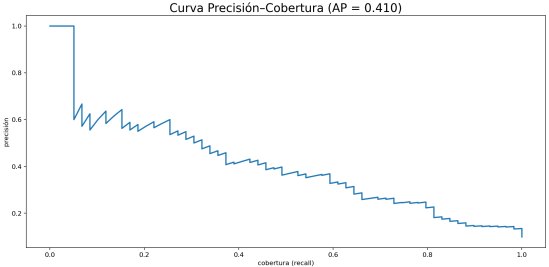

AUC, EER y lectura rápida de ROC

- **AUC** (Area Under the ROC Curve):
  - $\mathrm{AUC} = 1$: clasificador perfecto (curva pegada a la esquina superior izquierda).
  - $\mathrm{AUC} \approx 0{,}5$: como lanzar una moneda (diagonal).
- **Equal Error Rate (EER)**:
  - Punto donde $\mathrm{FPR} = \mathrm{FNR} = 1 - \mathrm{TPR}$. **(5.1.3.2)**
  - Se visualiza como intersección de la ROC con la diagonal descendente.
- **Uso práctico**: ROC es útil cuando el costo de FP/FN no está fijado, y queremos comparar modelos "globalmente".

Curva Precision–Recall (PR): cuando los positivos son raros

- Recordemos:

$$\mathrm{Prec}_\tau = \frac{TP_\tau}{TP_\tau + FP_\tau}, \qquad \mathrm{Rec}_\tau = \frac{TP_\tau}{TP_\tau + FN_\tau}. \qquad \textbf{(5.1.4.1)}$$

- La **curva PR** grafica Prec_τ vs Rec_τ al variar τ.
- Es especialmente informativa cuando hay **fuerte desbalance** ($P \ll N$), donde ROC puede verse "demasiado bonita".
- **PR-AUC / AP**: área (o average precision) bajo la curva PR. **(5.1.4.2)**

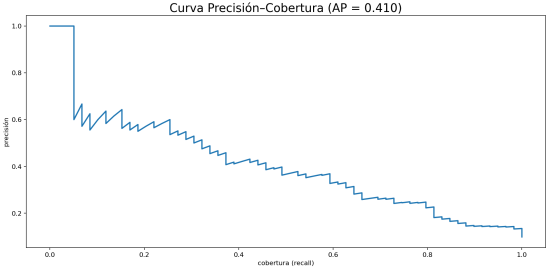

Mini-ejemplo ROC/PR con 5 ejemplos

- Dataset pequeño (ordenado por score descendente):

n	1	2	3	4	5
y_n	1	0	1	0	1
s_n	0,9	0,8	0,6	0,4	0,3

- Hay $P = 3$ positivos, $N = 2$ negativos.
- Si usamos $\tau = 0{,}75$:
  - $\hat{y} = (1, 1, 0, 0, 0) \Rightarrow TP = 1, FP = 1, TN = 1, FN = 2.$
  - $\mathrm{TPR} = 1/3$, $\mathrm{FPR} = 1/2$, $\mathrm{Prec} = 1/2$, $\mathrm{Rec} = 1/3$.
- Si usamos $\tau = 0{,}5$:
  - $\hat{y} = (1, 1, 1, 0, 0) \Rightarrow TP = 2, FP = 1, TN = 1, FN = 1.$
  - $\mathrm{TPR} = 2/3$, $\mathrm{FPR} = 1/2$, $\mathrm{Prec} = 2/3$, $\mathrm{Rec} = 2/3$.

Mini-ejemplo ROC/PR (cont.): puntos en las curvas

- Para el dataset anterior, podemos armar una pequeña tabla:

τ	TPR	FPR	Prec	Rec
1,0	0	0	–	–
0,75	1/3	1/2	1/2	1/3
0,5	2/3	1/2	2/3	2/3
0,25	1	1	3/5	1

- **ROC**: puntos $(\mathrm{FPR}, \mathrm{TPR}) = (0,0), (0{,}5, 1/3), (0{,}5, 2/3), (1,1)$.
- **PR**: puntos $(\mathrm{Rec}, \mathrm{Prec}) = (0,-), (1/3, 1/2), (2/3, 2/3), (1, 3/5)$.
- Con estos pocos puntos ya se puede:
  - visualizar cómo el **umbral** barre las curvas;
  - aproximar AUC/PR-AUC con la regla del trapecio (como en el Lab NumPy).

F-scores: combinar precisión y recall en un solo número

- Para un umbral fijo $(\mathrm{Prec}, \mathrm{Rec})$, el $\mathbf{F}_\beta$ se define como: **(5.1.4.3)**

$$F_\beta = \frac{(1+\beta^2)\,\mathrm{Prec}\,\mathrm{Rec}}{\beta^2\,\mathrm{Prec} + \mathrm{Rec}}.$$

- Casos especiales:
  - F_1: media armónica de precisión y recall (pesa ambos por igual).
  - $\beta > 1$: da más peso a *recall* (importa más cubrir positivos).
  - $\beta < 1$: da más peso a *precision* (importa más evitar FP).
- **Interpretación**: útil para seleccionar el umbral cuando tenemos una preferencia clara por precision o recall.

Desbalance de clases: ROC vs PR

- ROC usa tasas TPR y FPR que **no cambian** si escalamos P y N manteniendo la proporción. **(5.1.3.3)**
- En problemas muy desbalanceados, ROC puede verse buena aunque haya muchos FP absolutos.
- PR (y F-score) sí son **sensibles** a la prevalencia:

$$\mathrm{Prec} = \frac{\mathrm{TPR}}{\mathrm{TPR} + \frac{1}{r}\mathrm{FPR}}, \quad r = \frac{P}{N}. \qquad \textbf{(5.1.4.4)}$$

- **Regla práctica**:
  - Clases balanceadas $\rightarrow$ ROC-AUC es razonable.
  - Clases raras $\rightarrow$ mira PR-AUC / AP y F-scores.

Validación: train / validation / test y leakage

- Separar los datos en:
  - **Train**: ajustar parámetros θ.
  - **Validation**: escoger hiperparámetros (p. ej. λ, arquitectura, umbral).
  - **Test**: estimar $L(\theta^*; p^*)$ una sola vez. **(1.2.3, 4.5.4)**
- **Leakage**: usar test (directa o indirectamente) para tomar decisiones de modelo/hiperparámetros.
- **Consecuencia**: subestimar el error real; el modelo parece mejor de lo que realmente es.

Cross-validation (CV): usar mejor los datos

- Problema: con pocos datos, separar un validation set fijo puede ser caro.
- **K-fold CV** (K-pliegues): **(4.5.5, 5.4.3)**
  - Partimos train en K folds $D_1, \ldots, D_K$.
  - Para cada k: entrenamos en D_{-k} y evaluamos en D_k.
  - Promediamos la métrica (MSE, AUC, F1, etc.) sobre los K folds.
- **Uso típico**: escoger hiperparámetros (p. ej. λ de regularización) y comparar modelos.

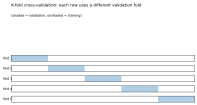

Cross-validation (CV): ejemplo numérico sencillo

- Supongamos $K = 3$ folds y medimos **accuracy** para un modelo:

Fold	Accuracy
1	0,82
2	0,79
3	0,87

- **Promedio**: $\bar{a} = (0{,}82 + 0{,}79 + 0{,}87)/3 \approx 0{,}83$.
- **Desviación estándar** (muestral):

$$s \approx \sqrt{\frac{(0{,}82 - \bar{a})^2 + (0{,}79 - \bar{a})^2 + (0{,}87 - \bar{a})^2}{3 - 1}} \approx 0{,}04.$$

- Reporte típico: accuracy CV $\approx 0{,}83 \pm 0{,}04$.
- **Lectura**: el modelo parece razonablemente estable, pero hay variabilidad entre folds (dependiente del split).

Semana 5 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab NumPy — objetivo general

- Tomar $\{y_n \in \{0,1\}, s_n \in [0,1]\}$ y construir:
  - Matrices de confusión para distintos umbrales τ.
  - Curvas ROC y PR, con AUC / PR-AUC vía regla del trapecio.
- Implementar una función de **riesgo empírico** con matriz de costos ℓ_{ij} y buscar el **umbral óptimo**.

Lab NumPy — checklist (qué debe aparecer en tu notebook)

- **Funciones básicas**:
  - `confusion_counts(y_true, scores, tau)` $\rightarrow$ TP, FP, TN, FN.
  - `metrics_from_confusion(...)` $\rightarrow$ accuracy, TPR, FPR, precision, recall, F1.
- **Curvas y áreas**:
  - `roc_curve_manual` y `pr_curve_manual`.
  - `auc_trapezoidal(x, y)` para ROC-AUC y PR-AUC.
  - Gráficos ROC y PR etiquetados (similar a las figuras del libro).
- **Costos asimétricos**:
  - Función `empirical_risk_tau(y, scores, tau, cost_matrix)`.
  - Gráfico de $\hat{L}(\tau)$ vs τ para distintos cocientes de costos FP/FN.
  - Comparar el τ que minimiza riesgo con el umbral $1/(1+c)$ teórico.

Semana 5 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab sklearn — objetivo general

- Construir un pipeline mínimo de evaluación para clasificación binaria:
  - `StratifiedKFold` para estimar métricas con CV (nota práctica: no aparece como tal en el libro).
  - `confusion_matrix`, `roc_curve`, `roc_auc_score`.
  - `precision_recall_curve`, `average_precision_score`.
- Reportar métricas por fold y su promedio $\pm$ desviación estándar.

Lab sklearn — checklist (estructura sugerida)

- **Datos y modelo**:
  - Dataset binario con cierto desbalance.
  - Modelo sencillo (p. ej. `LogisticRegression` o `RandomForestClassifier`).
- **Cross-validation**:
  - `StratifiedKFold(n_splits=K, shuffle=True, random_state=...)`.
  - Para cada fold: entrenar, obtener `predict_proba` y `predict`.
- **Métricas por fold**:
  - Accuracy, ROC-AUC, PR-AUC (AP), F1.
  - Matriz de confusión.
- **Tabla final**:
  - Filas = folds, columnas = métricas.
  - Fila extra con promedio y desviación estándar.

Semana 5 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Entregable — qué se evalúa

- **Slides:** claridad en:
  - definición de pérdida, riesgo esperado y reglas de decisión;
  - relación entre matriz de confusión, ROC/PR y métricas derivadas;
  - papel de train/validation/test y CV.
- **Notebook NumPy:** construcción manual y correcta de métricas/curvas + selección de umbral con costos.
- **Notebook sklearn:** pipeline de evaluación con CV + tabla de métricas bien interpretada.

Cierre: tres ideas para llevarte

1. **Decision theory** formaliza "qué acción tomar" como arg mín de riesgo esperado (pérdida + probabilidades). **(5.1.1–5.1.2)**
2. **Costos asimétricos** cambian el **umbral óptimo** y, por tanto, la región de operación en la ROC/PR. **(5.1.2.2, 5.1.3–5.1.4)**
3. **Evaluar bien** (train/val/test, CV) es clave para estimar el **riesgo poblacional** y no sobreestimar el modelo. **(1.2.3, 4.5.5, 5.4.3)**