Machine Learning — UAQ

Presentación

Angel Gutiérrez

23 de abril de 2026

Contenido

1. Arranque y framing
2. Teoría: workflow de ML
3. Lab NumPy: baseline + split + métricas
4. Lab sklearn: Pipeline + CV + PR-AUC
5. Cierre y entregable

Semana 1 — Introducción + workflow de Machine Learning

Framing, generalización, overfitting, leakage, baselines y métricas (Accuracy + PR/PR-AUC)

Curso de Machine Learning — UAQ (Matemáticas Aplicadas)

Libro base: *Probabilistic Machine Learning: An Introduction* (Kevin P. Murphy)

Semana 1

Temario de la Semana 1 (qué cubrimos hoy)

1. **Arranque y framing:** dataset $\rightarrow$ modelo $\rightarrow$ predicción $\rightarrow$ decisión
2. **Teoría (slides):**
   - Problem framing (qué es X, qué es y, unidad de predicción)
   - Generalización y overfitting
   - Leakage (conceptual + ejemplos)
   - Baselines
   - Métricas: Accuracy + Precision/Recall + PR-AUC
3. **Lab NumPy:** split + baseline + accuracy + PR básico (+ mini-leakage)
4. **Lab sklearn:** Pipeline + cross_val_score + PR-AUC
5. **Entregable:** repo + notebook plantilla + checklist reproducible

Lecturas sugeridas (PML = libro base) — Semana 1

Lectura previa (fundamentos para la sesión)

- **Cap. 1 — Introduction**
  - ¿Qué es ML? (definición tipo T/P/E) y *supervised learning*
  - *Generalization* y *overfitting* (por qué separar train/test)

Lectura mínima para métricas (lo que usaremos hoy)

- **Cap. 5 — Decision theory**
  - *Precision*, *Recall*, *Precision–Recall curve*
  - *Average Precision* (PR-AUC) como resumen

Lectura posterior (para consolidar evaluación honesta)

- **Cap. 4 — Statistics**
  - *Validation set* y selección de hiperparámetros
  - *Cross-validation* (K-fold): por qué reduce varianza con N pequeño

Semana 1 — mapa del temario (progreso)

1. Arranque y framing
2. Teoría: workflow de ML
3. Lab NumPy: baseline + split + métricas
4. Lab sklearn: Pipeline + CV + PR-AUC
5. Cierre y entregable

¿Qué es "aprender" en ML? (visión de extremo a extremo)

- **Dataset** (observaciones): pares (x_i, y_i)
- **Modelo** f_θ: transforma x en una predicción $\hat{y}$
- **Métrica**: mide qué tan bien predice (Acc, AP/PR-AUC)
- **Decisión**: usar $\hat{y}$ o un score para actuar (aprobar, clasificar, alertar, etc.)

Idea central del curso

El objetivo real no es "ganar en train"; es **generalizar** con evaluación honesta y reproducible.

Semana 1 — mapa del temario (progreso)

1. Arranque y framing
2. Teoría: workflow de ML
   - Problem framing
   - Generalización y overfitting
   - Fuga de información (leakage)
   - Modelos de referencia
   - Métricas
3. Lab NumPy: baseline + split + métricas
4. Lab sklearn: Pipeline + CV + PR-AUC
5. Cierre y entregable

Problem framing: qué debes definir antes de entrenar

- **Unidad de predicción:** ¿qué entidad scoreas? (persona, cliente, imagen, transacción)
- **Features X:** información disponible **al momento de predecir**
- **Target y:** definición operacional (evento + ventana + etiqueta)
- **Salida del modelo:** clase (0/1), probabilidad, score continuo
- **Métrica:** qué significa "éxito" (accuracy, AP, etc.)

Pregunta guía

¿Qué decisión cambia si tengo este score/predicción?

Supervised vs unsupervised vs RL (solo para ubicar)

Supervised

- Tienes etiquetas y
- Objetivo: predecir y desde x
- Ej: spam, precio de casa

Reinforcement Learning

- Aprendes por recompensa acumulada
- Interacción agente–entorno
- Ej: control, juegos

Unsupervised

- No hay y
- Objetivo: estructura/representaciones
- Ej: clustering, PCA

Hoy

Nos enfocamos en **supervised** (clasificación binaria) + evaluación.

Supervised learning: esquema visual (para fijar ideas)

Supervised learning: learn $f(x)$ from labeled pairs (x, y)

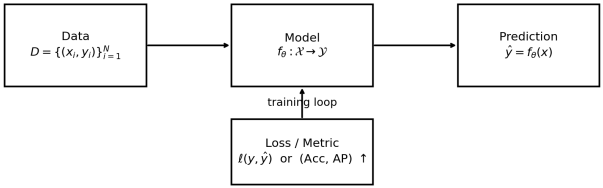

- Entrenamiento: ajustar θ para mejorar una pérdida/métrica en train.
- Evaluación: medir en datos **no usados** para ajustar el modelo.

Generalización: el objetivo real

- Queremos buen desempeño en datos nuevos (out-of-sample).
- Por eso separamos datos: train / validation / test.

Intuición

Train performance es "qué tan bien memoriza".
Test performance es "qué tan bien generaliza".

Overfitting: definición + señal práctica

Overfitting = el modelo se ajusta demasiado a peculiaridades/ruido del train:

- train muy bien, test/val notablemente peor
- "se derrumba" al salir del dataset de entrenamiento

Generalization gap

Diferencia entre el desempeño en train y en val/test.

Overfitting visual (intuición con modelos de distinta complejidad)

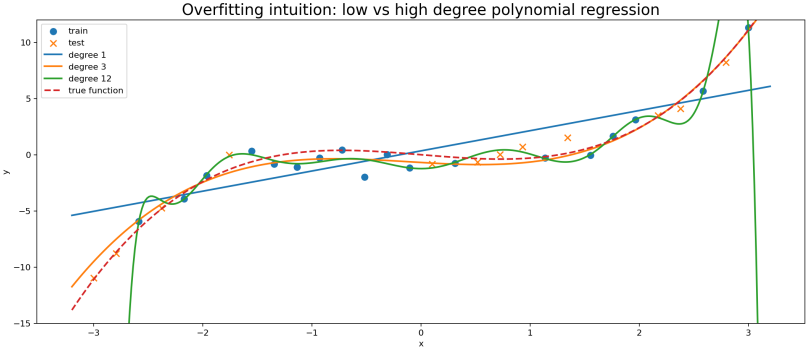

- Modelo simple: puede sub-ajustar (*underfit*)
- Modelo muy flexible: puede memorizar train y fallar en test

Complejidad vs error (por qué el test error es “U-shaped”)

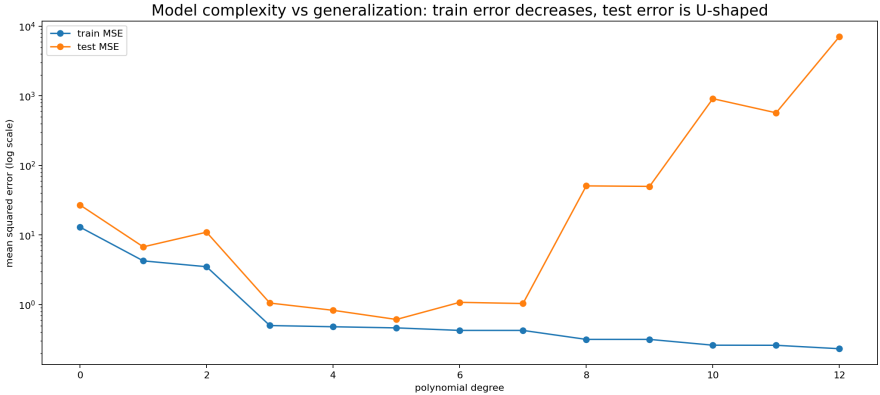

- El **train error** suele bajar con complejidad.
- El **test error** suele tener un mínimo: demasiada complejidad vuelve a empeorar.

Fuga de información: por qué las métricas pueden mentir

Pregunta guía

¿Por qué mi métrica (accuracy / AP) es alta en el cuaderno y cae en producción?

- **Objetivo**: estimar desempeño fuera de muestra (generalización).
- **Problema**: si el proceso "ve" datos del futuro, la evaluación es optimista.
- **Consecuencia**: eliges mal el modelo / umbral $\Rightarrow$ mal despliegue.

Definición operativa (en el flujo train/val/test)

- Partición: $\mathcal{D} = \mathcal{D}_{\text{train}} \cup \mathcal{D}_{\text{val}} \cup \mathcal{D}_{\text{test}}$ (disjuntos).
- En el pipeline "se aprenden":

$$\theta \text{ (modelo)}, \qquad \phi \text{ (transformaciones)}, \qquad \lambda \text{ (regularización)}, \qquad t \text{ (umbral)}.$$

Fuga de información

Ocurre si $\mathcal{D}_{\text{val/test}}$ influye (directa o indirectamente) en θ, ϕ, λ, t.

Regla de oro

Todo ajuste (`fit`) se hace solo con $\mathcal{D}_{\text{train}}$ (o dentro de cada pliegue).

Idea clave 1: cuándo el test estima el riesgo (sin sesgo)

- Riesgo (pérdida ℓ): $R(f) = \mathbb{E}[\ell(y, f(x))]$.
- Estimador en test:

$$\widehat{R}_{\text{test}}(f) = \frac{1}{n_{\text{test}}} \sum_{(x,y)\in\mathcal{D}_{\text{test}}} \ell(y, f(x)) \,.$$

Condición crítica

$\widehat{R}_{\text{test}}(f)$ es una evaluación honesta si f es **independiente** de $\mathcal{D}_{\text{test}}$.

- Si el test se usa para decidir f (modelo/umbral/variables), se rompe la independencia.
- $\Rightarrow$ la métrica en test se vuelve **optimista** (sesgo).

Idea clave 2: sesgo por selección (mirar test para elegir)

- Si usas $\mathcal{D}_{\text{test}}$ para elegir entre m opciones, el "ganador" suele ganar por **suerte**.
- Test finito: $\widehat{R}_{\text{test}}(f_j) = R(f_j) + \varepsilon_j$ (ruido de muestreo).
- Elegir por el mínimo introduce optimismo:

$$\widehat{R}_{\text{test}}(f_{j^\star}) = \min_j \{R(f_j) + \varepsilon_j\} \quad \text{(tiende a ser menor que } \min_j R(f_j)\text{)}.$$

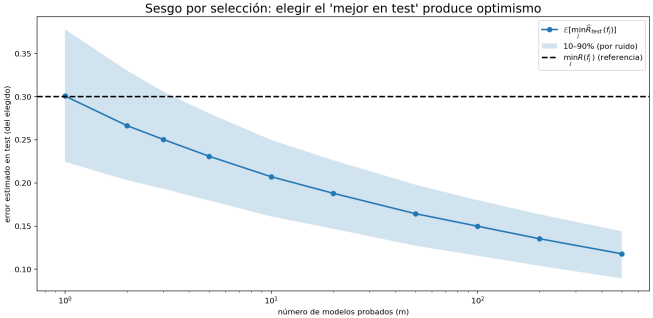

Idea clave 2 (continuación): cómo evitar el sesgo por selección

Regla práctica

El test es para auditar, no para decidir.

- Decide con $\mathcal{D}_{\text{val}}$ o validación cruzada:

$$\text{modelo},\ \lambda,\ \text{variables},\ t\ (\text{umbral}).$$

- Usa $\mathcal{D}_{\text{test}}$ **una sola vez** al final (sin "volver a mover perillas").
- Si ajustaste algo tras ver test, entonces ese test ya no es honesto $\Rightarrow$ necesitas un **nuevo test**.

Idea clave 3: fuga por preprocesamiento (por qué el pipeline importa)

- Transformación: $z = T_\phi(x)$. **Primero** se ajusta ϕ en $\mathcal{D}_{\text{train}}$.

$$\phi \leftarrow \mathrm{fit}(T, \mathcal{D}_{\text{train}}) \qquad \Rightarrow \qquad \theta \leftarrow \arg\min_\theta \widehat{R}_{\text{train}}(\theta \mid \phi).$$

- Fuga: $\phi \leftarrow \mathrm{fit}(T, \mathcal{D}_{\text{train}} \cup \mathcal{D}_{\text{test}})$.

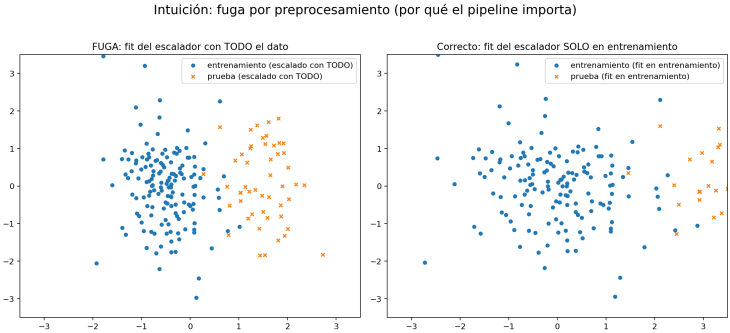

Ejemplo numérico mínimo: “elegí el mejor en test”

Mismo mundo, test finito

Supón que (en realidad) $R(f_A) = R(f_B) = R(f_C) = 0{,}30$.

$$\widehat{R}_{\text{test}}(f_A) = 0{,}28, \quad \widehat{R}_{\text{test}}(f_B) = 0{,}24, \quad \widehat{R}_{\text{test}}(f_C) = 0{,}27$$

- Si eliges y reportas f_B por tener 0.24, ya usaste el test para decidir.
- En un test nuevo, el rendimiento típico “regresa” cerca de 0.30.
- Solución: decide con $\mathcal{D}_{\text{val}}$ (o validación cruzada) y **audita** con $\mathcal{D}_{\text{test}}$.

Checklist: 3 patrones típicos de fuga de información

1. **Preprocesamiento**: ajustar transformaciones con todo el dataset $\Rightarrow$ ϕ debe salir solo de $\mathcal{D}_{\text{train}}$ (o por pliegue).
2. **Variable objetivo**: variables que "usan el futuro" o derivadas del desenlace $\Rightarrow$ la variable debe existir al momento de la decisión.
3. **Partición**: duplicados / mismo cliente-paciente en train y test / partición temporal incorrecta $\Rightarrow$ split por grupo o por tiempo cuando corresponda.

Señal de alarma: métrica "demasiado buena" + caída fuerte al desplegar.

Resumen: reglas prácticas (para no auto-engañarnos)

- **Test** se usa para **auditar** (una vez), no para elegir.
- **Validación / validación cruzada** se usa para decidir λ, variables y umbral t.
- Todo `fit` (modelo y preprocesamiento) vive dentro de train (o dentro del pliegue).
- La partición respeta estructura del dato: tiempo, grupos, duplicados.

Takeaway

Una métrica solo es creíble si el experimento imita el uso real del modelo.

Modelo de referencia: definición + por qué es obligatorio

Modelo de referencia = modelo simple que establece un "piso" de desempeño.

- **Referencia ingenua:** clase mayoritaria (predictor constante)
- **Referencia fuerte:** modelo lineal simple (regresión logística)

Disciplina

No celebramos un modelo si no supera una referencia razonable.

Métricas (clasificación binaria): matriz de confusión

	$\hat{y} = 1$	$\hat{y} = 0$
$y = 1$	TP	FN
$y = 0$	FP	TN

- TP: positivos detectados FN: positivos perdidos
- FP: falsas alarmas TN: negativos correctos

Idea

Todas las métricas de clasificación se construyen con TP, FP, FN, TN.

Precisión / Cobertura (recall): definiciones e intuición

- **Precisión** (pureza):

$$\mathrm{Prec} = \frac{TP}{TP + FP}$$

- **Cobertura** (recall):

$$\mathrm{Rec} = \frac{TP}{TP + FN}$$

Compromiso (umbral)

Al mover el umbral t, cambian $TP, FP, FN \Rightarrow$ cambia (precisión, cobertura).

Ejemplo mínimo: misma exactitud, comportamiento distinto

Dataset desbalanceado

$N = 100$: 10 positivos, 90 negativos.

Modelo A (ingenuo): $\hat{y} = 0$ siempre

$$TP = 0,\ FN = 10,\ FP = 0,\ TN = 90$$

$$\mathrm{Acc} = 0{,}90, \qquad \mathrm{Rec} = 0$$

Modelo B: detecta algunos positivos

$$TP = 6,\ FN = 4,\ FP = 6,\ TN = 84$$

$$\mathrm{Acc} = 0{,}90, \quad \mathrm{Prec} = 0{,}50, \quad \mathrm{Rec} = 0{,}60$$

Mensaje

La **exactitud** puede ocultar fallas en la clase positiva $\Rightarrow$ usamos precisión/recall y curva PR.

Exactitud (accuracy): cuándo sirve y cuándo engaña

Exactitud (accuracy):

$$\mathrm{Acc} = \frac{TP + TN}{TP + TN + FP + FN}.$$

- Útil si las clases están balanceadas y los costos de error son similares.
- Puede engañar con desbalance: puedes tener alta exactitud sin detectar positivos.

Ejemplo mental

Si 5 % son positivos, predecir siempre 0 da 95 % exactitud (pero 0 recall).

Curva Precisión–Recall y AP

- Curva PR: puntos $(\mathrm{Recall}(t), \mathrm{Prec}(t))$ al variar el umbral t.
- Se usa cuando hay **desbalance** y nos importa la **clase positiva**.
- Línea base: un clasificador no-informativo tiene $\mathrm{Prec} \approx \pi$, con $\pi = P(y = 1)$.
- **AP** (Average Precision): resumen escalar tipo "área" bajo la curva PR.

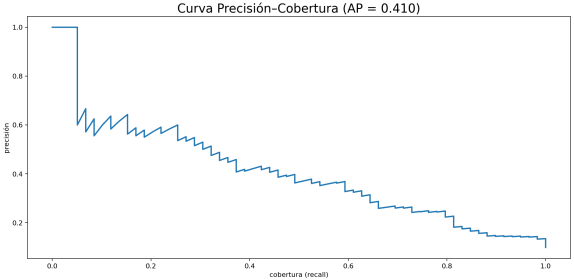

Uso práctico

Elegir t según una meta: recall mínimo o precisión mínima.

Semana 1 — mapa del temario (progreso)

1. Arranque y framing
2. Teoría: workflow de ML
3. Lab NumPy: baseline + split + métricas
4. Lab sklearn: Pipeline + CV + PR-AUC
5. Cierre y entregable

Lab NumPy — objetivo

Contexto: en teoría vimos **generalización**, **fuga de información**, **modelos de referencia** y **métricas** (precisión/recall, exactitud, PR/AP).

Objetivo del lab: construir ese workflow **sin librerías "mágicas"**, para entender qué se calcula y cuándo aparece la fuga.

Al final debes poder:

- generar un dataset binario sintético (X, y)
- hacer un split reproducible train/val/test
- comparar referencia ingenua vs un modelo con **score** + umbral
- medir exactitud, precisión, recall y ver el efecto del umbral
- reproducir una fuga por preprocesamiento (estandarizar "mal" vs "bien")

Archivo: `labs/week01_numpy_baseline.ipynb`

Lab NumPy — pasos (lo que deben implementar)

1. **Datos (reproducible):** genera $X \in \mathbb{R}^{n \times 2}$, $y \in \{0, 1\}$ (dos nubes / dos gaussianas) y grafica por clase.
2. **Split (sin fuga):** ‘rng.permutation‘ + cortes 60/20/20 en train/val/test (verifica tamaños y proporción de positivos).
3. **Referencia ingenua:** predice la clase mayoritaria (decidida con train) y reporta **exactitud** en val y test.
4. **Score + umbral:** define un score simple $s(x)$ y predice $\hat{y} = \mathbb{1}[s(x) \geq t]$.
5. **Barrido de umbral (clave):** evalúa varios t y arma una tabla en val con: t, exactitud, precisión, recall.
6. **Curva PR básica:** con el barrido, grafica puntos (recall, precisión) y elige t según una meta (p. ej. recall mínimo).
7. **Mini-fuga:** estandariza “con todo” vs “solo train” y compara cómo cambian métricas/curva; explica en 2–3 líneas por qué eso es fuga.

Output esperado: tabla de umbrales + gráfica PR + comentario corto (elección de t y nota sobre fuga).

Pausa

Pausa breve

Al volver: **Pipeline + cross-validation + PR-AUC**

Semana 1 — mapa del temario (progreso)

1. Arranque y framing
2. Teoría: workflow de ML
3. Lab NumPy: baseline + split + métricas
4. Lab sklearn: Pipeline + CV + PR-AUC
5. Cierre y entregable

Lab sklearn — objetivo

Objetivo del lab: implementar un pipeline reproducible en `sklearn` que:

- encapsule el preprocesamiento (evitar fuga),
- evalúe de forma estable (validación cruzada),
- y reporte métricas adecuadas (accuracy y AP / PR-AUC).

Al final debes poder:

- construir `Pipeline(StandardScaler, LogisticRegression)`
- evaluar con `cross_val_score` usando:
  - `scoring=.ªccuracy"`
  - `scoring=.ªverage_precision"` (AP / PR-AUC)
- entrenar en train y auditar en test con:
  - `precision_recall_curve`
  - `average_precision_score`

Regla práctica: decisiones con validación/CV; test solo auditoría final.
Archivo: `labs/week01_sklearn_pipeline_cv.ipynb`

¿Qué es cross-validation (CV) y para qué sirve?

- **Definición:** dividir $\mathcal{D}_{\text{trainval}}$ en K pliegues; repetir K veces: entrenar en $K-1$ y validar en 1; promediar la métrica.
- **Pasos (en práctica):**
  - partir $\mathcal{D}_{\text{trainval}}$ en folds $F_1, \ldots, F_K$
  - para $k = 1, \ldots, K$: `fit` en $\mathcal{D}_{\text{trainval}} \setminus F_k$, evaluar en F_k
  - promediar (y reportar variabilidad) de la métrica
  - si hay hiperparámetros (λ, C): elegir el que maximiza el promedio en CV
- **Sirve para:** estimar desempeño con menor varianza y **seleccionar** modelo/hiperparámetros (p. ej. λ, C).
- **No reemplaza al test:** el test se guarda para **auditar una sola vez** al final.
- **Cuidado con fuga:** el `Pipeline` asegura que cada pliegue haga `fit` del preprocesamiento solo con su train.

Regla práctica

Decisiones con CV; test solo auditoría final.

¿Por qué cross-validation ayuda? (intuición)

- Con pocos datos, un solo split (train/val) puede dar una métrica **muy variable**.
- K-fold CV promedia el rendimiento sobre K particiones $\Rightarrow$ estimación más **estable**.
- Para selección de modelo/hiperparámetros: elegir el que maximiza la métrica promedio en CV.
- El **test** queda fuera: sirve para auditar el sistema final (sin volver a ajustar).

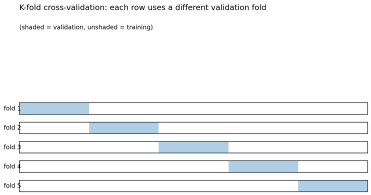

Discusión guiada (al final del lab)

Preguntas

- ¿Cuándo usarías accuracy y cuándo AP/PR-AUC?
- Si hay desbalance, ¿qué te dice AP que no te dice accuracy?
- ¿Qué evita Pipeline que es fácil "romper" si haces preprocessing a mano?

Semana 1 — mapa del temario (progreso)

1. Arranque y framing
2. Teoría: workflow de ML
3. Lab NumPy: baseline + split + métricas
4. Lab sklearn: Pipeline + CV + PR-AUC
5. Cierre y entregable

Checklist final (lo que debe quedar bien hoy)

1. Split correcto (sin contaminar test)
2. Baseline reportado (y comparado)
3. Métrica correcta (accuracy + PR/AP)
4. Evitar leakage (Pipeline / fit solo en train)
5. Reproducibilidad (semilla + requirements + README)

Entregable: repo + notebook plantilla

- Estructura mínima:
  - `slides/week01_intro_workflow.tex`
  - `slides/figs/*.png` (figuras generadas)
  - `labs/week01_numpy_baseline.ipynb`
  - `labs/week01_sklearn_pipeline_cv.ipynb`
  - `README.md` + `requirements.txt` (o `environment.yml`)
- Evidencia mínima:
  - tabla baseline vs logistic (Accuracy + AP)
  - PR curve (imagen) + interpretación (5–6 líneas)

Cierre: 3 ideas para llevarte

1. **Generalización** es el objetivo; train perfecto no impresiona.
2. **Leakage** es el enemigo silencioso; **Pipeline** es tu escudo.
3. **Baselines + métricas correctas** te mantienen honesto.

Semana 2 — Probabilidad (modelos univariados) + Bayes

Bayes, Bernoulli/Binomial, Beta, conjugación y Beta–Binomial (posterior + predictiva)

Curso de Machine Learning — UAQ (Matemáticas Aplicadas)

Libro base: *Probabilistic Machine Learning: An Introduction* (Kevin P. Murphy)

Semana 2

Lecturas sugeridas (para estos temas)

- **Capítulo 2 — Probability: Univariate Models**
  - **2.3** Bayes' rule
  - **2.4** Bernoulli and binomial distributions
  - **2.7.4** Beta distribution
- **Capítulo 4 — Statistics**
  - **4.6.1** Conjugate priors
  - **4.6.2** The beta-binomial model
  - **4.6.2.4** Posterior
  - **4.6.2.9** Posterior predictive
  - **4.6.2.10** Marginal likelihood

Temario de la Semana 2 (qué cubrimos hoy)

- **Teoría (PML)**
  - **Teorema de Bayes** y **piezas** (*prior*, *likelihood*, *posterior*, *evidencia*) **(2.3)**
  - **Modelos Bernoulli y Binomial** **(2.4)**
  - **Distribución Beta** (prior sobre probabilidades) **(2.7.4)**
  - **Conjugación** (por qué Beta es conjugada) **(4.6.1)**
  - **Modelo Beta–Binomial**: posterior y posterior predictiva **(4.6.2)**
- **Lab NumPy**
  - **Beta–Bernoulli**: posterior (actualización por conteos)
  - **Posterior predictiva**: 1 ensayo y M ensayos (simulación)
- **Lab sklearn**
  - **Umbral** (τ) y reglas de decisión
  - **Métricas**: Accuracy vs Precision/Recall vs Average Precision
- **Entregable**

¿Por qué es relevante el enfoque Bayesiano?

- **Objetivo:** inferir $\theta = \Pr(y = 1)$ (una **probabilidad**) a partir de datos D.
- **Incertidumbre explícita:** obtenemos una distribución $p(\theta \mid D)$, no solo un punto.
- **Actualización coherente:** prior + datos $\Rightarrow$ posterior.
- **Predicción robusta:** la **posterior predictiva** integra incertidumbre $\Rightarrow$ menos sobreconfianza con pocos datos.
- **Regularización interpretable:** priors como **pseudoconteos** (suavizado).
- **Comparación de modelos/priors:** evidencia $p(D) =$ **probabilidad marginal de los datos**.

Enfoque frecuentista (ejemplo: tasa de compra)

- Datos: $n = 20$, $k = 3 \Rightarrow \hat{\theta} = 0{,}15$.
- Estimación: $\hat{\theta} = k/n$ (MLE).
- IC 95 % (aprox. normal):

$$\hat{\theta} \pm 1{,}96\sqrt{\frac{\hat{\theta}(1-\hat{\theta})}{n}} = 0{,}15 \pm 0{,}156 \Rightarrow [-0{,}006,\ 0{,}306]$$

- Intervalo válido en $[0, 1]$: $[0,\ 0{,}306]$.
- Interpretación: 95 % de los ICs (en repeticiones) contienen a θ.

Enfoque Bayesiano (mismo ejemplo)

- Prior: $\theta \sim \mathrm{Beta}(2, 8)$ (creencia previa $\approx 0{,}20$).
- Posterior: $\theta \mid D \sim \mathrm{Beta}(5, 25)$.
- Media posterior: $\mathbb{E}[\theta \mid D] = \dfrac{5}{30} \approx 0{,}167$.
- Intervalo creíble 95 %: percentiles de $\mathrm{Beta}(5, 25)$.
- Interpretación: $P(\theta \in \mathrm{ICr} \mid D) = 0{,}95$.

Semana 2 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Motivación: inferir una probabilidad con pocos datos

- Problema base: estimar $\theta = \Pr(y = 1)$ a partir de pocos ensayos Bernoulli.
- Bayes da **distribución** sobre θ, no solo un número.
- Ventaja: incorpora información previa y cuantifica incertidumbre.
- Caso canónico: Bernoulli/Binomial + Beta $\Rightarrow$ actualizaciones cerradas.

Definiciones (2.3): piezas de Bayes

- **Prior:** $p(\theta)$.
- **Likelihood:** $p(D \mid \theta)$.
- **Posterior:** $p(\theta \mid D) = \dfrac{p(D \mid \theta)\, p(\theta)}{p(D)}$.
- **Evidencia:** $p(D) = \int p(D \mid \theta)\, p(\theta)\, d\theta$ (*marginal likelihood*).

Derivación 1 (2.4): likelihood Bernoulli/Binomial

- Datos iid $y_i \in \{0, 1\}$, con $k = \sum_{i=1}^{n} y_i$.
- Bernoulli: $p(y_i \mid \theta) = \theta^{y_i}(1-\theta)^{1-y_i}$.
- Likelihood agregada:

$$p(D \mid \theta) = \prod_{i=1}^{n} \theta^{y_i}(1-\theta)^{1-y_i} = \theta^k(1-\theta)^{n-k}.$$

- Binomial: $p(k \mid n, \theta) = \binom{n}{k}\theta^k(1-\theta)^{n-k}$.

Distribución Beta (2.7.4): prior sobre probabilidades

- Soporte: $\theta \in (0, 1)$ (ideal para probabilidades).
- Densidad:

$$\theta \sim \mathrm{Beta}(\alpha, \beta), \qquad p(\theta) = \frac{1}{B(\alpha, \beta)} \theta^{\alpha-1} (1-\theta)^{\beta-1}.$$

- Lectura: α, β controlan **sesgo** (media) y **fuerza** (concentración).
- Interpretación útil: α, β se comportan como **pseudoconteos** de éxitos/fracasos.

Priors Beta: ¿qué "forma" de creencia estás poniendo?

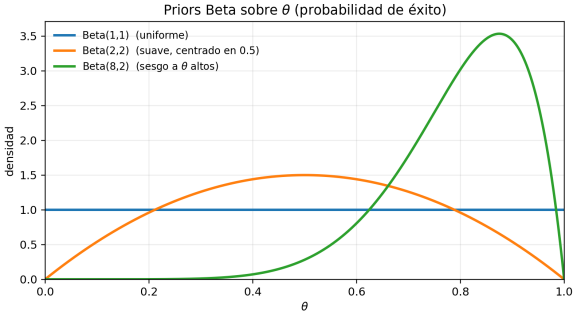

- $\mathrm{Beta}(1,1)$: uniforme.
- $\mathrm{Beta}(2,2)$: suave, centrada en 0,5.
- $\mathrm{Beta}(8,2)$: empuja hacia θ altos.
- **Idea:** el prior dice qué valores de θ son "plausibles" antes de ver datos.

Derivación 2 (4.6.1): conjugación Beta con Bernoulli/Binomial

- Usamos: $p(\theta \mid D) \propto p(D \mid \theta)\, p(\theta)$.
- Como $p(D \mid \theta) \propto \theta^k (1-\theta)^{n-k}$ y $p(\theta) \propto \theta^{\alpha-1}(1-\theta)^{\beta-1}$, el posterior queda:

$$p(\theta \mid D) \propto \theta^{k+\alpha-1}(1-\theta)^{n-k+\beta-1}.$$

- Conjugación (misma familia):

$$\theta \mid D \sim \mathrm{Beta}(\alpha + k,\ \beta + n - k).$$

- Lectura rápida: k suma a "éxitos" y $n-k$ suma a "fracasos".

¿Qué es la **posterior predictiva**?

- **Definición:** distribución de **datos futuros** dado lo observado:

$$p(D_{\text{new}} \mid D) = \int p(D_{\text{new}} \mid \theta)\, p(\theta \mid D)\, d\theta.$$

- **Idea:** en vez de fijar θ a un punto (plug-in), **promediamos** sobre la incertidumbre en θ.
- En Bernoulli/Binomial:
  - 1 paso: $p(y_{\text{new}} = 1 \mid D) = \mathbb{E}[\theta \mid D]$.
  - M pasos: $S = \sum_{j=1}^{M} y_j \mid D$ tiene una distribución (Beta–Binomial) más "ancha" que plug-in.

Predictiva *plug-in* vs predictiva Bayesiana (en una línea)

- **Plug-in:** primero estimas $\hat{\theta}$ (p.ej. MLE/MAP/media posterior) y luego predices como si fuera cierto:

$$p_{\text{plug-in}}(D_{\text{new}} \mid D) = p(D_{\text{new}} \mid \hat{\theta}).$$

- **Bayes:** no fijas θ; promedias con el posterior:

$$p(D_{\text{new}} \mid D) = \int p(D_{\text{new}} \mid \theta)\, p(\theta \mid D)\, d\theta.$$

- **Mensaje:** plug-in suele ser más "optimista"; Bayes tiende a ser menos sobreconfiante con pocos datos.

Modelo Beta–Binomial (4.6.2): posterior y predictiva

- Predictiva 1 paso:

$$p(y_{\text{nuevo}} = 1 \mid D) = \mathbb{E}[\theta \mid D] = \frac{\alpha + k}{\alpha + \beta + n}.$$

- Predictiva de conteos (m futuros):

$$p(k_{\text{new}} \mid m, D) = \binom{m}{k_{\text{new}}} \frac{B(\alpha + k + k_{\text{new}}, \beta + n - k + m - k_{\text{new}})}{B(\alpha + k, \beta + n - k)}.$$

Ejemplo numérico mínimo

- Prior uniforme: $\theta \sim \mathrm{Beta}(1, 1)$.
- Datos: $n = 4$ lanzamientos, $k = 3$ éxitos.
- Posterior: $\theta \mid D \sim \mathrm{Beta}(4, 2)$.
- Predictiva: $p(y_{\text{nuevo}} = 1 \mid D) = \dfrac{4}{6} = \dfrac{2}{3}$.

Derivación (4.6.2.10): evidencia Beta–Binomial $p(k \mid n, \alpha, \beta)$

- Definición (marginalizar θ):

$$p(k \mid n, \alpha, \beta) = \int_0^1 p(k \mid n, \theta)\, p(\theta \mid \alpha, \beta)\, d\theta.$$

- Sustituimos Binomial y Beta:

$$p(k \mid n, \theta) = \binom{n}{k} \theta^k (1-\theta)^{n-k}, \quad p(\theta) = \frac{1}{B(\alpha, \beta)} \theta^{\alpha-1} (1-\theta)^{\beta-1}.$$

- Agrupando potencias:

$$p(k \mid n, \alpha, \beta) = \binom{n}{k} \frac{1}{B(\alpha, \beta)} \int_0^1 \theta^{\alpha+k-1} (1-\theta)^{\beta+n-k-1}\, d\theta.$$

- Reconocemos la integral como $B(\alpha + k, \beta + n - k) \Rightarrow$

$$p(k \mid n, \alpha, \beta) = \binom{n}{k} \frac{B(\alpha + k, \beta + n - k)}{B(\alpha, \beta)}.$$

Evidencia $p(D)$: intuición y comparación de modelos

- **Qué es:** $p(D)$ es la **probabilidad marginal** del dataset (también *marginal likelihood*).
- **Rol en Bayes:** es el **normalizador** (no depende de θ).
- **Intuición:** promedia el likelihood sobre θ "plausibles" según el prior.
- **Comparación:** para dos modelos/priors M_1, M_2,

$$\text{Bayes factor} = \frac{p(D \mid M_1)}{p(D \mid M_2)}.$$

- **Lectura:** favorece modelos que explican bien los datos **sin** "apostar" probabilidad en demasiados θ.

Evidencia: misma data, distinto prior $\Rightarrow$ distinto $p(D)$

- Datos (Binomial): $n = 10$, $k = 7$ éxitos.
- Con prior $\theta \sim \mathrm{Beta}(\alpha, \beta)$:

$$p(k \mid n, \alpha, \beta) = \binom{n}{k} \frac{B(\alpha + k, \beta + n - k)}{B(\alpha, \beta)}.$$

- Evidencias (aprox.):
  - $\mathrm{Beta}(1, 1)$: $p(k \mid n) \approx 0{,}0909$
  - $\mathrm{Beta}(2, 2)$: $p(k \mid n) \approx 0{,}1119$
  - $\mathrm{Beta}(8, 2)$: $p(k \mid n) \approx 0{,}1486$
- **Interpretación (en simple):** estos números dicen qué tan "esperable" era ver $7/10$ *antes* de ver los datos, según cada prior.
- **Lo que importa: comparaciones.** Por ejemplo:

$$\frac{p(D \mid \mathrm{Beta}(8, 2))}{p(D \mid \mathrm{Beta}(1, 1))} \approx 1{,}63, \qquad \frac{p(D \mid \mathrm{Beta}(2, 2))}{p(D \mid \mathrm{Beta}(1, 1))} \approx 1{,}23.$$

Resumen y takeaways

- Bayes (2.3) combina prior y likelihood para obtener $p(\theta \mid D)$.
- Bernoulli/Binomial (2.4) $\Rightarrow$ likelihood $\theta^k(1-\theta)^{n-k}$.
- Beta (2.7.4) $\Rightarrow$ prior natural sobre probabilidades.
- Conjugación (4.6.1): $\mathrm{Beta}(\alpha, \beta) \to \mathrm{Beta}(\alpha + k, \beta + n - k)$.
- Predictiva (4.6.2): promedia sobre $\theta \Rightarrow$ menos sobreconfianza.
- Evidencia (4.6.2.10): $p(D)$ sirve para **comparar** priors/modelos (Bayes factor).

Semana 2 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab NumPy — objetivos (qué debes lograr)

- **Inferencia:** a partir de $y \in \{0,1\}^n$, calcular N_1, N_0 y actualizar $(\alpha, \beta) \to (\alpha', \beta')$.
- **Predicción:** calcular $p(y_{\text{new}} = 1 \mid D)$ y aproximar $p(S \mid D)$ para M futuros.
- **Comparación:** contrastar predictiva *plug-in* vs *Bayesiana* y explicar el efecto del prior (sesgo y fuerza) en 2–3 frases.

Lab NumPy — definiciones mínimas (puente con Teoría)

- **Parámetro:** $\theta = \Pr(y = 1)$.
- **Datos:** $D = \{y_i\}_{i=1}^{n}$, con conteos $N_1 = \sum_i y_i$, $N_0 = n - N_1$.
- **Prior:** $\theta \sim \mathrm{Beta}(\alpha, \beta)$.
- **Posterior (conjugación):** $\theta \mid D \sim \mathrm{Beta}(\alpha', \beta')$, donde $\alpha' = \alpha + N_1$, $\beta' = \beta + N_0$.
- **Posterior predictiva:** $p(D_{\text{new}} \mid D) = \int p(D_{\text{new}} \mid \theta) p(\theta \mid D) d\theta$.
- **Plug-in vs Bayes:** plug-in fija $\theta = \hat{\theta}$; Bayes integra sobre θ.

Lab NumPy — Pregunta 1: ¿Qué datos tengo y qué resumen necesito?

```
ENTRADA: y[1..n]  (valores 0/1)

N1 <- suma(y)
N0 <- n - N1

SALIDA: N1, N0
CHEQUEO: N1 + N0 = n
```

- Definición: N_1 = número de éxitos, N_0 = número de fracasos.

Lab NumPy — Pregunta 2: ¿Qué creía antes de ver datos? (prior)

```
ELIGE el prior (alpha > 0, beta > 0)

EJEMPLOS:
  alpha = 1, beta = 1   (uniforme)
  alpha = 2, beta = 2   (suave, centrado en 0.5)
  alpha = 8, beta = 2   (sesgo hacia theta altos)
```

- Tip: $\alpha + \beta$ controla la "fuerza" del prior.
- Pitfall: prior fuerte sin justificar.

Lab NumPy — Pregunta 3: ¿Qué creo después de ver datos? (posterior)

```
ACTUALIZA (conjugacion Beta--Bernoulli):
alpha_post <- alpha + N1
beta_post  <- beta  + N0

SALIDA: alpha_post, beta_post
CHEQUEO: alpha_post > 0 y beta_post > 0
```

- Definición: $\alpha' = \alpha + N_1$, $\beta' = \beta + N_0$.

Lab NumPy — Pregunta 4: ¿Qué predigo del siguiente ensayo? (predictiva 1 paso)

```
PREDICTIVA POSTERIOR (1 ensayo):
p1_bayes <- alpha_post / (alpha_post + beta_post)
p0_bayes <- 1 - p1_bayes

SALIDA: p(y_nuevo = 1 | D) = p1_bayes
```

- Definición: $p(y_{\text{new}} = 1 \mid D) = \mathbb{E}[\theta \mid D] = \dfrac{\alpha'}{\alpha' + \beta'}$.

Lab NumPy — Pregunta 5: ¿Qué predigo de M ensayos futuros? (predictiva de conteos)

```
FIJA M (ensayos futuros) y R (numero de simulaciones)

PARA r = 1..R:
  muestrea theta_r ~ Beta(alpha_post, beta_post)
  muestrea S_r ~ Binomial(M, theta_r)

ESTIMA p(S | D) con {S_r} (histograma / frecuencias)
CHEQUEO: suma_s p_hat(S=s | D) ~= 1
```

- Definición: $S = \sum_{j=1}^{M} y_j =$ número de éxitos futuros en M ensayos.
- Lógica Bayesiana: muestrear $\theta \sim \mathrm{Beta}(\alpha', \beta')$ y luego $S \sim \mathrm{Binomial}(M, \theta)$.

Lab NumPy — Pregunta 6: Predictiva plug-in vs Bayesiana

Objetivo: Comparar dos formas de predecir S = número de éxitos en M ensayos futuros.

	S_bayes	**S_plugin**
Qué es	Muestras de $p(S \mid D)$	Muestras de $\mathrm{Bin}(M, \hat{\theta})$
Cómo se obtiene	$\theta \sim \mathrm{Beta}(\alpha', \beta')$, luego $S \sim \mathrm{Bin}(M, \theta)$	$S \sim \mathrm{Bin}(M, \theta_{\mathrm{MAP}})$ con θ fijo
Incertidumbre sobre θ	Sí (integra sobre la posterior)	No (usa un solo $\hat{\theta}$)

Pasos:

1. **Estimador puntual:** θ_{MAP}. Si $\alpha' > 1$ y $\beta' > 1$: $\dfrac{\alpha' - 1}{\alpha' + \beta' - 2}$; si no: $\dfrac{\alpha'}{\alpha' + \beta'}$.
2. **S_plugin:** para $r = 1, \ldots, R$, muestrea $S_r \sim \mathrm{Binomial}(M, \theta_{\mathrm{MAP}})$.
3. **S_bayes:** para $r = 1, \ldots, R$, muestrea $\theta_r \sim \mathrm{Beta}(\alpha', \beta')$, luego $S_r \sim \mathrm{Binomial}(M, \theta_r)$.
4. **Comparar:** media, varianza y una probabilidad de cola (ej. $P(S \leq k)$ o $P(S \geq k)$) de S_plugin vs S_bayes. Opcional: histogramas superpuestos.

Interpretación: S_bayes suele tener más varianza y colas más pesadas; el plug-in suele subestimar la

Lab NumPy — entregables (checklist)

Tu notebook debe incluir (evaluable):

- **Resultados:** (α, β), (α', β'), N_1, N_0, y $p(y_{\text{new}} = 1 \mid D)$.
- **Predictiva:** aproximación de $p(S \mid D)$ para algún M (elige M y R y repórtalos).
- **Comparación:** Bayes vs plug-in (una figura o, mínimo, media/varianza y una probabilidad de cola).
- **Discusión (2–3 frases):** qué cambia al variar $\alpha + \beta$ (fuerza) y la media del prior (sesgo).
- **Reproducible:** semilla fija y celdas sin salidas gigantes.

Semana 2 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab sklearn — objetivo

En un problema binario:

- entrenar un modelo que produzca $\hat{p}$
- barrer umbrales τ y ver trade-offs
- comparar accuracy vs precision/recall vs average precision

Lab sklearn — Paso 1: modelo con probabilidades

```
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression

# X, y: tus datos (numpy arrays)
Xtr, Xte, ytr, yte = train_test_split(X, y, test_size=0.3, random_state=0)

clf = LogisticRegression(max_iter=1000)
clf.fit(Xtr, ytr)

p_hat = clf.predict_proba(Xte)[:, 1]  # scores en [0,1]
```

Lab sklearn — Paso 2: umbral y conteos TP/FP/TN/FN

```
def yhat_from_tau(p, tau):
    return (p >= tau).astype(int)

tau = 0.5
yhat = yhat_from_tau(p_hat, tau)

TP = int(((yhat==1) & (yte==1)).sum())
FP = int(((yhat==1) & (yte==0)).sum())
TN = int(((yhat==0) & (yte==0)).sum())
FN = int(((yhat==0) & (yte==1)).sum())
print(TP, FP, TN, FN)
```

Lab sklearn — Paso 3: métricas por umbral

```
from sklearn.metrics import accuracy_score, precision_score, recall_score

taus = np.linspace(0.0, 1.0, 101)
rows = []
for tau in taus:
    yhat = (p_hat >= tau).astype(int)
    acc = accuracy_score(yte, yhat)
    prec = precision_score(yte, yhat, zero_division=0)
    rec  = recall_score(yte, yhat, zero_division=0)
    rows.append([tau, acc, prec, rec])

rows = np.array(rows)
best_tau_acc = rows[rows[:,1].argmax(), 0]
print("best tau (accuracy):", best_tau_acc)
```

- Pitfall: escoger τ usando el test (se elige con validación).

Lab sklearn — Paso 4: Average Precision (AP) y curva PR

```
from sklearn.metrics import average_precision_score, precision_recall_curve

ap = average_precision_score(yte, p_hat)
prec, rec, thr = precision_recall_curve(yte, p_hat)

print("Average Precision =", ap)
# (Opcional) graficar: rec (x) vs prec (y)
```

Lab sklearn — preguntas guía

- ¿Qué pasa con precision y recall cuando subes τ?
- ¿Por qué accuracy puede ser engañosa con desbalance?
- ¿Qué te dice AP que no te dice un umbral fijo?

Semana 2 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Entregable (Semana 2)

Subir al repo:

- **Notebook 1 (NumPy):** Beta–Bernoulli posterior + posterior predictiva (1 y M).
- **Notebook 2 (sklearn):** umbrales + tabla de métricas + AP (y opcional curva PR).
- **README corto:** cómo correr, qué aprendiste (5–8 líneas) y una figura/tabla destacada.

Checklist de entrega (formato)

- Carpeta: `week02/`
- Nombres: `week02_beta_bernoulli.ipynb`, `week02_thresholding_metrics.ipynb`
- Celdas limpias (sin outputs gigantes) y semilla fija donde aplique.
- Commits pequeños con mensajes claros.
- Reproducible: `requirements.txt` o `environment.yml` (si ya lo estamos usando).

Cierre

- Bayes = prior $\times$ likelihood $\rightarrow$ posterior (actualización).
- Conjugación = actualizaciones simples (conteos $\rightarrow$ parámetros).
- Predicción Bayesiana integra incertidumbre $\Rightarrow$ menos sobreconfianza.
- En clasificación: el score no es la decisión; la decisión depende del umbral y del objetivo.

Semana 3 — Probabilidad (modelos multivariados)

De describir dependencia a inferir faltantes: $\Sigma/R \to$ MVN $\to$ Mahalanobis $\to$ condicionamiento $\to$ imputación (Iris) $\to$ GMM

Curso de Machine Learning — UAQ (Matemáticas Aplicadas)

Libro base: *Probabilistic Machine Learning: An Introduction* (Kevin P. Murphy)

Semana 3

Lecturas sugeridas (para estos temas)

- **Capítulo 3 — Probability: Multivariate Models**
  - **3.1.1** Covarianza
  - **3.1.2** Correlación
  - **3.1.3** No correlación $\not\Rightarrow$ independencia
  - **3.1.4** Correlación $\not\Rightarrow$ causalidad
  - **3.1.5** Paradoja de Simpson
  - **3.2.1** Definición de la MVN
  - **3.2.2** Distancia de Mahalanobis
  - **3.2.3** Marginales y condicionales de una MVN *
  - **3.2.4** Ejemplo: condicionamiento en una Gaussiana 2D
  - **3.2.5** Ejemplo: imputación de valores faltantes *
  - **3.3.1** Regla de Bayes para gaussianas
  - **3.5.1** Modelos de mezcla gaussianos (GMM)

Temario de la Semana 3 (qué cubrimos hoy)

- **Teoría (PML)**
  - **1) Describir dependencia:** $\hat{\Sigma}$ y $\hat{R}$ **(3.1.1–3.1.2)**
  - **2) Interpretar con cuidado:** $\rho = 0 \not\Rightarrow$ independencia; correlación $\not\Rightarrow$ causalidad; Simpson **(3.1.3–3.1.5)**
  - **3) Modelar:** MVN $\mathcal{N}(\mu, \Sigma)$ como baseline **(3.2.1)**
  - **4) Geometría/probabilidad:** Mahalanobis (qué tan "raro" es un punto) **(3.2.2)**
  - **5) Inferir:** marginales/condicionales y condicionamiento por bloques **(3.2.3)**
  - **6) Aplicación:** imputación (Iris) como $\mathbb{E}[X_m \mid X_o]$ **(3.2.5)**
  - **7) Extensión:** GMM para multimodalidad **(3.5.1)**
- **Lab NumPy**
  - **Condicionamiento en una MVN** (bloques + fórmulas)
  - **Imputación:** $\mathbb{E}[x_{\text{miss}} \mid x_{\text{obs}}]$
  - **Evaluación:** MSE en valores ocultados
- **Lab sklearn**
  - **GaussianMixture:** ajustar un GMM en 2D
  - **Leer parámetros:** weights, means, covariances
  - **Visualización:** puntos + elipses por componente
- **Entregable**

Hilo conductor de la semana (Iris)

- Vamos a usar **Iris** como ejemplo mental: 4 variables (sépalo/pétalo).
- **Pregunta 1 (describir):** ¿qué variables se mueven juntas? $\Rightarrow \hat{\Sigma}$, $\hat{R}$.
- **Pregunta 2 (modelar):** si aproximamos con una MVN, ¿cómo se ve la nube? $\Rightarrow$ geometría de Σ.
- **Pregunta 3 (medir rareza):** ¿qué puntos son atípicos bajo ese modelo? $\Rightarrow$ Mahalanobis.
- **Pregunta 4 (inferir faltantes):** si falta una variable, ¿qué valor es más plausible? $\Rightarrow$ condicionamiento $\rightarrow$ imputación.
- **Pregunta 5 (ir más allá):** si hay varias "nubes", ¿cómo lo modelamos? $\Rightarrow$ GMM.

Semana 3 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Punto de partida: vector aleatorio, media y covarianza

- En datos reales (p. ej. Iris), cada fila es un vector $x \in \mathbb{R}^D$ (aquí $D = 4$).
- Modelamos X como vector aleatorio: $X \in \mathbb{R}^D$.
- **Media**: $\mu = \mathbb{E}[X]$ (valor "típico" por variable).
- **Covarianza**: $\Sigma = \mathbb{E}[(X - \mu)(X - \mu)^\top]$ (escala y dependencia lineal).
- **Entrada**: $\Sigma_{ij} = \mathrm{Cov}(X_i, X_j)$ indica si dos variables tienden a subir/bajar juntas.

Construcción en práctica: $\hat{\Sigma}$ y $\hat{R}$ (pasos)

1. **Paso 1 — datos:** Tenemos n observaciones $x_1, \ldots, x_n$ (filas). Puede ser Iris (4 variables) o un ejemplo 3D.
2. **Paso 2 — covarianza muestral:** Estimamos $\hat{\Sigma}_{ij}$ como el promedio centrado de productos de desviaciones:
$$\hat{\Sigma}_{ij} = \frac{1}{n-1} \sum_{k=1}^{n} (x_{ki} - \bar{x}_i)(x_{kj} - \bar{x}_j), \quad \bar{x}_i = \frac{1}{n} \sum_{k=1}^{n} x_{ki}.$$
Diagonal = varianza muestral; fuera de diagonal = covarianza (nota: *unidades mezcladas*).
3. **Paso 3 — correlación:** Estandarizamos a escala $[-1, 1]$:
$$\hat{R}_{ij} = \frac{\hat{\Sigma}_{ij}}{\sqrt{\hat{\Sigma}_{ii}\hat{\Sigma}_{jj}}}.$$
4. **Lectura rápida:** usa $\hat{R}$ para comparar dependencias; usa $\hat{\Sigma}$ para cálculos (geometría y condicionamiento).

$\hat{\Sigma}$ vs $\hat{R}$: mismo dato, dos "lentes"

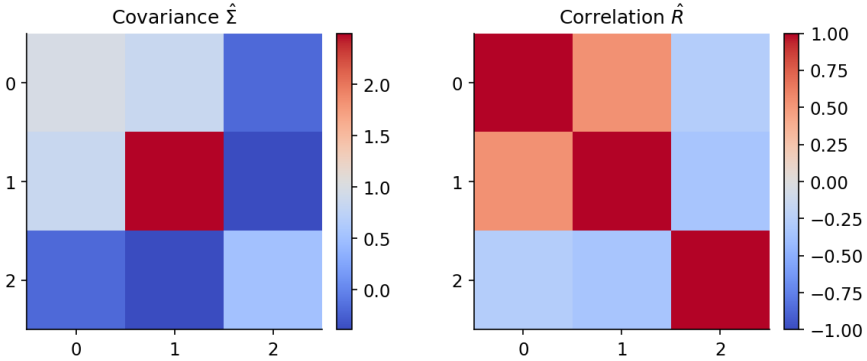

Idea: la izquierda conserva escala (varianzas grandes dominan); la derecha estandariza y hace comparables las relaciones lineales.

Izquierda: $\hat{\Sigma}$. Derecha: $\hat{R}$.

Alerta 1: $\rho = 0$ no implica independencia

- **Mensaje**: correlación mide *dependencia lineal*. Puede haber relación no lineal con $\rho \approx 0$.
- **Hecho**: $\mathrm{Cov}(X, Y) = 0 \not\Rightarrow X \perp Y$ (salvo casos especiales como gaussianas).
- **Traducción práctica**: "no hay correlación" $\neq$ "no hay relación".

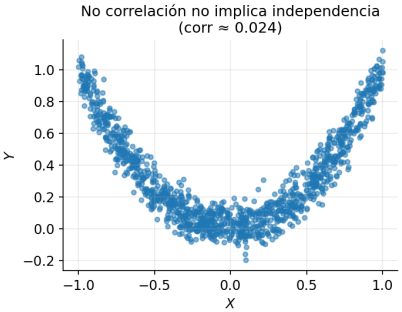

Alerta 2: correlación no implica causalidad

- Una correlación puede venir de **confusores**, **sesgo de selección** o **causalidad invertida**.
- **Pregunta guía**: ¿qué variable podría estar afectando a ambas? ¿qué estoy dejando fuera?

Paradoja de Simpson: cuando el agregado engaña

- **Definición**: una tendencia en datos **agregados** cambia (o se invierte) al **estratificar** por una tercera variable.
- **Ejemplo (Berkeley, 1973)**: al controlar por departamento, la interpretación cambia.
  - **Agregado**: parece haber sesgo.
  - **Estratificado**: aparece el rol del confusor (departamento).

Paradoja de Simpson: visualización y “checklist mental”

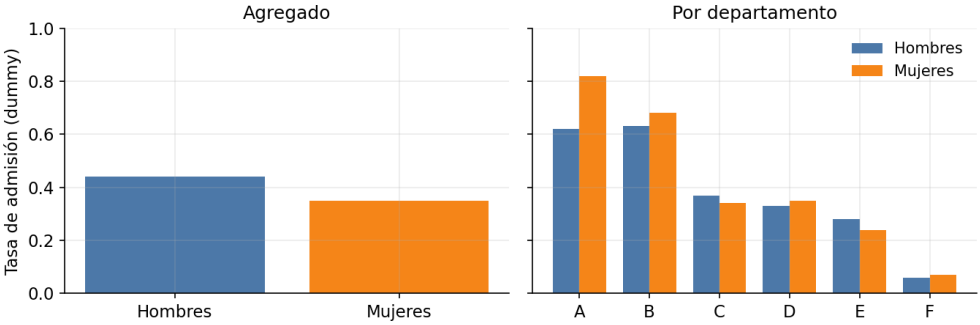

- **Checklist**: antes de concluir, pregunta “¿qué variable podría estar mezclando grupos?”.
- Ejemplos de estratos: departamento, cohorte, nivel educativo, hospital/escuela, etc.

MVN: un baseline probabilístico para vectores

- Idea: aproximar una nube de datos con una sola *elipse* (2D) / *elipsoide* (D).
- Notación: $X \sim \mathcal{N}(\mu, \Sigma)$.
- μ: centro; Σ: escala + orientación (forma).
- Esto nos da dos cosas: **geometría** (elipses) y **cálculo cerrado** (condicionales).

Geometría de Σ: cómo "lee" la MVN la nube de datos

- En una MVN, las curvas de igual densidad son *elipses*/*elipsoides*.
- **Autovectores**: direcciones principales (ejes) de la nube.
- **Autovalores**: dispersión en cada dirección (eje $\propto \sqrt{\lambda}$).
- **Lectura práctica**: Σ codifica *escala* y *correlación* en una sola matriz.

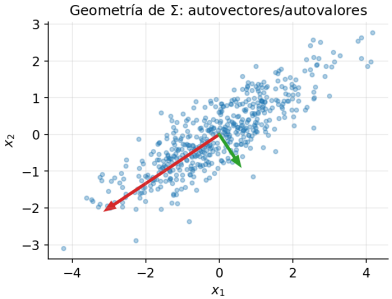

Distancia de Mahalanobis: qué es y para qué sirve

- **Definición:**

$$d_M(x, \mu) = \sqrt{(x-\mu)^\top \Sigma^{-1} (x-\mu)}.$$

- **Intuición:** mide "lejanía" en unidades que respetan *escala* y *correlación*.
- **Sirve para:**
  - detectar *atípicos* bajo una MVN (outliers),
  - entender el *log-likelihood* gaussiano (el término cuadrático),
  - conectar con GMM: cada componente usa su Σ_k para medir cercanía.
- **Puente:** la geometría que define d_M es la misma que usamos al **condicionar** (siguiente bloque).

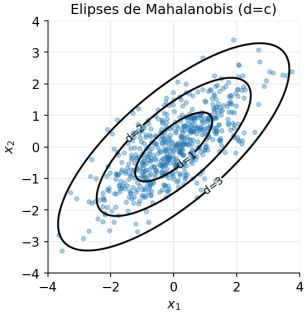

De “medir rareza” a “inferir faltantes”

- Con μ y Σ ya podemos:
  - evaluar qué tan plausible es un punto (vía d_M),
  - y también **inferir** partes faltantes de un vector.
- La herramienta clave es que en la MVN, **marginales** y **condicionales** siguen siendo gaussianas.

Marginales y condicionales en una MVN (la pieza que habilita todo)

- **Marginal**: si te quedas con algunas coordenadas, sigues en el mundo gaussiano.
- **Condicional**: si conoces parte del vector, la distribución del resto también es gaussiana.
- **Consecuencia**: podemos calcular $\mathbb{E}[X_{\text{faltante}} \mid X_{\text{observado}}]$ en forma cerrada $\Rightarrow$ imputación.

Condicionamiento por bloques: la receta (MVN)

- **Notación**: a = variables *observadas*; b = variables *faltantes* (o las que queremos predecir).
- Partición:

$$x = \begin{pmatrix} x_a \\ x_b \end{pmatrix}, \quad \mu = \begin{pmatrix} \mu_a \\ \mu_b \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{pmatrix}.$$

- Resultado: $X_b \mid X_a = a \sim \mathcal{N}(\mu_{b|a}, \Sigma_{b|a})$.
- Fórmulas:

$$\mu_{b|a} = \mu_b + \Sigma_{ba}\Sigma_{aa}^{-1}(a - \mu_a), \qquad \Sigma_{b|a} = \Sigma_{bb} - \Sigma_{ba}\Sigma_{aa}^{-1}\Sigma_{ab}.$$

- Nota: $\Sigma_{b|a}$ no depende de a. Para imputación "simple", usamos la media $\mu_{b|a}$.

Condicionamiento por bloques: ejemplo numérico (D=5)

Ejemplo: observamos 3 variables (a) y faltan 2 (b). Así "se ven" μ y Σ.

- Vector de medias: $\mu = \begin{pmatrix} 2{,}1 \\ 1{,}8 \\ 3{,}0 \\ 4{,}2 \\ 5{,}5 \end{pmatrix}$ (shape $(5,)$).
- Matriz de covarianza Σ (shape (5×5)):

$$\Sigma = \begin{pmatrix} 1{,}2 & 0{,}5 & 0{,}3 & 0{,}4 & 0{,}2 \\ 0{,}5 & 0{,}9 & 0{,}2 & 0{,}3 & 0{,}1 \\ 0{,}3 & 0{,}2 & 1{,}5 & 0{,}6 & 0{,}4 \\ 0{,}4 & 0{,}3 & 0{,}6 & 2{,}0 & 0{,}8 \\ 0{,}2 & 0{,}1 & 0{,}4 & 0{,}8 & 1{,}8 \end{pmatrix}$$

- Partición: $a =$ índices $[0, 1, 2]$ (observadas), $b =$ índices $[3, 4]$ (faltantes).

Condicionamiento por bloques: ejemplo numérico (D=5) — subbloques

- **Partir** μ en observado/faltante:

$$\mu_a = \begin{pmatrix} 2{,}1 \\ 1{,}8 \\ 3{,}0 \end{pmatrix} \quad (\text{shape } (3,)), \qquad \mu_b = \begin{pmatrix} 4{,}2 \\ 5{,}5 \end{pmatrix} \quad (\text{shape } (2,)).$$

- **Partir** Σ en 4 bloques (observado-observado, observado-faltante, etc.):

$$\Sigma_{aa} = \begin{pmatrix} 1{,}2 & 0{,}5 & 0{,}3 \\ 0{,}5 & 0{,}9 & 0{,}2 \\ 0{,}3 & 0{,}2 & 1{,}5 \end{pmatrix} \quad (\text{shape } (3 \times 3)),$$

$$\Sigma_{ab} = \begin{pmatrix} 0{,}4 & 0{,}2 \\ 0{,}3 & 0{,}1 \\ 0{,}6 & 0{,}4 \end{pmatrix} \quad (\text{shape } (3 \times 2)), \qquad \Sigma_{ba} = \Sigma_{ab}^\top, \quad \Sigma_{bb} = \begin{pmatrix} 2{,}0 & 0{,}8 \\ 0{,}8 & 1{,}8 \end{pmatrix} \quad (\text{shape } (2 \times 2)).$$

- **Lectura**: Σ_{aa} es lo que invertimos; Σ_{ba} "transporta" información de observado $\rightarrow$ faltante.
- Para imputar: $\mu_{b|a} = \mu_b + \Sigma_{ba}\Sigma_{aa}^{-1}(x_a - \mu_a)$ (shape $(2,)$).

Condicionamiento en 2D: intuición visual (rebanar la elipse)

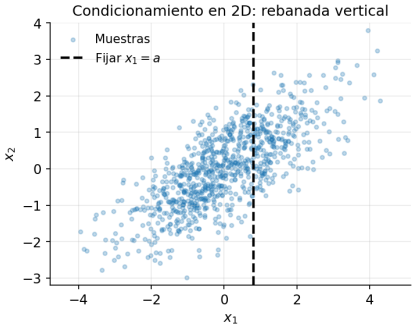

- En 2D: observado $a = x_1$, faltante $b = x_2$.
- Fijar $x_1 = a$ "rebana" la nube: queda una normal 1D para $x_2 \mid x_1 = a$.

Imputación (Iris) = condicionamiento + evaluación honesta

- **Idea**: tratar "faltante" como X_m y lo observado como X_o.
- **Regla**: imputación determinista $x_m \leftarrow \mathbb{E}[X_m \mid X_o = x_o]$ (media condicional).
- **Experimento**: ocultamos ancho del pétalo en 20 % de filas; estimamos (μ, Σ) con las filas observadas; imputamos y comparamos.
- **Gráfica**: cada punto azul = una celda ocultada (verdadero vs imputado). Diagonal $y = x$ = ideal.
- **Métrica**: MSE **solo** donde ocultaste; compara contra baseline (media marginal por columna).

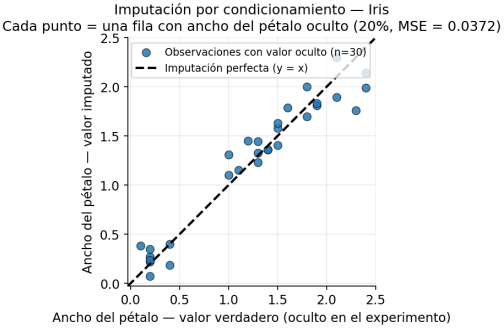

¿Por qué no basta una sola MVN? (puente a mixtures)

- Una MVN = una sola "nube elíptica".
- En Iris, distintas especies sugieren **más de una nube** (multimodalidad).
- Solución: **mezcla** = suma ponderada de varias MVNs.

GMM: varias elipses para explicar una nube compleja

- Modelo:

$$p(x) = \sum_{k=1}^{K} \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k), \qquad \sum_k \pi_k = 1,\ \pi_k \geq 0.$$

- En 2D, cada componente induce una elipse; el modelo suma "nubes".
- Interpretación: π_k (peso), μ_k (centro), Σ_k (forma).
- Conexión: "cercanía" a cada componente se relaciona con Mahalanobis y su log-likelihood.

Cierre: qué te llevas de Week03

- $\hat{\Sigma}$ conserva escala; $\hat{R}$ estandariza para comparar dependencias.
- Interpretación cuidadosa: $\rho = 0 \not\Rightarrow$ independencia; correlación $\not\Rightarrow$ causalidad; cuidado con Simpson.
- MVN + Σ da geometría; Mahalanobis mide "rareza" bajo esa geometría.
- Condicionamiento MVN es cerrado $\Rightarrow$ imputación como $\mathbb{E}[X_m \mid X_o]$.
- Si hay varias nubes, GMM (mezcla de elipses) es una extensión natural.

Semana 3 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab NumPy — objetivo general

- Implementar la **media condicional** de una MVN por bloques (la receta de Teoría).
- Aplicarla a **imputación** (p. ej. Iris: ocultar una columna y recuperarla).
- Evaluar sin engañarse: MSE **solo** en valores ocultados + baseline.
- Reproducibilidad: semilla fija, reporta N y % faltantes.

Lab NumPy — notación y shapes (traducción Teoría → código)

- `mu (D,)`: vector de medias; `mu[i]` = media de la variable i.
- `Sigma (D,D)`: covarianza; `Sigma[i,j]` = $\mathrm{cov}(X_i, X_j)$.
- `idx_a / idx_b`: índices de observado/faltante (en Iris, $D = 4$ y puedes ocultar "petal width").
- `x_a`: valores observados de una fila; es el "a" numérico de esa observación.
- Fórmula por fila (media condicional): $\mu_{b|a} = \mu_b + \Sigma_{ba}\Sigma_{aa}^{-1}(x_a - \mu_a)$.

Lab NumPy — Pseudocódigo 1: partir en bloques

```
# INPUT:
#   mu:    shape (D,)    # vector de medias
#   Sigma: shape (D,D)   # matriz de covarianza
#   idx_a: índices observados
#   idx_b: índices faltantes

mu_a = mu[idx_a]                          # (Da,)
mu_b = mu[idx_b]                          # (Db,)
S_aa = Sigma[np.ix_(idx_a, idx_a)]        # (Da,Da)
S_ab = Sigma[np.ix_(idx_a, idx_b)]        # (Da,Db)
S_ba = Sigma[np.ix_(idx_b, idx_a)]        # (Db,Da)
S_bb = Sigma[np.ix_(idx_b, idx_b)]        # (Db,Db)

# CHEQUEO: S_aa debe ser invertible (si no, regulariza: S_aa += eps*I)
```

Lab NumPy — Pseudocódigo 2: media condicional → imputación

```
# Precompute una vez (fuera del loop por filas):
S_aa_inv = inv(S_aa)   # costoso -> hazlo una sola vez

# Para cada fila i con faltantes en idx_b:
x_a = X[i, idx_a]      # valores observados de la fila (Da,)

# Fórmula MVN:
# mu_{b|a} = mu_b + S_ba @ inv(S_aa) @ (x_a - mu_a)
mu_b_given_a = mu_b + S_ba @ S_aa_inv @ (x_a - mu_a)  # (Db,)

# Imputación determinista (media condicional):
X_imputed[i, idx_b] = mu_b_given_a

# Opcional (imputación estocástica):
# S_{b|a} = S_bb - S_ba @ inv(S_aa) @ S_ab
```

Lab NumPy — Pseudocódigo 3: evaluación correcta (MSE)

```
# 1) Guarda el dato completo
X_true = X.copy()                    # (N,D)

# 2) Genera máscara de celdas a ocultar (True = oculto)
mask = make_mask(...)                # (N,D) boolean

# 3) Oculta y luego imputa
X_missing = X_true.copy()
X_missing[mask] = NaN
X_imputed = impute(X_missing)        # tu función del pseudocódigo 2

# 4) Evalúa solo donde ocultaste (para no "hacer trampa")
mse = mean( (X_true[mask] - X_imputed[mask])**2 )

# Baseline: imputar por media marginal (media de columna)
```

Semana 3 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab sklearn — objetivo general

- Ajustar un **GMM** en 2D (elige K, fija semilla).
- Leer parámetros: pesos, medias y covarianzas $\Rightarrow$ "varias elipses".
- Visualizar: puntos + elipses por componente.
- Interpretar: 2–3 frases (¿qué parte de la nube captura cada componente?).

GMM: cómo interpretar π_k, μ_k, Σ_k

- π_k: proporción de datos que "explica" el componente k.
- μ_k: centro del componente.
- Σ_k: forma/orientación (elipse) del componente.
- **Pregunta guía:** ¿el componente captura estructura real o está "partiendo" artificialmente una sola nube?

GMM en 2D: visualización (puntos + elipses)

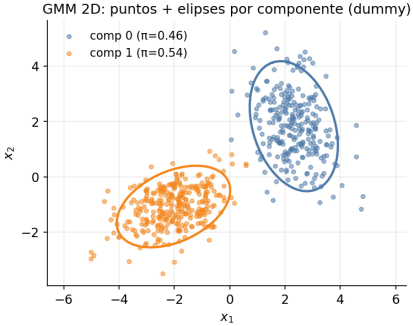

- Elipses = covarianza por componente; colores = componente más probable.
- Lectura: cada elipse es una "nube" gaussiana; el mixto suma varias nubes.

Lab sklearn — Checklist (mínimo indispensable)

```
# INPUT:
#   X: shape (N,2)   # datos 2D

# PASOS:
# 1) ajustar GaussianMixture(K)
# 2) leer weights_, means_, covariances_
# 3) predecir componente / probabilidades
# 4) graficar puntos + elipses

# OUTPUT:
#   figura 2D + breve interpretación
```

Semana 3 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Entregable — qué se evalúa

- **Notebook 1 (NumPy):** condicionamiento por bloques $\rightarrow$ imputación $\rightarrow$ MSE (con baseline).
- **Notebook 2 (sklearn):** GMM 2D $\rightarrow$ parámetros $\rightarrow$ visualización + interpretación breve.
- **Reproducible:** semilla, N, % faltantes (si aplica), y una conclusión corta por notebook.

Semana 4 — Estadística: MLE / ERM

Likelihood $\to$ log-likelihood $\to$ MLE en Bernoulli/Gaussiana $\to$ ERM y pérdidas sustitutas

Curso de Machine Learning — UAQ (Matemáticas Aplicadas)

Libro base: *Probabilistic Machine Learning: An Introduction* (Kevin P. Murphy)

Semana 4

Lecturas sugeridas (para estos temas)

- **Capítulo 4 — Statistics**
  - **4.1** Introduction
  - **4.2** Maximum likelihood estimation (MLE)
    - **4.2.1** Definition
    - **4.2.2** Justification for MLE
    - **4.2.3** Bernoulli
    - **4.2.4** Categorical
    - **4.2.5** Univariate Gaussian
    - **4.2.6** Multivariate Gaussian
    - **4.2.7** Linear regression **(vista previa)**
  - **4.3** Empirical risk minimization (ERM)
    - **4.3.1** Minimizing the misclassification rate
    - **4.3.2** Surrogate loss

Temario de la Semana 4 (qué cubrimos hoy)

- **Teoría (PML)**
  - **1) Lenguaje correcto:** probabilidad vs likelihood **(4.1)**
  - **2) MLE como optimización:** producto $\to$ suma (log) $\to$ NLL **(4.2.1)**
  - **3) Por qué MLE tiene sentido:** "mejor ajuste" dentro del modelo **(4.2.2)**
  - **4) Ejemplos canónicos:** Bernoulli, Categórica, Gaussiana 1D (y MVN) **(4.2.3–4.2.6)**
  - **5) ERM:** riesgo empírico, 0-1 y pérdidas sustitutas **(4.3.1–4.3.2)**
- **Lab NumPy**
  - **Implementar** $\ell(\theta)$, NLL y MLE analítico (Bernoulli + Gaussiana)
  - **Validar** con búsqueda por rejilla (grid) + checks numéricos
- **Lab sklearn**
  - **Equivalencias:** MLE $\leftrightarrow$ minimizar log-loss (intercept-only)
  - **ERM:** ver 0-1 vs log-loss en un barrido de probabilidades
- **Entregable**

Hilo conductor (dos preguntas "universales")

- **Pregunta A (estadística):** dado un modelo $p(x \mid \theta)$ y datos D, ¿qué θ los hace más plausibles? **(4.2)**
- **Pregunta B (ML):** dado un modelo f_θ y una pérdida ℓ, ¿qué θ minimiza el error promedio en train? **(4.3)**
- **Mensaje:** para modelos probabilísticos, MLE $\equiv$ minimizar NLL, que es un caso de ERM con log-loss.

Semana 4 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Probabilidad vs likelihood (no es solo semántica)

- **Probabilidad/densidad:** $p(x \mid \theta)$ como función de x, con θ fijo.
- **Likelihood:** $L(\theta; x) = p(x \mid \theta)$ como función de θ, con x fijo. **(4.1)**
- **Error común:** interpretar $L(\theta)$ como una distribución sobre θ (no tiene por qué sumar/integrar 1).
- Con datos iid: $p(D \mid \theta) = \prod_{i=1}^{n} p(x_i \mid \theta)$.

Definición de MLE: optimización sobre θ

- **Definición:**

$$\hat{\theta}_{\mathrm{MLE}} = \arg\max_{\theta} p(D \mid \theta). \qquad \textbf{(4.2.1)}$$

- Si los datos son iid:

$$p(D \mid \theta) = \prod_{i=1}^{n} p(x_i \mid \theta).$$

- **Intuición:** elegir el θ que hace "grandes" las probabilidades/densidades de los datos observados.

Log-likelihood y NLL: la forma computable

- Producto $\to$ suma:

$$\ell(\theta) = \log p(D \mid \theta) = \sum_{i=1}^{n} \log p(x_i \mid \theta). \qquad \textbf{(4.2.1)}$$

- **NLL (negative log-likelihood):** $\mathrm{NLL}(\theta) = -\ell(\theta)$.
- **Práctico:** evita underflow y es la forma típica de entrenamiento en ML.

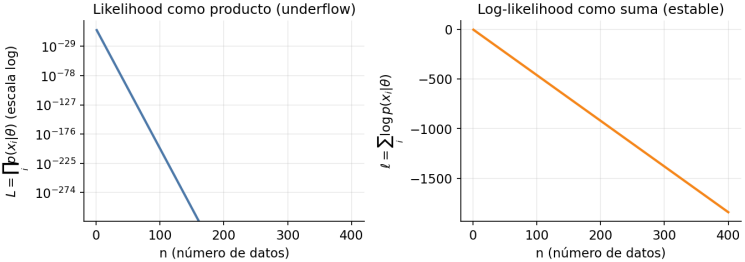

Por qué MLE "tiene sentido" (una lectura útil)

- Maximizar $\ell(\theta)$ equivale a maximizar el promedio $\frac{1}{n}\sum_i \log p(x_i \mid \theta)$. **(4.2.2)**
- **Lectura:** elige el miembro de la familia $p(\cdot \mid \theta)$ que mejor se ajusta a los datos (dentro del modelo).
- **Advertencia:** si el modelo está mal especificado, MLE aun da el "mejor" θ dentro de esa familia, pero no "arregla" el modelo.

Ejemplo MLE 1: Bernoulli (resultado = frecuencia)

- Datos $x_i \in \{0,1\}$, $p(x \mid \pi) = \pi^x (1-\pi)^{1-x}$. **(4.2.3)**
- Log-likelihood (sea $S = \sum_i x_i$):

$$\ell(\pi) = S \log \pi + (n - S) \log(1 - \pi).$$

- **MLE:** $\hat{\pi} = \dfrac{S}{n} = \bar{x}$.

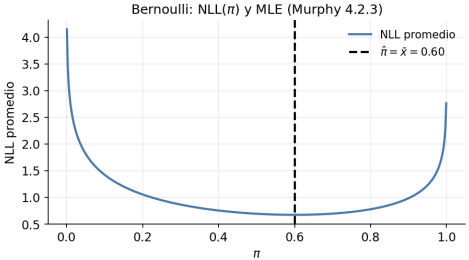

Ejemplo MLE 2: Categórica (resultado = proporciones)

- $x \in \{1, \ldots, K\}$, $p(x = k \mid \boldsymbol{\pi}) = \pi_k$, $\sum_k \pi_k = 1$. **(4.2.4)**
- Con conteos n_k: $\ell(\boldsymbol{\pi}) = \sum_{k=1}^{K} n_k \log \pi_k$.
- **MLE:** $\hat{\pi}_k = \dfrac{n_k}{n}$ (frecuencia por clase).
- **Check:** $\sum_k \hat{\pi}_k = 1$. Si $n_k = 0$, evaluar $\log \pi_k$ requiere cuidado numérico.

Ejemplo MLE 3: Gaussiana 1D (media y varianza MLE)

- $x_i \sim \mathcal{N}(\mu, \sigma^2)$. **(4.2.5)**
- NLL (ignorando constantes):

$$\mathrm{NLL}(\mu, \sigma^2) = \frac{n}{2} \log \sigma^2 + \frac{1}{2\sigma^2} \sum_{i=1}^{n} (x_i - \mu)^2.$$

- **MLE:** $\hat{\mu} = \bar{x}$, $\hat{\sigma}^2 = \frac{1}{n} \sum_i (x_i - \bar{x})^2$.
- Nota: el estimador "insesgado" usa $1/(n-1)$, pero no es el MLE.

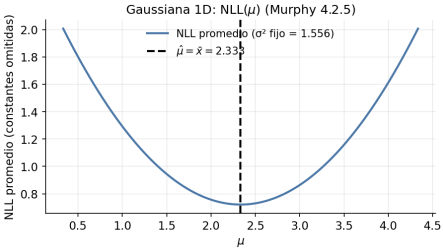

MLE en MVN: misma idea, en $\mathbb{R}^d$

- $\mathbf{x}_i \in \mathbb{R}^d$, $\mathbf{x}_i \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$. **(4.2.6)**
- **MLE:**

$$\hat{\boldsymbol{\mu}} = \frac{1}{n}\sum_{i=1}^{n} \mathbf{x}_i, \qquad \hat{\Sigma} = \frac{1}{n}\sum_{i=1}^{n} (\mathbf{x}_i - \hat{\boldsymbol{\mu}})(\mathbf{x}_i - \hat{\boldsymbol{\mu}})^\top.$$

- **Checks:** $\hat{\Sigma} \succeq 0$; puede ser singular si $n < d$.

ERM: la versión ML de "ajustar parámetros"

- Riesgo poblacional:

$$R(f) = \mathbb{E}[\ell(f(x), y)].$$

- Riesgo empírico:

$$\hat{R}(f) = \frac{1}{n} \sum_{i=1}^{n} \ell(f(x_i), y_i) \,. \qquad \textbf{(4.3)}$$

- **Mensaje:** en ML casi siempre minimizamos $\hat{R}$ (lo computable).

Misclassification rate (0-1): por qué es difícil optimizar

- Pérdida 0-1: $\ell_{0/1}(\hat{y}, y) = \mathbb{I}[\hat{y} \neq y]$. **(4.3.1)**
- Empírico: $\hat{R}_{0/1} = \frac{1}{n}\sum_i \mathbb{I}[\hat{y}_i \neq y_i]$ (tasa de error).
- **Problema:** no es suave; pequeños cambios en θ pueden no cambiar $\hat{y} \Rightarrow$ gradientes poco útiles.

Surrogate loss: hacer optimizable el problema

- Reemplazamos 0-1 por pérdidas que sean **optimizables** y correlacionen con acertar. **(4.3.2)**
- Para modelos probabilísticos, surrogate natural = **log-loss**:

$$\ell(\theta) = -\log p(y \mid x, \theta).$$

- **Puente:** minimizar NLL es ERM con log-loss:

$$\min_{\theta} \frac{1}{n} \sum_{i} -\log p(y_i \mid x_i, \theta).$$

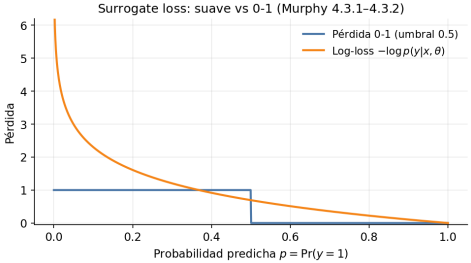

Semana 4 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab NumPy — objetivo general

- Implementar $\ell(\theta)$ y $\mathrm{NLL}(\theta)$ para Bernoulli y Gaussiana. **(4.2.1)**
- Calcular MLE **analítico** y validarlo con grid search. **(4.2.3, 4.2.5)**
- Incluir checks: clipping, $\sigma^2 > 0$, y comparación de mínimos.

Lab NumPy — checklist (qué debe aparecer en tu notebook)

- **Bernoulli:** $\hat{\pi} = \bar{x}$, curva $\mathrm{NLL}(\pi)$ por rejilla, y mínimo en $\hat{\pi}$. **(4.2.3)**
- **Gaussiana 1D:** $\hat{\mu} = \bar{x}$, $\hat{\sigma}^2$ (MLE), y validación por rejilla. **(4.2.5)**
- **Numerical hygiene:** evitar $\log 0$, evitar $\sigma^2 \leq 0$, usar NLL promedio para comparar.

Semana 4 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab sklearn — objetivo general

- Ver la equivalencia: MLE $\leftrightarrow$ minimizar log-loss (ERM con surrogate). **(4.3.2)**
- Caso simple: **logística intercept-only** $\Rightarrow$ Bernoulli (probabilidad constante). **(4.2.3)**
- Comparar 0-1 vs log-loss en un barrido de $p \in (0, 1)$. **(4.3.1–4.3.2)**

Logística intercept-only: la versión "ML" del Bernoulli

- Si el modelo predice una probabilidad constante p, el MLE Bernoulli es $\hat{p} = \bar{y}$. **(4.2.3)**
- En logística con solo intercept b: $p = \sigma(b) = \frac{1}{1+e^{-b}}$.
- Relación: $b = \log \frac{p}{1-p}$ (logit). Así, $\hat{b} = \log \frac{\bar{y}}{1-\bar{y}}$.
- **Check:** la probabilidad promedio predicha debe ser $\approx \bar{y}$ (si no hay regularización fuerte).

Semana 4 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Entregable — qué se evalúa

- **Slides:** comprensión conceptual (likelihood/log-likelihood/NLL, MLE, ERM).
- **Notebook NumPy:** implementación de NLL + MLE analítico + validación por grid + checks.
- **Notebook sklearn:** equivalencia log-loss/MLE (intercept-only) + comparación con 0-1.
- **Reproducible:** semilla fija, outputs limpios, y 5–8 líneas de interpretación.

Cierre: tres ideas para llevarte

1. **MLE** = elegir θ que maximiza $p(D \mid \theta)$ (mejor "explica" los datos). **(4.2)**
2. Trabajamos casi siempre con **log-likelihood/NLL** por estabilidad y porque suma pérdidas. **(4.2.1)**
3. **ERM** + **surrogates**: entrenar = minimizar un promedio de pérdidas; log-loss conecta directo con MLE. **(4.3)**

Semana 5 — Decision theory y evaluación de modelos

De probabilidades a decisiones: riesgo esperado, costos asimétricos, umbral $\rightarrow$ matriz de confusión, ROC/PR, AUC $\rightarrow$ validación cruzada

Curso de Machine Learning — UAQ (Matemáticas Aplicadas)

Libro base: *Probabilistic Machine Learning: An Introduction* (Kevin P. Murphy)

Semana 5

Lecturas sugeridas (para estos temas)

- **Capítulo 5 — Decision Theory**
  - **5.1** Bayesian decision theory
    - **5.1.1** Basics (acciones, estados, pérdida, riesgo)
    - **5.1.2** Classification problems (incluye costos asimétricos y reject)
    - **5.1.3** ROC curves
    - **5.1.4** Precision-recall curves
    - **5.1.5** Regression problems (repaso de pérdidas)
    - **5.1.6** Probabilistic prediction problems (log-loss, Brier)
  - **5.4** Empirical risk minimization (vista desde teoría estadística)
- **Capítulo 4 — Statistics**
  - **4.5.4** Picking the regularizer using a validation set
  - **4.5.5** Cross-validation

Temario de la Semana 5 (qué cubrimos hoy)

- **Teoría (PML)**
  - **1) Decision theory:** acciones, estados, pérdida, riesgo esperado **(5.1.1)**
  - **2) Clasificación:** pérdida 0-1, regla MAP y matriz de costos **(5.1.2)**
  - **3) Costos asimétricos:** cómo cambian los umbrales de decisión **(5.1.2.2)**
  - **4) Métricas:** matriz de confusión $\rightarrow$ precision/recall, TPR/FPR, specificity **(5.1.3–5.1.4)**
  - **5) Curvas ROC/PR y AUC:** interpretación y efecto del desbalance **(5.1.3–5.1.4)**
  - **6) Validación y CV:** riesgo empírico vs poblacional, K-fold **(1.2.3, 4.5.4–4.5.5, 5.4.3)**
- **Lab NumPy**
  - Construir matrices de confusión, TPR/FPR y precision/recall desde $\{y, s\}$
  - Generar curvas ROC/PR y calcular AUC / PR-AUC manualmente
  - Elegir umbral óptimo en función de costos asimétricos
- **Lab sklearn**
  - Pipeline de evaluación con `StratifiedKFold` (práctica externa)
  - `confusion_matrix`, `roc_curve`, `precision_recall_curve`
  - Reportar ROC-AUC, PR-AUC y métricas por fold en una tabla
- **Entregable**

Hilo conductor: de “ajustar” a “decidir y evaluar”

- Semana 4: vimos **MLE/ERM** como $\min_\theta \hat{R}(\theta)$ (ajustar parámetros al train).
- Semana 5: suponemos que ya tenemos $p(y \mid x)$ o scores, y ahora toca:
  - **(a) Decidir:** traducir probabilidades en acciones, usando *pérdidas/costos*.
  - **(b) Evaluar:** estimar qué tan bien funcionará el modelo fuera de la muestra.
- **Idea central:** *decision theory* + *evaluación* = puente entre modelos probabilísticos y problemas reales.

Semana 5 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Decision theory: ingredientes básicos

- **Estados del mundo** $h \in \mathcal{H}$: clase verdadera, valor real, etc.
- **Acciones** $a \in \mathcal{A}$: predecir una clase, un número, dar/no dar un tratamiento, elegir un modelo, etc.
- **Pérdida/costo** $\ell(h, a)$: qué tan "mala" es la acción a si la realidad es h. **(5.1.1)**
- **Riesgo posterior** dado evidencia x:

$$\rho(a \mid x) = \mathbb{E}_{p(h|x)}[\ell(h, a)].$$

- **Regla de decisión Bayesiana**:

$$\pi^*(x) = \arg\min_{a \in \mathcal{A}} \rho(a \mid x).$$

- **Ejemplo mental**: médico que decide entre "no tratar" o "dar fármaco caro con efectos secundarios" a un paciente que puede (o no) tener COVID-19.

Decision theory: ejemplo COVID-19 (tabla de pérdidas)

- **Estados** $h \in \mathcal{H}$: combinación de
  - edad (joven vs viejo),
  - estado de enfermedad (COVID-19 vs no COVID-19).
- **Acciones** $a \in \mathcal{A}$: $\{$*Nothing* (no tratar), *Drugs* (dar fármaco)$\}$.
- Usamos *QALYs* (quality-adjusted life years) como unidad de costo/beneficio:
  - joven: 60 QALYs esperados si se salva;
  - viejo: 10 QALYs esperados si se salva;
  - el fármaco "cuesta" 8 QALYs (dolor, efectos secundarios).
- **QALY** (*quality-adjusted life year*) $\approx$ "un año de vida en perfecta salud"; años con peor salud aportan menos de 1 QALY.

State	Nothing	Drugs
No COVID-19, young	0	8
COVID-19, young	60	8
No COVID-19, old	0	8
COVID-19, old	10	8

Decision theory: cómo leer la tabla de pérdidas

- La tabla no muestra los QALYs que la persona *tiene*, sino cuántos QALYs **pierde** por la combinación estado/acción.
- Fila "No COVID-19, young":
  - **Nothing = 0**: el joven sano tiene muchos QALYs de vida potencial, pero la decisión de no tratar *no le quita ninguno*.
  - **Drugs = 8**: tratarlo innecesariamente le hace perder 8 QALYs (efectos secundarios, sufrimiento, secuelas).
- Fila "COVID-19, young":
  - **Nothing = 60**: si no se trata y muere, se pierden los 60 QALYs que habría tenido.
  - **Drugs = 8**: el tratamiento le salva la vida pero "cuesta" 8 QALYs de calidad.
- Igual razonamiento para el paciente viejo con COVID-19 (10 vs 8 QALYs de pérdida).

Riesgo esperado y política óptima (ejemplo COVID-19)

- Dado lo que observamos x (p. ej. resultado del test y edad), el **riesgo** de una acción a es la pérdida esperada:

$$\rho(a \mid x) = \mathbb{E}[\ell(h, a) \mid x] = \sum_{h \in \mathcal{H}} \ell(h, a)\, p(h \mid x).$$

- En el ejemplo, una acción es $a =$ **Nothing** (*no hacer nada*). Llamamos **cost-noop** al riesgo de esa acción:

$$\text{cost-noop}(x) = \rho(\text{Nothing} \mid x).$$

- La **política óptima** elige, para cada x, la acción con menor riesgo:

$$\pi^*(x) = \arg\min_{a \in \mathcal{A}} \rho(a \mid x).$$

- Los **inputs** del ejemplo son: `test` (negativo/positivo), age (joven/viejo) y $p(\text{COVID} \mid x)$. En la siguiente slide veremos cómo se calcula cost-noop; al final tendremos la tabla con la decisión óptima.

Ejemplo COVID-19: cálculo de `cost-noop` (fórmula)

- Por definición, el cost-noop es el riesgo de la acción "no hacer nada":

$$\text{cost-noop}(x) = \mathbb{E}[\ell(h, \text{Nothing}) \mid x] = \sum_h \ell(h, \text{Nothing})\, p(h \mid x).$$

- **Paciente joven**: de la tabla de pérdidas, $\ell(\text{No COVID}, \text{young}, \text{Nothing}) = 0$ y $\ell(\text{COVID}, \text{young}, \text{Nothing}) = 60$. Entonces

$$\text{cost-noop} = 0 \cdot p(\text{No COVID} \mid x) + 60 \cdot p(\text{COVID} \mid x) = 60\, p(\text{COVID} \mid x).$$

- **Paciente mayor**: $\ell(\text{No COVID}, \text{old}, \text{Nothing}) = 0$, $\ell(\text{COVID}, \text{old}, \text{Nothing}) = 10$, luego

$$\text{cost-noop} = 10\, p(\text{COVID} \mid x).$$

- Los valores de la tabla se obtienen sustituyendo $p(\text{COVID} \mid x)$ por las probabilidades que da el test (siguiente slide).

Ejemplo COVID-19: `cost-noop` (valores numéricos)

- Con las probabilidades del test: $p(\text{COVID} \mid \text{test} = 0) \approx 0{,}014$, $p(\text{COVID} \mid \text{test} = 1) \approx 0{,}7955$.
- Sustituyendo en las fórmulas anteriores:
  - **Test negativo**: joven $60 \times 0{,}014 = 0{,}84$; mayor $10 \times 0{,}014 = 0{,}14$.
  - **Test positivo**: joven $60 \times 0{,}7955 = 47{,}73$; mayor $10 \times 0{,}7955 = 7{,}95$.

test	age	pr(covid)	cost-noop	cost-drugs	action
0	0	0.01	0.84	8.00	0
0	1	0.01	0.14	8.00	0
1	0	0.80	47.73	8.00	1
1	1	0.80	7.95	8.00	0

- **Comparación**: cost-drugs $= 8$ siempre. Si cost-noop < 8 conviene no tratar (action=0); si cost-noop > 8, tratar (action=1). Por eso, con test positivo y paciente joven, la política óptima es tratar; con test positivo y mayor, no tratar (7.95 y 8 son muy cercanos).

De pérdida a utilidad: el mismo principio

- En muchos textos se usa **utilidad** $U(h, a)$ en vez de pérdida $\ell(h, a)$.
- Relación simple: $U(h, a) = -\ell(h, a)$.
- **Máxima utilidad esperada**:

$$\pi^*(x) = \arg\max_{a \in \mathcal{A}} \mathbb{E}_{p(h|x)}[U(h, a)].$$

- En ML solemos pensar en **minimizar pérdida promedio** (riesgo) $\leftrightarrow$ **maximizar utilidad esperada**.

Clasificación binaria con pérdida 0-1

- Estados y acciones son las clases: $\mathcal{H} = \mathcal{A} = \{0, 1\}$. **(5.1.2.1)**
- **Pérdida** 0-1:

$$\ell_{0/1}(y^*, \hat{y}) = \mathbf{1}[y^* \neq \hat{y}].$$

- Riesgo posterior de predecir $\hat{y}$:

$$\rho(\hat{y} \mid x) = 1 - p(y^* = \hat{y} \mid x).$$

- **Regla óptima**: elegir la clase más probable (MAP):

$$\hat{y}(x) = \arg \max_{y \in \{0,1\}} p(y \mid x).$$

Costos asimétricos en binario: matriz de pérdida

- En muchos problemas, **no todos los errores cuestan igual**.
- Matriz de pérdida general:

$$\ell(y^*, \hat{y}) = \begin{pmatrix} \ell_{00} & \ell_{01} \\ \ell_{10} & \ell_{11} \end{pmatrix},$$

  donde filas = verdad, columnas = predicción. **(5.1.2.2)**
- Ejemplo clásico: detección de enfermedad
  - FP (decir "enfermo" cuando está sano) = costo moderado.
  - FN (decir "sano" cuando está enfermo) = costo muy alto.

Costos asimétricos $\Rightarrow$ umbral distinto de 0.5

- Sea $p_1 = p(y^* = 1 \mid x)$, $p_0 = 1 - p_1$, donde y^* es la **etiqueta verdadera** (ground truth) y $\hat{y}$ la predicción.
- Así, p_1 = probabilidad de que la clase real sea 1 dado x; p_0 = probabilidad de que sea 0.
- Riesgo de predecir $\hat{y} = 1$:
$$\rho(1 \mid x) = \ell_{01} p_0 + \ell_{11} p_1.$$
- Riesgo de predecir $\hat{y} = 0$:
$$\rho(0 \mid x) = \ell_{00} p_0 + \ell_{10} p_1.$$
- Caso típico $\ell_{00} = \ell_{11} = 0$: predecir 1 si
$$p_1 \geq \frac{\ell_{01}}{\ell_{01} + \ell_{10}}.$$
- Si un FN cuesta c veces más que un FP ($\ell_{10} = c\,\ell_{01}$):
$$p_1 \geq \frac{1}{1 + c}.$$
- **Ejemplo**: $c = 4 \Rightarrow$ umbral $1/5 = 0{,}2$ (somos mucho más "sensibles").

Costos asimétricos: de dónde sale el umbral

- Con $\ell_{00} = \ell_{11} = 0$ (acertar no cuesta), el riesgo de predecir 1 es $\rho(1 \mid x) = \ell_{01}(1 - p_1)$; el de predecir 0 es $\rho(0 \mid x) = \ell_{10} p_1$.
- Predecimos 1 cuando $\rho(1 \mid x) \leq \rho(0 \mid x)$, es decir

$$\ell_{01}(1 - p_1) \leq \ell_{10} p_1 \iff \ell_{01} - \ell_{01} p_1 \leq \ell_{10} p_1 \iff \ell_{01} \leq p_1(\ell_{01} + \ell_{10}) \iff p_1 \geq \frac{\ell_{01}}{\ell_{01} + \ell_{10}}.$$

- Si $\ell_{10} = c\,\ell_{01}$ (un FN cuesta c veces un FP):

$$p_1 \geq \frac{1}{1 + c}.$$

- **Interpretación**: $c = 4 \Rightarrow$ umbral 0.2. Bajamos el umbral respecto a 0.5 para ser más sensibles: preferimos más FP que perder casos reales (FN).

Costos asimétricos: umbral 0.5 vs umbral óptimo

- Con **umbral 0.5** (costos simétricos): predecimos 1 solo si $p_1 \geq 0{,}5$.
- Con **umbral** $1/(1+c)$ (FN cuesta c veces un FP): predecimos 1 si $p_1 \geq 1/(1+c)$.
- Si $c > 1$, entonces $1/(1+c) < 0{,}5$: el umbral óptimo es *menor* que 0.5.
- **Ejemplo** $c = 4$: umbral 0,2. Un modelo que da $p_1 = 0{,}3$:
  - Con 0.5: predeciríamos 0 ("sano"); con 0.2: predecimos 1 ("tratar").
  - Priorizamos no perder enfermos (menos FN), aunque haya más falsas alarmas (más FP).

Costos asimétricos: ejemplo numérico completo

- Supongamos la siguiente matriz de pérdida para un clasificador médico:

$$\ell(y^*, \hat{y}) = \begin{pmatrix} 0 & 1 \\ 5 & 0 \end{pmatrix},$$

  donde $y^* = 0 =$ sano, $y^* = 1 =$ enfermo.
- Entonces un FN (enfermo etiquetado como sano) cuesta 5 veces un FP $\Rightarrow c = 5$.
- El **umbral óptimo** según decision theory es

$$p_1^\star = \frac{1}{1+c} = \frac{1}{6} \approx 0{,}17.$$

- **Interpretación práctica**:
  - Si $p(y = 1 \mid x) = 0{,}20$: bajo 0,5 dirías "sano"; bajo 0,17 ya vale la pena tratar.
  - Si $p(y = 1 \mid x) = 0{,}05$: incluso con costos asimétricos, sigue por debajo del umbral 0,17.

Matriz de confusión: conectar decisiones con conteos

- Para un clasificador binario con umbral fijo:
  - **TP**: verdaderos positivos
  - **FP**: falsos positivos
  - **TN**: verdaderos negativos
  - **FN**: falsos negativos
- Tabla (forma de **Tabla 5.3**):

	$\hat{y} = 0$	$\hat{y} = 1$
$y = 0$	TN	FP
$y = 1$	FN	TP

Derivar métricas desde la matriz de confusión

- Normalizando por filas (condicionado en la verdad): **(5.1.3.1, 5.1.3.2)**
  - **TPR / recall / sensitivity**: $\mathrm{TPR} = \dfrac{TP}{TP + FN}$.
  - **TNR / specificity**: $\mathrm{TNR} = \dfrac{TN}{TN + FP}$.
  - **FPR**: $\mathrm{FPR} = 1 - \mathrm{TNR} = \dfrac{FP}{FP + TN}$.
- Normalizando por columnas (condicionado en la predicción):
  - **Precision / PPV**: $\mathrm{Prec} = \dfrac{TP}{TP + FP}$.
  - **NPV**: $\mathrm{NPV} = \dfrac{TN}{TN + FN}$.
- **Idea**: todas las métricas que usamos (accuracy, recall, precision, etc.) son distintas "vistas" de la misma tabla.

Matriz de confusión: ejemplo numérico

	$\hat{y} = 0$	$\hat{y} = 1$
$y = 0$	50	10
$y = 1$	5	35

- Total negativos verdaderos $N = 60$, positivos verdaderos $P = 40$.
- Accuracy $= (50 + 35)/100 = 0{,}85$.

- **Recall / TPR**:

$$\mathrm{TPR} = \frac{TP}{TP + FN} = \frac{35}{35 + 5} = 0{,}875.$$

- **FPR**:

$$\mathrm{FPR} = \frac{FP}{FP + TN} = \frac{10}{10 + 50} \approx 0{,}167.$$

- **Precision**:

$$\mathrm{Prec} = \frac{TP}{TP + FP} = \frac{35}{35 + 10} \approx 0{,}78.$$

- **NPV**:

$$\mathrm{NPV} = \frac{TN}{TN + FN} = \frac{50}{50 + 5} \approx 0{,}91.$$

Curva ROC: barrer el umbral

- Si el modelo produce un **score** $s(x)$ (p. ej. $p(y = 1 \mid x)$), definimos $\hat{y}_\tau(x) = \mathbf{1}[s(x) \geq \tau]$.
- Para cada τ calculamos TPR_τ y FPR_τ. **(5.1.3)**
- La **curva ROC** grafica TPR_τ vs FPR_τ al variar $\tau \in [0, 1]$.
- **Extremos**:
  - $\tau \to 0$: todo es positivo ($\mathrm{TPR} \approx 1$, $\mathrm{FPR} \approx 1$).
  - $\tau \to 1$: nadie es positivo ($\mathrm{TPR} \approx 0$, $\mathrm{FPR} \approx 0$).

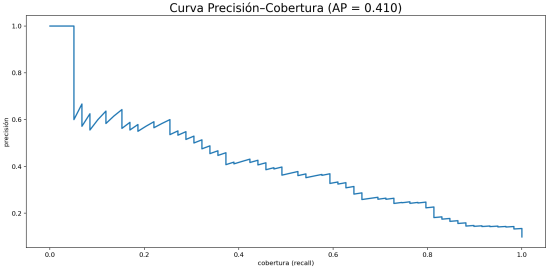

AUC, EER y lectura rápida de ROC

- **AUC** (Area Under the ROC Curve):
  - $\mathrm{AUC} = 1$: clasificador perfecto (curva pegada a la esquina superior izquierda).
  - $\mathrm{AUC} \approx 0{,}5$: como lanzar una moneda (diagonal).
- **Equal Error Rate (EER)**:
  - Punto donde $\mathrm{FPR} = \mathrm{FNR} = 1 - \mathrm{TPR}$. **(5.1.3.2)**
  - Se visualiza como intersección de la ROC con la diagonal descendente.
- **Uso práctico**: ROC es útil cuando el costo de FP/FN no está fijado, y queremos comparar modelos "globalmente".

Curva Precision–Recall (PR): cuando los positivos son raros

- Recordemos:

$$\mathrm{Prec}_\tau = \frac{TP_\tau}{TP_\tau + FP_\tau}, \qquad \mathrm{Rec}_\tau = \frac{TP_\tau}{TP_\tau + FN_\tau}. \qquad \textbf{(5.1.4.1)}$$

- La **curva PR** grafica Prec_τ vs Rec_τ al variar τ.
- Es especialmente informativa cuando hay **fuerte desbalance** ($P \ll N$), donde ROC puede verse "demasiado bonita".
- **PR-AUC / AP**: área (o average precision) bajo la curva PR. **(5.1.4.2)**

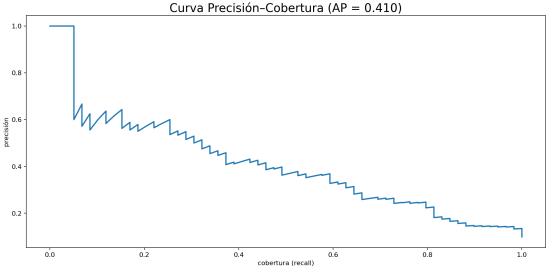

Mini-ejemplo ROC/PR con 5 ejemplos

- Dataset pequeño (ordenado por score descendente):

n	1	2	3	4	5
y_n	1	0	1	0	1
s_n	0,9	0,8	0,6	0,4	0,3

- Hay $P = 3$ positivos, $N = 2$ negativos.
- Si usamos $\tau = 0{,}75$:
  - $\hat{y} = (1, 1, 0, 0, 0) \Rightarrow TP = 1, FP = 1, TN = 1, FN = 2.$
  - $\mathrm{TPR} = 1/3$, $\mathrm{FPR} = 1/2$, $\mathrm{Prec} = 1/2$, $\mathrm{Rec} = 1/3$.
- Si usamos $\tau = 0{,}5$:
  - $\hat{y} = (1, 1, 1, 0, 0) \Rightarrow TP = 2, FP = 1, TN = 1, FN = 1.$
  - $\mathrm{TPR} = 2/3$, $\mathrm{FPR} = 1/2$, $\mathrm{Prec} = 2/3$, $\mathrm{Rec} = 2/3$.

Mini-ejemplo ROC/PR (cont.): puntos en las curvas

- Para el dataset anterior, podemos armar una pequeña tabla:

τ	TPR	FPR	Prec	Rec
1,0	0	0	–	–
0,75	1/3	1/2	1/2	1/3
0,5	2/3	1/2	2/3	2/3
0,25	1	1	3/5	1

- **ROC**: puntos $(\mathrm{FPR}, \mathrm{TPR}) = (0,0), (0{,}5, 1/3), (0{,}5, 2/3), (1,1)$.
- **PR**: puntos $(\mathrm{Rec}, \mathrm{Prec}) = (0,-), (1/3, 1/2), (2/3, 2/3), (1, 3/5)$.
- Con estos pocos puntos ya se puede:
  - visualizar cómo el **umbral** barre las curvas;
  - aproximar AUC/PR-AUC con la regla del trapecio (como en el Lab NumPy).

F-scores: combinar precisión y recall en un solo número

- Para un umbral fijo $(\mathrm{Prec}, \mathrm{Rec})$, el $\mathbf{F}_\beta$ se define como: **(5.1.4.3)**

$$F_\beta = \frac{(1+\beta^2)\,\mathrm{Prec}\,\mathrm{Rec}}{\beta^2\,\mathrm{Prec} + \mathrm{Rec}}.$$

- Casos especiales:
  - F_1: media armónica de precisión y recall (pesa ambos por igual).
  - $\beta > 1$: da más peso a *recall* (importa más cubrir positivos).
  - $\beta < 1$: da más peso a *precision* (importa más evitar FP).
- **Interpretación**: útil para seleccionar el umbral cuando tenemos una preferencia clara por precision o recall.

Desbalance de clases: ROC vs PR

- ROC usa tasas TPR y FPR que **no cambian** si escalamos P y N manteniendo la proporción. **(5.1.3.3)**
- En problemas muy desbalanceados, ROC puede verse buena aunque haya muchos FP absolutos.
- PR (y F-score) sí son **sensibles** a la prevalencia:

$$\mathrm{Prec} = \frac{\mathrm{TPR}}{\mathrm{TPR} + \frac{1}{r}\mathrm{FPR}}, \quad r = \frac{P}{N}. \qquad \textbf{(5.1.4.4)}$$

- **Regla práctica**:
  - Clases balanceadas $\rightarrow$ ROC-AUC es razonable.
  - Clases raras $\rightarrow$ mira PR-AUC / AP y F-scores.

Validación: train / validation / test y leakage

- Separar los datos en:
  - **Train**: ajustar parámetros θ.
  - **Validation**: escoger hiperparámetros (p. ej. λ, arquitectura, umbral).
  - **Test**: estimar $L(\theta^*; p^*)$ una sola vez. **(1.2.3, 4.5.4)**
- **Leakage**: usar test (directa o indirectamente) para tomar decisiones de modelo/hiperparámetros.
- **Consecuencia**: subestimar el error real; el modelo parece mejor de lo que realmente es.

Cross-validation (CV): usar mejor los datos

- Problema: con pocos datos, separar un validation set fijo puede ser caro.
- **K-fold CV** (K-pliegues): **(4.5.5, 5.4.3)**
  - Partimos train en K folds $D_1, \ldots, D_K$.
  - Para cada k: entrenamos en D_{-k} y evaluamos en D_k.
  - Promediamos la métrica (MSE, AUC, F1, etc.) sobre los K folds.
- **Uso típico**: escoger hiperparámetros (p. ej. λ de regularización) y comparar modelos.

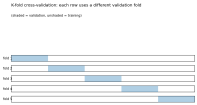

Cross-validation (CV): ejemplo numérico sencillo

- Supongamos $K = 3$ folds y medimos **accuracy** para un modelo:

Fold	Accuracy
1	0,82
2	0,79
3	0,87

- **Promedio**: $\bar{a} = (0{,}82 + 0{,}79 + 0{,}87)/3 \approx 0{,}83$.
- **Desviación estándar** (muestral):

$$s \approx \sqrt{\frac{(0{,}82 - \bar{a})^2 + (0{,}79 - \bar{a})^2 + (0{,}87 - \bar{a})^2}{3 - 1}} \approx 0{,}04.$$

- Reporte típico: accuracy CV $\approx 0{,}83 \pm 0{,}04$.
- **Lectura**: el modelo parece razonablemente estable, pero hay variabilidad entre folds (dependiente del split).

Semana 5 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab NumPy — objetivo general

- Tomar $\{y_n \in \{0,1\}, s_n \in [0,1]\}$ y construir:
  - Matrices de confusión para distintos umbrales τ.
  - Curvas ROC y PR, con AUC / PR-AUC vía regla del trapecio.
- Implementar una función de **riesgo empírico** con matriz de costos ℓ_{ij} y buscar el **umbral óptimo**.

Lab NumPy — checklist (qué debe aparecer en tu notebook)

- **Funciones básicas**:
  - `confusion_counts(y_true, scores, tau)` $\rightarrow$ TP, FP, TN, FN.
  - `metrics_from_confusion(...)` $\rightarrow$ accuracy, TPR, FPR, precision, recall, F1.
- **Curvas y áreas**:
  - `roc_curve_manual` y `pr_curve_manual`.
  - `auc_trapezoidal(x, y)` para ROC-AUC y PR-AUC.
  - Gráficos ROC y PR etiquetados (similar a las figuras del libro).
- **Costos asimétricos**:
  - Función `empirical_risk_tau(y, scores, tau, cost_matrix)`.
  - Gráfico de $\hat{L}(\tau)$ vs τ para distintos cocientes de costos FP/FN.
  - Comparar el τ que minimiza riesgo con el umbral $1/(1+c)$ teórico.

Semana 5 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab sklearn — objetivo general

- Construir un pipeline mínimo de evaluación para clasificación binaria:
  - `StratifiedKFold` para estimar métricas con CV (nota práctica: no aparece como tal en el libro).
  - `confusion_matrix`, `roc_curve`, `roc_auc_score`.
  - `precision_recall_curve`, `average_precision_score`.
- Reportar métricas por fold y su promedio $\pm$ desviación estándar.

Lab sklearn — checklist (estructura sugerida)

- **Datos y modelo**:
  - Dataset binario con cierto desbalance.
  - Modelo sencillo (p. ej. `LogisticRegression` o `RandomForestClassifier`).
- **Cross-validation**:
  - `StratifiedKFold(n_splits=K, shuffle=True, random_state=...)`.
  - Para cada fold: entrenar, obtener `predict_proba` y `predict`.
- **Métricas por fold**:
  - Accuracy, ROC-AUC, PR-AUC (AP), F1.
  - Matriz de confusión.
- **Tabla final**:
  - Filas = folds, columnas = métricas.
  - Fila extra con promedio y desviación estándar.

Semana 5 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Entregable — qué se evalúa

- **Slides:** claridad en:
  - definición de pérdida, riesgo esperado y reglas de decisión;
  - relación entre matriz de confusión, ROC/PR y métricas derivadas;
  - papel de train/validation/test y CV.
- **Notebook NumPy:** construcción manual y correcta de métricas/curvas + selección de umbral con costos.
- **Notebook sklearn:** pipeline de evaluación con CV + tabla de métricas bien interpretada.

Cierre: tres ideas para llevarte

1. **Decision theory** formaliza "qué acción tomar" como arg mín de riesgo esperado (pérdida + probabilidades). **(5.1.1–5.1.2)**
2. **Costos asimétricos** cambian el **umbral óptimo** y, por tanto, la región de operación en la ROC/PR. **(5.1.2.2, 5.1.3–5.1.4)**
3. **Evaluar bien** (train/val/test, CV) es clave para estimar el **riesgo poblacional** y no sobreestimar el modelo. **(1.2.3, 4.5.5, 5.4.3)**

Semana 6 — Information Theory para Machine Learning

Entropía, cross-entropy, KL divergence y su papel como loss

Curso de Machine Learning — UAQ (Matemáticas Aplicadas)

Libro base: *Probabilistic Machine Learning: An Introduction* (Kevin P. Murphy)

Semana 6

Lecturas sugeridas (para estos temas)

- **Capítulo 6 — Information theory**
  - **6.1** Entropy
    - **6.1.1** Entropy for discrete random variables
    - **6.1.2** Cross entropy
    - **6.1.3–6.1.5** Joint / conditional entropy, perplexity
  - **6.2** Relative entropy (KL divergence)
    - **6.2.1–6.2.6** Definición, interpretación, no-negatividad, KL y MLE

Temario de la Semana 6 (qué cubrimos hoy)

- **Teoría (PML)**
  - **1) Surprisal:** $I(x) = -\log p(x)$, unidades (bits/nats) **(6.1.1)**
  - **2) Entropía:** $H(X)$ como incertidumbre promedio; ejemplos discretos **(6.1.1)**
  - **3) Cross-entropy:** $H(p, q)$, interpretación codificación / modelo **(6.1.2)**
  - **4) KL:** $\mathrm{KL}(p\|q)$, no-negatividad, orden p vs q **(6.2)**
  - **5) Identidad:** $H(p, q) = H(p) + \mathrm{KL}(p\|q)$ **(6.1.2, 6.2)**
  - **6) ML:** CE/NLL en etiquetas one-hot, enlace con MLE e incertidumbre del modelo **(6.1.2, 6.2)**
- **Lab NumPy**
  - Calcular $H(p)$, $H(p, q)$ y $\mathrm{KL}(p\|q)$ a mano en ejemplos pequeños
  - Curva de entropía Bernoulli $H(\theta)$; verificar casos límite numéricamente
- **Lab sklearn**
  - `log_loss` y equivalencia con CE promedio en clasificación
  - Comparar CE manual vs implementación en un mini-dataset
- **Entregable**

Hilo conductor: de “evaluar aciertos” a “evaluar probabilidades”

- Semana 5: métricas de clasificación y curvas ROC/PR miden, sobre todo, **decisiones** y **aciertos** bajo umbrales.
- Semana 6: si el modelo entrega una **distribución** $\hat{p}(y \mid x)$, necesitamos una loss coherente con probabilidades.
- **Idea central:** surprisal $\rightarrow$ entropía $\rightarrow$ cross-entropy $\rightarrow$ KL conectan incertidumbre, codificación y entrenamiento (MLE $\equiv$ minimizar NLL/CE).

Semana 6 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

¿Qué estudia information theory?

- **Pregunta central:** ¿cuánta incertidumbre hay en una fuente aleatoria y cuánto cuesta describir sus resultados?
- **Shannon (1948):** propone medidas cuantitativas para:
  - la **incertidumbre** de una variable aleatoria,
  - la **sorpresa** de observar un evento,
  - el costo de usar un **modelo incorrecto** para describir los datos.
- **Idea guía de la semana:** pasaremos de la sorpresa de un evento individual a la pérdida promedio de un modelo probabilístico.
- Esa ruta conceptual será:

$$\text{surprisal} \longrightarrow \text{entropía} \longrightarrow \text{cross-entropy} \longrightarrow \mathrm{KL}.$$

¿Por qué importa en machine learning?

- En muchos modelos de ML no solo queremos **predecir una clase**, sino asignar una **distribución de probabilidad** sobre las clases.
- Esto requiere una forma coherente de:
  - medir la **incertidumbre** del modelo,
  - **comparar** distribuciones (datos vs modelo),
  - definir **funciones de pérdida** basadas en probabilidad.
- Las cantidades de information theory (entropía, cross-entropy, divergencia KL) serán los ladrillos para:
  - diseñar la loss estándar de clasificación,
  - entender por qué maximizar likelihood equivale a minimizar NLL/CE,
  - preparar métodos probabilísticos más avanzados.

Self-information / surprisal: definición e intuición

- Sea un evento x con probabilidad $p(x) \in (0, 1]$.
- **Definición (Shannon):**

$$I(x) \triangleq -\log p(x)$$

- **Unidades:**
  - base 2 $\Rightarrow$ bits,
  - base e $\Rightarrow$ nats.
- **Intuición:**
  - cuanto más improbable es x, mayor es su sorpresa/información;
  - si $p(x) = 1$ (evento seguro), entonces $I(x) = 0$: no hay sorpresa.

Ejemplo numérico de surprisal

- Evento A: lanzar una moneda justa y obtener cara.

$$p(A) = 0{,}5, \quad I(A) = -\log_2(0{,}5) = 1 \text{ bit}$$

- Evento B: lanzar un dado justo y obtener un 6.

$$p(B) = \tfrac{1}{6}, \quad I(B) = -\log_2\left(\tfrac{1}{6}\right) \approx 2{,}585 \text{ bits}$$

- **Lectura:** observar un 6 específico en un dado justo aporta más información que observar cara en una moneda justa.

Nota: Confundir "información" con "importancia" del evento. Un evento raro tiene mucha información en el sentido de sorpresa, no necesariamente en el sentido de relevancia práctica.

Analogía útil para explicar surprisal

- Imagina un sistema de **alertas**:
  - "Todo funciona normal" (muy frecuente) $\rightarrow$ poca sorpresa.
  - "El servidor crítico está caído" (muy raro) $\rightarrow$ mucha sorpresa.
- El valor $I(x)$ mide "**cuán inesperado**" fue el evento.
- En ML, si el modelo asigna probabilidad muy baja a la clase verdadera, la loss será alta: el modelo se "sorprende" demasiado por lo que pasó en realidad.

	Evento frecuente	Evento raro	Evento muy raro
Probabilidad $p(x)$	0.8	0.15	0.05
Sorpresa $I(x) = -\log_2 p(x)$	$\approx 0{,}32$	$\approx 2{,}74$	$\approx 4{,}32$

Entropía: definición formal

- Sea X una variable discreta con distribución $p(x)$ sobre un conjunto finito $\mathcal{X}$.
- **Definición de entropía de Shannon:**

$$H(X) \triangleq -\sum_{x \in \mathcal{X}} p(x) \log p(x)$$

- **Interpretaciones equivalentes:**
  - incertidumbre promedio de X,
  - información esperada de los eventos x (promedio de $I(x)$),
  - longitud promedio mínima (en bits) de un código óptimo para X.
- **Notación alternativa:** $H(p)$ cuando queremos enfatizar que depende de la distribución p.

Entropía como esperanza de surprisal

- Ya definimos la sorpresa de un evento individual:

$$I(x) = -\log p(x).$$

- Si ahora $X \sim p$, la sorpresa **promedio** es:

$$\mathbb{E}_p[I(X)] = \sum_x p(x)\, I(x).$$

- Sustituyendo $I(x) = -\log p(x)$:

$$\mathbb{E}_p[I(X)] = \sum_x p(x)\,[-\log p(x)] = -\sum_x p(x) \log p(x).$$

- **Conclusión:**

$$H(X) = \mathbb{E}_p[I(X)].$$

- Esta identidad conecta de forma natural evento individual $\rightarrow$ incertidumbre promedio.

Ejemplo: entropía de una distribución discreta simple

- Supón $X \in \{a, b, c\}$ con:

$$p(a) = 0{,}5, \quad p(b) = 0{,}25, \quad p(c) = 0{,}25.$$

- Calculamos:

$$H(X) = -\big[0{,}5 \log_2 0{,}5 + 0{,}25 \log_2 0{,}25 + 0{,}25 \log_2 0{,}25\big].$$

- Paso a paso:

$$\log_2 0{,}5 = -1, \quad \log_2 0{,}25 = -2$$

$$H(X) = -\big[0{,}5(-1) + 0{,}25(-2) + 0{,}25(-2)\big] = -\big[-0{,}5 - 0{,}5 - 0{,}5\big] = 1{,}5 \text{ bits}.$$

- **Lectura:** en promedio, "necesitamos" 1.5 bits para codificar X de forma óptima.

Entropía y dispersión de la distribución

- Para un alfabeto fijo:
  - la **entropía es máxima** cuando la distribución es uniforme (toda la probabilidad repartida por igual);
  - la **entropía es mínima** (0) cuando la distribución es degenerada (toda la masa en un solo punto).
- Intuición: cuanta más "dispersa" esté la probabilidad entre muchos valores plausibles, más incertidumbre tenemos; cuando casi todo el peso está en un único valor, apenas dudamos.
- **Mensaje para ML:** una predicción con probabilidades muy repartidas tiene mayor entropía que una predicción muy concentrada en una sola clase.

Entropía de una moneda: visualización

- Para una moneda con parámetro $\theta = \Pr(\text{cara})$, la entropía

$$H(\theta) = -\theta \log_2 \theta - (1-\theta) \log_2 (1-\theta)$$

  mide cuánta incertidumbre hay antes de observar el resultado del lanzamiento.
- Analíticamente sabemos que:
  - la incertidumbre es **máxima** en $\theta = 0{,}5$ (moneda justa),
  - tiende a 0 cuando $\theta \to 0$ o $\theta \to 1$ (moneda casi determinista).
- En la siguiente gráfica se ve claramente esta forma "en campana invertida" de $H(\theta)$.

Entropía de una moneda: curva $H(\theta)$

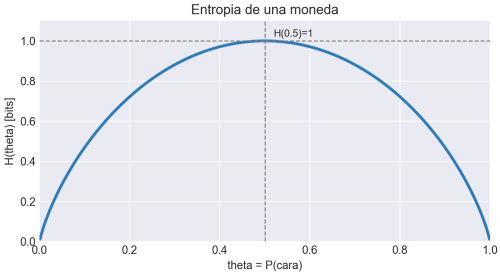

La entropía es máxima para $\theta = 0{,}5$ (moneda justa) y se aproxima a 0 cuando θ se acerca a 0 o 1, es decir, cuando la moneda es prácticamente determinista.

Cross-entropy: definición e interpretación

- Tenemos una **distribución verdadera** p y un **modelo** q.
- **Definición:**

$$H(p, q) \triangleq -\sum_{x} p(x) \log q(x).$$

- **Lectura:**
  - sorpresa promedio de datos generados por p, pero evaluada con el modelo q,
  - costo promedio de codificar datos de p usando el código óptimo para q.
- Si $q = p$, entonces $H(p, q) = H(p)$: el mejor caso es usar el modelo verdadero.

Ejemplo: cross-entropy entre dos distribuciones sobre $\{a, b\}$

- Verdadera p: $\quad p(a) = 0{,}8,\ p(b) = 0{,}2.$
- Modelo q: $\quad q(a) = 0{,}6,\ q(b) = 0{,}4.$
- Calculamos:

$$H(p, q) = -\big[0{,}8 \log_2 0{,}6 + 0{,}2 \log_2 0{,}4\big].$$

- Números aproximados:

$$\log_2 0{,}6 \approx -0{,}737, \quad \log_2 0{,}4 \approx -1{,}322,$$

$$H(p, q) \approx -\big[0{,}8(-0{,}737) + 0{,}2(-1{,}322)\big] \approx -\big[-0{,}5896 - 0{,}2644\big] \approx 0{,}854 \text{ bits}.$$

- Como veremos enseguida, este valor es mayor que $H(p)$ por una cantidad exactamente igual a la divergencia KL.

KL divergence: definición y significado

- **Definición:**

$$\mathrm{KL}(p\|q) \triangleq \sum_x p(x) \log \frac{p(x)}{q(x)}.$$

- **Interpretaciones:**
  - "**penalización** media por usar q en lugar de p",
  - exceso de longitud promedio (en bits) al codificar datos de p con un código óptimo para q,
  - medida de cuán distinta es q de p (aunque *no* es una distancia simétrica).
- Propiedades clave:
  - $\mathrm{KL}(p\|q) \geq 0$ (**desigualdad de Gibbs**),
  - $\mathrm{KL}(p\|q) = 0 \iff p = q$ (casi en todas partes),
  - en general $\mathrm{KL}(p\|q) \neq \mathrm{KL}(q\|p)$.

Ejemplo numérico de KL divergence

- Reutilizamos el ejemplo anterior:

$$p(a) = 0{,}8,\ p(b) = 0{,}2, \quad q(a) = 0{,}6,\ q(b) = 0{,}4.$$

- Calculamos:

$$\mathrm{KL}(p\|q) = 0{,}8 \log_2 \frac{0{,}8}{0{,}6} + 0{,}2 \log_2 \frac{0{,}2}{0{,}4}.$$

$$\log_2 \frac{0{,}8}{0{,}6} \approx \log_2(1{,}333) \approx 0{,}415, \quad \log_2 \frac{0{,}2}{0{,}4} = \log_2(0{,}5) = -1.$$

$$\mathrm{KL}(p\|q) \approx 0{,}8(0{,}415) + 0{,}2(-1) \approx 0{,}332 - 0{,}2 = 0{,}132 \text{ bits}.$$

- **Lectura:** al codificar datos de p con un código óptimo para q, pagamos en promedio 0.132 bits extra por símbolo.

Identidad clave: $H(p,q) = H(p) + \mathrm{KL}(p\|q)$

- Recordemos:

$$H(p) = -\sum_x p(x)\log p(x), \quad H(p,q) = -\sum_x p(x)\log q(x).$$

- Queremos mostrar:

$$H(p,q) = H(p) + \mathrm{KL}(p\|q).$$

Derivación paso a paso:

$$\mathrm{KL}(p\|q) = \sum_x p(x)\log\frac{p(x)}{q(x)} = \sum_x p(x)\big[\log p(x) - \log q(x)\big].$$

$$\mathrm{KL}(p\|q) = \sum_x p(x)\log p(x) - \sum_x p(x)\log q(x).$$

$$-\sum_x p(x)\log q(x) = -\sum_x p(x)\log p(x) + \mathrm{KL}(p\|q).$$

$$\Rightarrow \quad H(p,q) = H(p) + \mathrm{KL}(p\|q).$$

Interpretación de la identidad $H(p, q) = H(p) + \mathrm{KL}(p\|q)$

- **Descomposición:**
  - $H(p)$: incertidumbre "irreductible" de la fuente (no depende de nuestro modelo),
  - $\mathrm{KL}(p\|q)$: **penalización extra** por usar el modelo q en lugar del modelo óptimo p.
- **Mensaje:** al minimizar $H(p, q)$ sobre q, en realidad estamos minimizando $\mathrm{KL}(p\|q)$, ya que $H(p)$ es constante.
- Esto anticipa lo que haremos en ML: elegir parámetros para que la distribución predicha por el modelo se acerque a la distribución verdadera de etiquetas.

Setup: clasificación probabilística y etiquetas one-hot

- Problema de clasificación con C clases.
- Dado un input x, el modelo produce un vector de probabilidades:

$$\hat{p}_\theta(y = c \mid x), \quad c = 1, \ldots, C.$$

- La etiqueta verdadera se representa como vector **one-hot**:

$$y = (y_1, \ldots, y_C), \quad y_c \in \{0, 1\}, \quad \sum_c y_c = 1.$$

- **Cross-entropy empírica** para un ejemplo (x, y):

$$\ell_{\mathrm{CE}}(y, \hat{p}_\theta(\cdot \mid x)) = -\sum_{c=1}^{C} y_c \log \hat{p}_\theta(y = c \mid x).$$

- Como solo una componente de y es 1, la suma se reduce a $-\log$ de la probabilidad de la clase verdadera.

De cross-entropy a negative log-likelihood

- Si la clase verdadera es k, entonces la etiqueta one-hot cumple:

$$y_k = 1, \qquad y_c = 0 \ \text{ para } c \neq k.$$

- Sustituyendo en la definición:

$$\ell_{\mathrm{CE}}(y, \hat{p}) = -\sum_{c=1}^{C} y_c \log \hat{p}(c) = -\log \hat{p}(k).$$

- **Interpretación:** la loss depende solo de la probabilidad asignada a la clase correcta.
- Por eso en clasificación probabilística, la CE para un ejemplo coincide con la **negative log-likelihood**:

$$\ell_{\mathrm{NLL}} = -\log \hat{p}_\theta(y \mid x).$$

Ejemplos numéricos: modelo seguro y modelo inseguro

- Supón 3 clases: gato, perro, ave.
- Etiqueta verdadera: $y = (1, 0, 0)$ (gato).
- Caso A (modelo acierta con alta confianza):

$$\hat{p} = (0{,}9, 0{,}05, 0{,}05) \Rightarrow \ell_{\mathrm{CE}} = -\log 0{,}9 \approx 0{,}105.$$

- Caso B (modelo acierta pero poco confiado):

$$\hat{p} = (0{,}5, 0{,}25, 0{,}25) \Rightarrow \ell_{\mathrm{CE}} = -\log 0{,}5 \approx 0{,}693.$$

- Caso C (modelo se equivoca con mucha confianza, cree que es perro):

$$\hat{p} = (0{,}01, 0{,}98, 0{,}01) \Rightarrow \ell_{\mathrm{CE}} = -\log 0{,}01 \approx 4{,}605.$$

- **Lectura:** la cross-entropy **diferencia** fuertemente entre "equivocarse con duda" y "equivocarse con confianza".

Diferencia entre accuracy y cross-entropy

- **Accuracy:** porcentaje de ejemplos donde $\arg\max_c \hat{p}_\theta(y = c \mid x)$ coincide con la clase verdadera.
- **Problema:** no distingue entre:
  - $\hat{p} = (0{,}51, 0{,}49)$ (muy inseguro),
  - $\hat{p} = (0{,}99, 0{,}01)$ (muy seguro),

  si en ambos casos acierta la clase.
- **Cross-entropy:** premia modelos que aciertan y además asignan alta probabilidad a la clase verdadera.
- En entrenamiento, **optimizamos cross-entropy**; accuracy suele usarse como métrica de evaluación secundaria.

Derivación de la entropía como esperanza de surprisal

- Definimos información de un evento: $I(x) = -\log p(x)$.
- Para una variable aleatoria $X \sim p$, la información promedio es:

$$\mathbb{E}_p[I(X)] = \sum_x p(x)\, I(x) = \sum_x p(x)\,[-\log p(x)].$$

$$\Rightarrow \quad H(X) = -\sum_x p(x) \log p(x).$$

- **Comentario pedagógico:** enfatizar en clase que **entropía no es una fórmula mágica**, sino simplemente la esperanza de la sorpresa.

Derivación de CE en clasificación one-hot

- Partimos de la definición general de cross-entropy para una etiqueta y y una predicción $\hat{p}$:

$$\ell_{\mathrm{CE}}(y, \hat{p}) = -\sum_{c=1}^{C} y_c \log \hat{p}(c).$$

- Si la clase correcta es k, entonces $y_k = 1$ y todas las demás componentes valen 0.
- Por lo tanto, todos los términos se anulan excepto el de la clase verdadera:

$$\ell_{\mathrm{CE}}(y, \hat{p}) = -(0 + \cdots + 1 \cdot \log \hat{p}(k) + \cdots + 0).$$

$$\Rightarrow \quad \ell_{\mathrm{CE}}(y, \hat{p}) = -\log \hat{p}(k).$$

- Esta es exactamente la forma de la **negative log-likelihood** para una observación etiquetada.

Ejemplo 1 — entropía de una distribución sobre tres eventos

- $X \in \{rojo,\ azul,\ verde\}$ con:

$$p(rojo) = 0{,}1, \quad p(azul) = 0{,}2, \quad p(verde) = 0{,}7.$$

- Calcula:

$$H(X) = -\big[0{,}1 \log_2 0{,}1 + 0{,}2 \log_2 0{,}2 + 0{,}7 \log_2 0{,}7\big].$$

- Valores aproximados:

$$\log_2 0{,}1 \approx -3{,}322, \quad \log_2 0{,}2 \approx -2{,}322, \quad \log_2 0{,}7 \approx -0{,}515.$$

$$H(X) \approx -\big[0{,}1(-3{,}322) + 0{,}2(-2{,}322) + 0{,}7(-0{,}515)\big]$$
$$\approx -\big[-0{,}3322 - 0{,}4644 - 0{,}3605\big] \approx 1{,}157 \text{ bits}.$$

- **Comparar:** con la entropía de la distribución uniforme en 3 valores ($\approx 1{,}585$ bits): aquí la distribución está más concentrada, por eso la entropía es menor.

Ejemplo 2 — cross-entropy y KL entre p y q

- Sea $\mathcal{X} = \{0, 1\}$.
- Verdadera p: $\quad p(1) = 0{,}7,\ p(0) = 0{,}3.$
- Modelo q: $\quad q(1) = 0{,}4,\ q(0) = 0{,}6.$
- Entropía de p:
$$H(p) = -[0{,}7 \log_2 0{,}7 + 0{,}3 \log_2 0{,}3] \approx 0{,}881 \text{ bits.}$$
- Cross-entropy:
$$H(p, q) = -[0{,}7 \log_2 0{,}4 + 0{,}3 \log_2 0{,}6] \approx 1{,}286 \text{ bits.}$$
- KL:
$$\mathrm{KL}(p \| q) = H(p, q) - H(p) \approx 1{,}286 - 0{,}881 = 0{,}405 \text{ bits.}$$
- **Lectura:** el modelo q paga 0.405 bits extra por símbolo respecto al modelo óptimo que conoce p.

Ejemplo 3 — CE en clasificación binaria

- Clasificación binaria ($y \in \{0, 1\}$).
- Datos:
  - Ejemplo 1: $y = 1$, $\hat{p}(1 \mid x) = 0{,}9$.
  - Ejemplo 2: $y = 1$, $\hat{p}(1 \mid x) = 0{,}6$.
  - Ejemplo 3: $y = 1$, $\hat{p}(1 \mid x) = 0{,}2$.
- Loss individual:

$$\ell_1 = -\log 0{,}9 \approx 0{,}105, \quad \ell_2 = -\log 0{,}6 \approx 0{,}511, \quad \ell_3 = -\log 0{,}2 \approx 1{,}609.$$

- Loss promedio:

$$\bar{\ell} = \frac{\ell_1 + \ell_2 + \ell_3}{3} \approx \frac{0{,}105 + 0{,}511 + 1{,}609}{3} \approx 0{,}742.$$

- **Discusión para clase:** ¿qué cambio en el modelo bajaría más la loss? (hacer que el modelo deje de estar tan seguro en el ejemplo 3).

Entropía como medida de incertidumbre del modelo

- Dado un vector de probabilidades de clase $\hat{p}_\theta(\cdot \mid x)$, podemos calcular:

$$H(\hat{p}_\theta(\cdot \mid x)) = -\sum_c \hat{p}_\theta(y = c \mid x) \log \hat{p}_\theta(y = c \mid x).$$

- **Alta entropía:** el modelo está indeciso (probabilidades dispersas).
- **Baja entropía:** el modelo está muy seguro (probabilidades concentradas).
- En active learning o detección de incertidumbre, se pueden priorizar ejemplos con entropía alta.

Cross-entropy como loss natural en clasificación

- Si el dataset es una muestra iid de la distribución verdadera, la CE empírica aproxima:

$$\mathbb{E}_{(x,y)\sim p_{\text{data}}}\big[-\log \hat{p}_\theta(y \mid x)\big] \approx H(p_{\text{data}}, \hat{p}_\theta).$$

- Minimizar la CE empírica $\Rightarrow$ acercar $\hat{p}_\theta$ a p_{data} en el sentido de $\mathrm{KL}(p_{\text{data}} \| \hat{p}_\theta)$.
- **Conexión con MLE:** MLE elige θ que maximiza la probabilidad del dataset; es equivalente a minimizar la NLL o la CE promedio.
- En la práctica, esto se implementa como:

$$\min_\theta \frac{1}{N} \sum_{i=1}^{N} -\log \hat{p}_\theta(y_i \mid x_i).$$

¿Por qué aparece KL en métodos probabilísticos avanzados?

- En **variational inference**, aproximamos una distribución posterior $p(z \mid x)$ con una familia $q_\phi(z)$.
- Elegimos ϕ para que q_ϕ esté "cerca" de p, típicamente minimizando:

$$\mathrm{KL}(q_\phi(z) \| p(z \mid x)).$$

- En **VAEs** y otros modelos generativos, la función de entrenamiento incluye un término de KL que regulariza la distribución latente hacia un prior simple (ej. $\mathcal{N}(0, I)$).
- En **model distillation**, se usa KL para alinear las distribuciones de salida de un "teacher" y un "student".
- **Idea transversal:** KL es la *moneda estándar* para cuantificar "qué tan diferente" es un modelo probabilístico de otro.

Errores típicos de interpretación

- **Error 1:** pensar que entropía mide "desorden físico" en este contexto.
  Corrección: aquí es una medida de **incertidumbre** de una variable aleatoria.
- **Error 2:** creer que cross-entropy solo importa "porque funciona bien en práctica".
  Corrección: está directamente conectada con MLE y con la idea de codificación óptima.
- **Error 3:** interpretar KL como una distancia "simétrica".
  Corrección: KL no es simétrica y el orden de p y q importa mucho.
- **Error 4:** pensar que alta accuracy $\Rightarrow$ cross-entropy baja.
  Corrección: se puede tener buena accuracy pero probabilidades muy mal calibradas.

Ideas clave (Semana 6)

- **Self-information:** $I(x) = -\log p(x)$ mide cuán inesperado fue un evento.
- **Entropía:** $H(X) = \mathbb{E}[I(X)]$ es incertidumbre promedio; máxima para distribuciones uniformes.
- **Cross-entropy:** $H(p, q) = \mathbb{E}_p[-\log q]$ es el costo de codificar datos de p usando el modelo q.
- **KL divergence:** $\mathrm{KL}(p\|q) = H(p, q) - H(p)$ mide el "precio extra" por usar el modelo incorrecto.
- **Identidad clave:** $H(p, q) = H(p) + \mathrm{KL}(p\|q)$.
- **En ML:** minimizar cross-entropy $\Leftrightarrow$ hacer MLE $\Leftrightarrow$ aproximar la distribución verdadera de etiquetas.
- **Etiquetas one-hot:** la loss se reduce a $-\log$ de la probabilidad de la clase correcta.

Mapa de fórmulas clave (Information Theory)

Fórmula	**Interpretación**
$I(x) = -\log p(x)$	Sorpresa/información de un evento.
$H(X) = -\sum_x p(x) \log p(x)$	Incertidumbre promedio de X.
$H(p, q) = -\sum_x p(x) \log q(x)$	Costo de codificar datos de p con modelo q.
$\mathrm{KL}(p\|q) = \sum_x p(x) \log \frac{p(x)}{q(x)}$	Penalización por usar q en lugar de p.
$H(p, q) = H(p) + \mathrm{KL}(p\|q)$	Descomposición de cross-entropy en incertidumbre + error de modelo.
$\mathrm{NLL}(\theta) = -\frac{1}{N} \sum_i \log \hat{p}_\theta(y_i \mid x_i)$	Loss promedio en MLE; coincide con CE promedio.
$\ell_{\mathrm{CE}}(y, \hat{p}) = -\sum_c y_c \log \hat{p}(c)$	Cross-entropy entre etiqueta one-hot y distribución predicha.

Semana 6 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab NumPy — objetivo general

- Implementar $H(p) = -\sum_x p(x) \log p(x)$, $H(p,q)$ y $\mathrm{KL}(p\|q)$ en ejemplos discretos pequeños (tablas 2×1, 3×1).
- Graficar $H(\theta) = -\theta \log_2 \theta - (1-\theta) \log_2 (1-\theta)$ para $\theta \in (0,1)$ y contrastar con la figura de la sesión.

Lab NumPy — checklist (qué debe aparecer en tu notebook)

- **Funciones:** entropía de un vector de probabilidades (con chequeo $\sum p_i = 1$); cross-entropy y KL entre dos vectores alineados.
- **Casos borde:** evitar $\log 0$ (clamp o máscara); verificar $\mathrm{KL}(p\|p) = 0$ numéricamente.
- **Bernoulli:** vector θ en $(0, 1)$ y gráfico de $H(\theta)$; marcar $\theta = 0{,}5$.

Semana 6 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab sklearn — objetivo general

- Usar `sklearn.metrics.log_loss` como CE promedio (base e por defecto; documentar la base).
- Comparar con tu implementación NumPy en el mismo conjunto de etiquetas y probabilidades predichas.

Lab sklearn — checklist (estructura sugerida)

- **Datos:** un problema de clasificación pequeño (binario o multiclase) con `predict_proba`.
- **Métrica:** `log_loss(y_true, y_proba)` y desglose manual en $-\frac{1}{N}\sum_i \log \hat{p}(y_i \mid x_i)$.
- **Discusión:** por qué accuracy puede ocultar mala calibración; relacionar con slides de CE vs accuracy.

Semana 6 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Entregable — qué se evalúa

- **Slides:** definiciones claras de surprisal, entropía, CE y KL; identidad $H(p,q) = H(p) + \mathrm{KL}(p\|q)$; vínculo CE $\leftrightarrow$ NLL/MLE.
- **Notebook NumPy:** funciones de entropía / CE / KL reproducibles y gráfica de entropía Bernoulli.
- **Notebook sklearn:** `log_loss` contrastado con cálculo manual.

Cierre de la Semana 6

- Information theory proporciona el **lenguaje** para hablar de incertidumbre y de modelos probabilísticos.
- Las pérdidas estándar en clasificación (cross-entropy / NLL) no son "trucos": vienen directamente de estas ideas.
- La KL divergence reaparecerá en casi todos los métodos probabilísticos avanzados que veamos después.

Semana 7 — Álgebra lineal para Machine Learning

Proyección, mínimos cuadrados, SVD, conditioning y PCA

Curso de Machine Learning — UAQ (Matemáticas Aplicadas)

Libro base: *Probabilistic Machine Learning: An Introduction* (Kevin P. Murphy)

Semana 7

Lecturas sugeridas y ruta matemática

- **Cap. 7 — Linear Algebra**
  - **7.1.2–7.1.4** Espacios vectoriales, normas, propiedades matriciales
  - **7.4** EVD de matrices simétricas y formas cuadráticas
  - **7.5** SVD, conexión con EVD, truncación y pseudoinversa
  - **7.6.2** QR
  - **7.7.3** Sistemas sobredeterminados y mínimos cuadrados
- **Conexiones prácticas**
  - **11.2** Regresión lineal por mínimos cuadrados
  - **20.1** PCA y su derivación espectral

Ruta de la semana

modelo lineal $\to$ proyección $\to$ mínimos cuadrados $\to$ conditioning y resolución estable $\to$ SVD $\to$ PCA

Pregunta central de la semana

Dado un vector $y \in \mathbb{R}^n$ y una matriz X, queremos responder cuatro preguntas:

1. ¿Cuál es la mejor aproximación de y dentro de $\mathrm{col}(X)$?
2. ¿Qué ecuación caracteriza esa solución?
3. ¿Cómo resolverla de forma estable cuando el problema está mal condicionado?
4. ¿Qué nos revela la SVD sobre rango, energía, truncación, pseudoinversa y PCA?

Mensaje

La geometría del modelo lineal y la estructura espectral de las matrices responden a la misma pregunta: cómo aproximar y representar información en subespacios.

Semana 7 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

El modelo lineal como subespacio

- Si $X = [x_1, \ldots, x_p] \in \mathbb{R}^{n \times p}$, cualquier combinación lineal de sus columnas tiene la forma

$$Xw = w_1 x_1 + \cdots + w_p x_p.$$

- El conjunto de todas esas combinaciones es el **espacio columna**

$$\mathrm{col}(X) = \{Xw : \ w \in \mathbb{R}^p\}.$$

- Un modelo lineal no puede producir cualquier vector en $\mathbb{R}^n$: solo vectores dentro de $\mathrm{col}(X)$.

Idea central

Regresión lineal = buscar el mejor vector posible dentro de $\mathrm{col}(X)$.

Norma euclidiana y error cuadrático

- La norma euclidiana de un vector es
$$\|x\|_2 = \sqrt{x^\top x}.$$
- La distancia entre y y una predicción Xw es
$$\|y - Xw\|_2.$$
- El problema de mínimos cuadrados se formula como
$$\hat{w} = \arg\min_w \|y - Xw\|_2^2.$$

Lectura geométrica

Mínimos cuadrados es un problema de distancia mínima entre un vector y un subespacio.

Proyección ortogonal sobre una recta

Queremos proyectar y sobre la dirección de u. Buscamos a tal que au minimice

$$\|y - au\|_2^2.$$

$$f(a) = (y - au)^\top (y - au) = y^\top y - 2a\, u^\top y + a^2 u^\top u,$$
$$f'(a) = -2u^\top y + 2a\, u^\top u = 0.$$

Por tanto,

$$a = \frac{u^\top y}{u^\top u} \Rightarrow \mathrm{proj}_u(y) = \frac{u^\top y}{u^\top u}\, u.$$

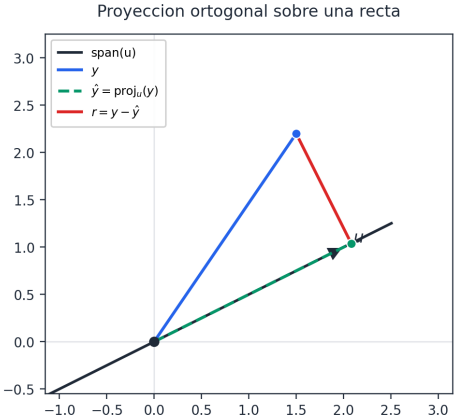

- El residual $r = y - \hat{y}$ satisface $u^\top r = 0$: el error es ortogonal a la dirección usada para aproximar.

Mínimos cuadrados como proyección sobre $\mathrm{col}(X)$

$$\hat{w} = \arg\min_{w} \|y - Xw\|_2^2, \quad \hat{y} = X\hat{w}.$$

- $\hat{y}$ es la **proyección ortogonal** de y sobre $\mathrm{col}(X)$.
- El residual $r = y - \hat{y}$ es ortogonal a todas las columnas de X.
- Por tanto, $X^\top r = 0$.

Esquema en $\mathbb{R}^3$: el plano representa $\mathrm{col}(X)$. En la práctica, el razonamiento vale en $\mathbb{R}^n$.

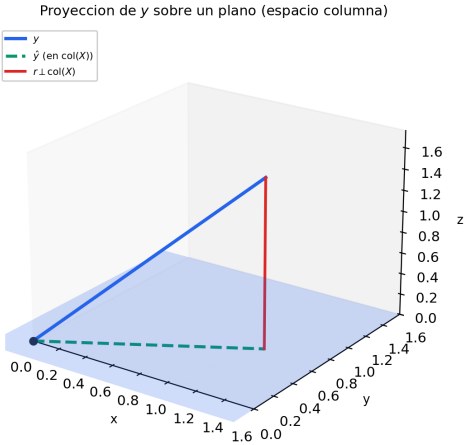

Ecuaciones normales

Como $r = y - X\hat{w}$ y $X^\top r = 0$,

$$X^\top(y - X\hat{w}) = 0 \qquad \Rightarrow \qquad X^\top X\hat{w} = X^\top y.$$

Resultado

Las ecuaciones normales caracterizan algebraicamente la proyección ortogonal de y sobre $\mathrm{col}(X)$.

También se obtiene por gradiente:

$$J(w) = \|y - Xw\|_2^2 \quad \Rightarrow \quad \nabla_w J(w) = -2X^\top y + 2X^\top Xw = 0.$$

Matriz de proyección

Si $X^\top X$ es invertible, entonces

$$\hat{w} = (X^\top X)^{-1} X^\top y, \qquad \hat{y} = X(X^\top X)^{-1} X^\top y.$$

Definimos

$$P = X(X^\top X)^{-1} X^\top.$$

Entonces

$$\hat{y} = Py.$$

- $P^\top = P$ (simétrica).
- $P^2 = P$ (idempotente).

Interpretación

P es la matriz que proyecta ortogonalmente sobre $\mathrm{col}(X)$.

Ejemplo completo de mínimos cuadrados

$$X = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad y = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}.$$

$$\hat{w} = \begin{bmatrix} 7/6 \\ 1/2 \end{bmatrix}, \ \hat{y} = \begin{bmatrix} 7/6 \\ 10/6 \\ 13/6 \end{bmatrix}, \ r = y - \hat{y} = \frac{1}{6} \begin{bmatrix} -1 \\ 2 \\ -1 \end{bmatrix}.$$

Se verifica que $X^\top r = 0$.

Lectura

La recta de regresión es la proyección ortogonal del vector de respuestas sobre el subespacio generado por las columnas de X.

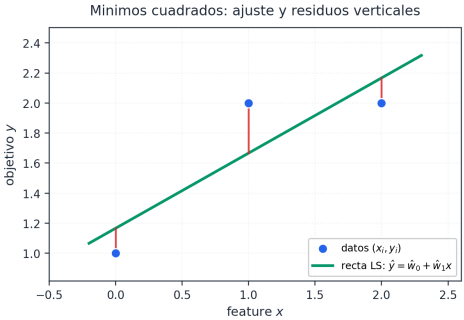

Conditioning: sensibilidad de la solución

Un problema lineal está **mal condicionado** si pequeñas perturbaciones en la entrada producen grandes cambios en la solución.

$$\kappa(A) = \frac{\sigma_{\text{máx}}(A)}{\sigma_{\text{mín}}(A)}$$

donde, en la norma 2:

- $\sigma_{\text{máx}}(A)$ es el **mayor valor singular** de A;
- $\sigma_{\text{mín}}(A)$ es el **menor valor singular no nulo** de A.
- Los σ_i miden cuánto **estira** o **comprime** la matriz en direcciones especiales.
- Si $\sigma_{\text{mín}}(A)$ es muy pequeño, una dirección casi se colapsa y el error se amplifica.

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 1{,}0001 \end{bmatrix}$$

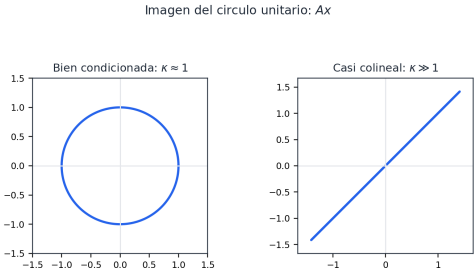

Cómo resolver mínimos cuadrados de forma estable

Queremos resolver siempre la misma pregunta:

$$\min_{w} \|y - Xw\|_2^2.$$

1. **Ecuaciones normales**
$$X^\top X w = X^\top y$$
excelentes para la intuición geométrica, pero pueden ser numéricamente delicadas.
2. **QR**
$$X = QR$$
evita formar $X^\top X$ y suele ser más estable.
3. **SVD**
$$X = U \Sigma V^\top$$
funciona incluso con rango deficiente y conduce naturalmente a la pseudoinversa.

Mensaje

No son tres problemas distintos: son tres maneras de responder la misma pregunta de mínimos cuadrados.

La descomposición singular de una matriz

Definición

Para toda matriz real $A \in \mathbb{R}^{m \times n}$ existe una factorización

$$A = U \Sigma V^{\top},$$

donde $U \in \mathbb{R}^{m \times m}$ y $V \in \mathbb{R}^{n \times n}$ son ortogonales, y $\Sigma \in \mathbb{R}^{m \times n}$ es diagonal rectangular con

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq 0.$$

- Las columnas de U son los **vectores singulares izquierdos**.
- Las columnas de V son los **vectores singulares derechos**.
- Los σ_i son los **valores singulares**.

Observación

La SVD siempre existe; la EVD no siempre existe, incluso para matrices cuadradas.

Interpretación geométrica de la SVD

La descomposición $A = U\Sigma V^\top$ se interpreta como tres pasos:

1. $V^\top$: cambia de base en el espacio de entrada;
2. Σ: estira o comprime en direcciones ortogonales especiales;
3. U: rota o refleja en el espacio de salida.

Conclusión:

Toda matriz actúa como: rotar/reflejar $\to$ escalar $\to$ rotar/reflejar.

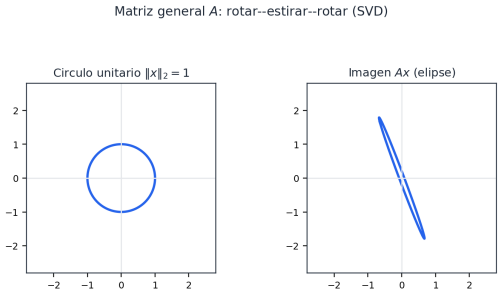

Conexión entre SVD y EVD

Si

$$A = U\Sigma V^\top,$$

entonces

$$A^\top A = V\Sigma^\top \Sigma V^\top, \qquad AA^\top = U\Sigma\Sigma^\top U^\top.$$

- Las columnas de V son eigenvectores de $A^\top A$.
- Las columnas de U son eigenvectores de $AA^\top$.
- Los eigenvalores no nulos son

$$\lambda_i = \sigma_i^2.$$

Caso especial

Si A es simétrica y definida positiva, entonces la SVD coincide con la EVD:

$$A = U\Sigma U^\top.$$

¿Por qué las columnas de V son eigenvectores de $A^\top A$?

Partimos de la SVD $A = U\Sigma V^\top$. Entonces

$$A^\top A = V\Sigma^\top U^\top U\Sigma V^\top = V\Sigma^\top \Sigma V^\top.$$

Sea v_i la columna i-ésima de V. Como V es ortogonal, $V^\top v_i = e_i$ (vector canónico). Por tanto

$$A^\top A\, v_i = V\Sigma^\top \Sigma e_i = V(\sigma_i^2 e_i) = \sigma_i^2 v_i.$$

Conclusión: v_i es eigenvector de $A^\top A$ con eigenvalor σ_i^2.
Interpretación:

- $A^\top A$ actúa en el espacio de entrada.
- Las direcciones especiales del espacio de entrada están dadas por las columnas de V.
- Por eso V aparece en la descomposición espectral de $A^\top A$.

Mensaje final

Las columnas de V diagonalizan a $A^\top A$, y sus eigenvalores son los cuadrados de los valores singulares.

Comprobación numérica: $\sigma_i^2 = \lambda_i(A^\top A)$

Sea

$$A = \begin{bmatrix} 1 & 2 \\ 0 & 2 \\ 2 & 0 \end{bmatrix}.$$

Entonces

$$A^\top A = \begin{bmatrix} 5 & 2 \\ 2 & 8 \end{bmatrix}.$$

Sus eigenvalores son

$$\lambda_1 = 9, \qquad \lambda_2 = 4.$$

Luego, los valores singulares de A son

$$\sigma_1 = 3, \qquad \sigma_2 = 2.$$

Por tanto,

$$\sigma_1^2 = 9 = \lambda_1(A^\top A), \qquad \sigma_2^2 = 4 = \lambda_2(A^\top A).$$

Mensaje

Los valores singulares de A son la raíz cuadrada de los eigenvalores de $A^\top A$.

Energía, rango y truncación

La SVD puede escribirse como suma de matrices de rango 1:

$$A = \sum_{i=1}^{r} \sigma_i u_i v_i^\top,$$

donde $r = \mathrm{rank}(A)$.

- La energía total en norma de Frobenius es

$$\|A\|_F^2 = \sum_{i=1}^{r} \sigma_i^2.$$

- La aproximación truncada de rango k es

$$A_k = \sum_{i=1}^{k} \sigma_i u_i v_i^\top.$$

- Los primeros valores singulares concentran la estructura principal de la matriz.

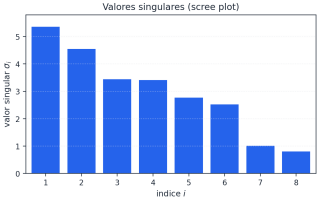

Scree plot.

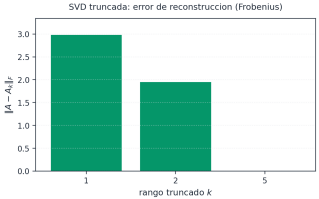

Error de reconstrucción.

Ejemplo: compresión de imágenes con SVD

Una imagen en escala de grises puede representarse como una matriz

$$X \in R^{m \times n}.$$

Aplicamos la descomposición singular:

$$X = U \Sigma V^T.$$

Si conservamos solo los primeros k valores singulares, obtenemos la aproximación truncada

$$X_k = U_{:,1:k} \Sigma_{1:k,1:k} V^T_{:,1:k}.$$

Ideas clave:

- X_k tiene rango k.
- Los primeros valores singulares capturan la estructura dominante de la imagen.
- Si la imagen tiene redundancia, puede aproximarse bien con pocos componentes.
- Esto muestra que la SVD sirve para compresión y aproximación de bajo rango.

Mensaje final

La SVD permite describir una imagen compleja usando solo unas cuantas direcciones principales.

Espectro singular y estructura de una imagen

Si graficamos los valores singulares $\sigma_1, \sigma_2, \ldots$, observamos cuánto aporta cada componente de la SVD.

Qué observar:

- En una imagen real, los valores singulares suelen decrecer relativamente rápido.
- Esto indica que gran parte de la información está concentrada en pocos modos.
- Si aleatorizamos los pixeles, la estructura geométrica se destruye.
- En ese caso, el espectro singular se vuelve menos concentrado.

Interpretación:

- El decaimiento de los valores singulares mide la complejidad efectiva de la matriz.

Mensaje final

Una matriz con estructura puede comprimirse mejor que una matriz aleatoria.

Pseudo-inversa de Moore–Penrose

La pseudo-inversa de Moore–Penrose de A, denotada por $A^\dagger$, es la **única** matriz que satisface:

$$AA^\dagger A = A, \qquad A^\dagger AA^\dagger = A^\dagger,$$

$$(AA^\dagger)^\top = AA^\dagger, \qquad (A^\dagger A)^\top = A^\dagger A.$$

- Si A es cuadrada e invertible, entonces $A^\dagger = A^{-1}$.
- Si A es **tall** $(m > n)$ y full rank en columnas,

$$A^\dagger = (A^\top A)^{-1} A^\top.$$

- Si A es **fat** $(m < n)$ y full rank en filas,

$$A^\dagger = A^\top (AA^\top)^{-1}.$$

Pseudoinversa vía SVD y lectura geométrica

Si

$$A = U\Sigma V^\top,$$

entonces

$$A^\dagger = V\Sigma^\dagger U^\top,$$

donde $\Sigma^\dagger$ invierte los valores singulares no nulos y deja en cero los demás.

- En problemas **sobredeterminados**, $A^\dagger b$ da la solución de mínimos cuadrados.
- En problemas **infradeterminados**, $A^\dagger b$ da la solución exacta de **menor norma** cuando existe.
- La pseudoinversa unifica inversa, mínimos cuadrados y rango deficiente en una sola fórmula.

Ejemplo que ya vimos

Para $A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}$ y $b = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}$,

$$A^\dagger b = \begin{bmatrix} 7/6 \\ 1/2 \end{bmatrix},$$

que coincide con el estimador OLS.

Formas cuadráticas y cociente de Rayleigh

Sea A una matriz simétrica. La forma cuadrática asociada es

$$q(v) = v^\top A v.$$

El **cociente de Rayleigh** de A en una dirección $v \neq 0$ es

$$R_A(v) = \frac{v^\top A v}{v^\top v}.$$

Si además $\|v\| = 1$, entonces $R_A(v) = v^\top A v$.

Resultado fundamental

Si A es simétrica, el máximo de $R_A(v)$ se alcanza en un eigenvector del mayor eigenvalor, y el mínimo en un eigenvector del menor eigenvalor.

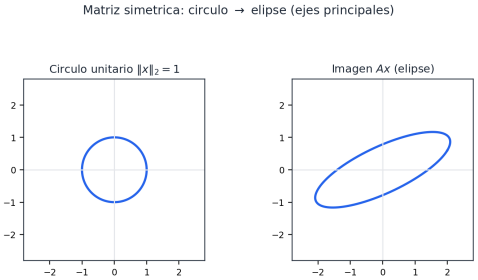

Ejemplo simétrico 2×2

Sea

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

Entonces

$$q(v) = v^\top A v = 2v_1^2 + 2v_2^2 + 2v_1 v_2.$$

Sus eigenpares son:

$$\lambda_1 = 3, \quad q_1 = \tfrac{1}{\sqrt{2}}(1,1)^\top, \quad \lambda_2 = 1, \quad q_2 = \tfrac{1}{\sqrt{2}}(1,-1)^\top.$$

Sobre la esfera unitaria,

$$\text{máx}\, q(v) = 3 \text{ en } q_1, \quad \text{mín}\, q(v) = 1 \text{ en } q_2.$$

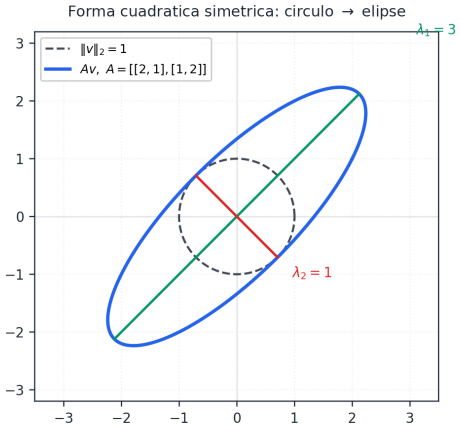

PCA como problema espectral

Sea X_c la matriz de datos centrada. PCA busca la dirección unitaria que maximiza la varianza proyectada:

$$\max_{\|v\|=1} v^\top X_c^\top X_c v.$$

Con multiplicadores de Lagrange,

$$\mathcal{L}(v, \lambda) = v^\top X_c^\top X_c v - \lambda(v^\top v - 1)$$

implica

$$X_c^\top X_c v = \lambda v.$$

- Las componentes principales son eigenvectores de $X_c^\top X_c$.
- El mayor eigenvalor corresponde a la primera componente principal.

PCA y SVD de datos centrados

Si

$$X_c = U\Sigma V^\top,$$

entonces

$$X_c^\top X_c = V\Sigma^\top \Sigma V^\top.$$

Por tanto:

- las columnas de V son las **direcciones principales**;
- la varianza explicada está asociada a σ_i^2 (salvo factores de escala como n o $n-1$);
- PCA es la aplicación estadística más importante de la estructura espectral vista en esta semana.

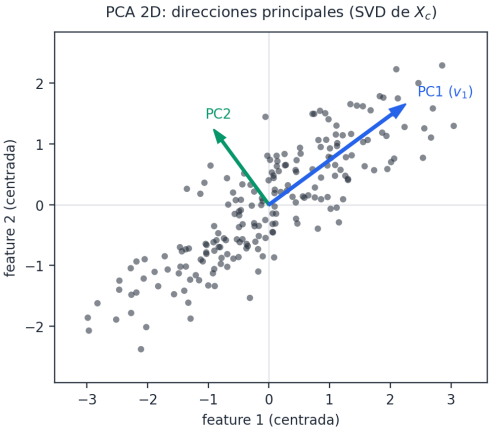

Cierre de la semana

- **Proyección, mínimos cuadrados y regresión lineal** describen el mismo objeto geométrico.
- **Conditioning** explica cuándo una solución es sensible al ruido y por qué conviene resolver con QR o SVD.
- **SVD** organiza la matriz en modos ortogonales, cuantifica energía, permite truncar y define la pseudoinversa.
- **Formas cuadráticas, cociente de Rayleigh y EVD** preparan el camino hacia **PCA**.

Detrás de muchos algoritmos de machine learning hay una misma idea: representar, aproximar y descomponer información en espacios lineales.

Semana 7 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab NumPy — Actividad 1: proyección en una dirección

- Fijar $u, y \in \mathbb{R}^d$; calcular
$$\hat{y} = \frac{u^\top y}{u^\top u} u, \qquad r = y - \hat{y}.$$
- Verificar numéricamente que $u^\top r \approx 0$.

Lab NumPy — Actividad 2: mínimos cuadrados del ejemplo de clase

- Construir X y y del ejemplo; calcular $X^\top X$, $X^\top y$, $\hat{w}$, $\hat{y}$ y r.
- Verificar $X^\top r \approx 0$.
- Comparar con `numpy.linalg.lstsq`.

Lab NumPy — Actividades 3–4: SVD y conditioning

- **SVD:** usar `np.linalg.svd`, reconstruir A y aproximarla por A_k; medir error Frobenius.
- **Conditioning:** comparar matrices bien y mal condicionadas con `np.linalg.cond`; perturbar b en $Ax = b$ y observar el efecto sobre la solución.

Lab NumPy — Pseudocódigo: compresión de imágenes con SVD

Pseudocódigo (guía conceptual)

1. Cargar una imagen en escala de grises y representarla como una matriz X.
2. Calcular la SVD:
$$X = U\Sigma V^T.$$
3. Elegir varios valores de k, por ejemplo:
$$k \in \{1, 2, 5, 10, 20, 50, 100\}.$$
4. Para cada k, construir la aproximación truncada:
$$X_k = U_{:,1:k}\Sigma_{1:k,1:k}V^T_{:,1:k}.$$
5. Visualizar cada reconstrucción y comparar la pérdida de detalle.
6. Graficar los primeros valores singulares para observar su decaimiento.
7. Aleatorizar los pixeles de la imagen, recalcular la SVD y comparar el espectro singular con el de la imagen original.
8. Concluir qué relación hay entre:
   - estructura de la matriz,
   - rapidez del decaimiento espectral,
   - calidad de la compresión.

Preguntas para discutir en laboratorio

- ¿Por qué una imagen real puede comprimirse bien con pocos componentes?
- ¿Qué cambia cuando se destruye la estructura espacial de los pixeles?
- ¿Qué información nos da el espectro singular sobre la complejidad de la matriz?
- ¿Cómo conecta este experimento con PCA y reducción de dimensión?

Interpretación matemática

El experimento conecta la aproximación de bajo rango

$$X_k = \sum_{i=1}^{k} \sigma_i u_i v_i^\top$$

con la concentración espectral: cuando σ_i decae rápido, la energía

$$\|X\|_F^2 = \sum_i \sigma_i^2$$

se preserva con pocos términos y la compresión mantiene estructura relevante.

Semana 7 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab sklearn — Regresión lineal y PCA

- `LinearRegression`: comparar coeficientes con la solución cerrada de mínimos cuadrados.
- `PCA`: interpretar `components_` y `explained_variance_ratio_` a la luz de la SVD de X_c.

Preguntas guía para la discusión

- ¿Qué significa proyectar ortogonalmente?
- ¿Por qué el residual en LS es ortogonal a $\mathrm{col}(X)$?
- ¿Qué indica un valor singular grande frente a uno casi nulo?
- ¿Qué nos dice un número de condición grande sobre la estabilidad del problema?
- ¿Por qué PCA se conecta con eigenvectores de $X_c^\top X_c$ y con la SVD de X_c?

Semana 9 — Regresión lineal y regularización

OLS, Ridge, Lasso, Elastic Net, generalización y laboratorios NumPy/sklearn

Curso de Machine Learning — UAQ (Matemáticas Aplicadas)

Libro base: *Probabilistic Machine Learning: An Introduction* (Kevin P. Murphy)

Semana 9

Temario de la Semana 9

1. **Teoría:** modelo lineal, mínimos cuadrados, solución cerrada, descenso por gradiente, Ridge, Lasso, Elastic Net y tradeoff sesgo–varianza.
2. **Lab NumPy:** OLS con solución cerrada y con GD; Ridge en forma cerrada; Lasso con subgradiente simple.
3. **Lab sklearn:** `LinearRegression`, `Ridge`, `Lasso`, `ElasticNet` + validación cruzada.
4. **Entregable:** notebooks reproducibles, figuras mínimas e interpretación breve.

Secciones recomendadas (PML = Murphy)

- **Cap. 11 — Linear Regression**
  - **11.1** Modelo e interpretación de coeficientes
  - **11.2** Mínimos cuadrados, ecuaciones normales, geometría y buenas prácticas numéricas
  - **11.3** Ridge (regularización ℓ_2)
  - **11.4** Lasso (ℓ_1), *soft thresholding*, camino de regularización, Elastic Net (**11.4.8**)
- **Cap. 4: 4.5** regularización y CV; **4.7.6** bias–variance tradeoff
- **Cap. 8: 8.2** métodos de primer orden; **8.4.2** SGD en regresión lineal
- **Puente Semana 7: 7.7.3** sistemas sobredeterminados (misma geometría de LS)

Convención de símbolos

En estas diapositivas: n observaciones, d features, X diseño, y targets, w coeficientes, b intercepto, λ regularización. En Murphy suele escribirse N y D; las fórmulas son las mismas.

Pregunta central de la semana

Esta semana gira alrededor de tres preguntas:

1. ¿Cómo ajustamos un modelo lineal de manera estable?
2. ¿Qué pasa cuando la solución de mínimos cuadrados se vuelve sensible o inestable?
3. ¿Cómo ayuda la regularización a mejorar la generalización?

Mensaje central

Minimizar el error en entrenamiento no siempre basta.
En ML también queremos que el modelo funcione bien **fuera de muestra**.

Semana 9 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Apertura: por qué seguimos estudiando regresión lineal

- No solo sirve como baseline. Es el lugar natural para entender:
  - función de pérdida,
  - optimización,
  - interpretación de parámetros,
  - regularización,
  - generalización.
- Muchos modelos más complejos conservan esta misma lógica (hasta redes neuronales terminan con una capa lineal).
- Conecta con la Semana 7: mínimos cuadrados es un problema de **proyección ortogonal** sobre el espacio columna de la matriz de diseño.

Modelo lineal y notación

- n: observaciones; d: features.
- $X \in \mathbb{R}^{n \times d}$: matriz de diseño (cada fila = una observación).
- $y \in \mathbb{R}^n$: *targets* (lo que queremos predecir).
- $w \in \mathbb{R}^d$: coeficientes; $b \in \mathbb{R}$: intercepto.
- $\hat{y} = Xw + b\,\mathbf{1}_n$: predicciones.
- $r = y - \hat{y}$: residuos.
- $\lambda \geq 0$: fuerza de regularización.

Forma ampliada

$$\tilde{X} = [\,\mathbf{1}_n \mid X\,] \in \mathbb{R}^{n \times (d+1)}, \quad \theta = \begin{bmatrix} b \\ w \end{bmatrix}, \quad \hat{y} = \tilde{X}\theta.$$

La idea es simple: aproximar y como combinación lineal de las features, más un término constante.

¿Qué minimiza mínimos cuadrados?

Queremos los coeficientes que hagan pequeñas las diferencias entre lo observado y lo predicho.

Definimos la función objetivo:

$$J(\theta) = \|y - \tilde{X}\theta\|_2^2 = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2.$$

Penalizamos más los errores grandes porque los elevamos al cuadrado.

Intuitivamente: entre todos los hiperplanos posibles, buscamos el que deje los residuos lo más pequeños posible en conjunto.

Intuición geométrica

Resolver mínimos cuadrados equivale a **proyectar** el vector y sobre el espacio generado por las columnas de X.

- $\hat{y}$ vive dentro de $\mathrm{col}(X)$.
- El residuo $r = y - \hat{y}$ queda **ortogonal** a ese espacio.

Esta es la conexión natural con la semana de álgebra lineal: mínimos cuadrados no es solo una fórmula, también es un **problema de proyección**.

Ecuaciones normales y solución cerrada

Derivando J e igualando a cero:

$$X^\top X\, w = X^\top y \qquad \Rightarrow \qquad \hat{w} = (X^\top X)^{-1} X^\top y.$$

- Elegante y conceptualmente importante.
- Pero si $X^\top X$ está **mal condicionada**, invertir directamente amplifica errores.
- En la práctica, conviene usar `np.linalg.lstsq`, QR o SVD.

Ejemplo: recta ajustada y residuos

Un ejemplo sencillo: datos 1D con ruido, recta ajustada y segmentos verticales que muestran los residuos.

La meta es ver que "ajustar una recta" realmente significa minimizar el tamaño conjunto de esos errores.

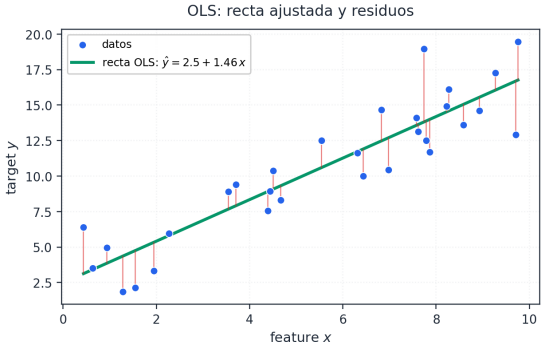

Métricas básicas de ajuste

Una vez ajustado el modelo, resumimos su desempeño con:

- **MSE / RMSE:** tamaño típico del error.
- R^2**:** qué proporción de la variabilidad observada explica el modelo.

Y con gráficos de diagnóstico:

- predicción vs. realidad,
- residuos vs. predicción,
- pérdida vs. iteración (en gradient descent).

La idea no es memorizar fórmulas, sino entender qué nos dice cada métrica.

Descenso por gradiente

Aunque existe solución cerrada, GD introduce la lógica de **entrenamiento iterativo** que aparece en muchos otros modelos.
Para $\mathcal{L}(\theta) = \frac{1}{n}\|y - \tilde{X}\theta\|_2^2$:

$$\nabla_\theta \mathcal{L} = \frac{2}{n}\tilde{X}^\top(\tilde{X}\theta - y), \qquad \theta \leftarrow \theta - \eta\,\nabla_\theta \mathcal{L}.$$

Tres ideas clave:

1. El **learning rate** η controla la velocidad del paso.
2. Si η es demasiado grande, el algoritmo puede oscilar o divergir.
3. Escalar features importa mucho en la práctica.

GD en acción: pérdida vs. iteración

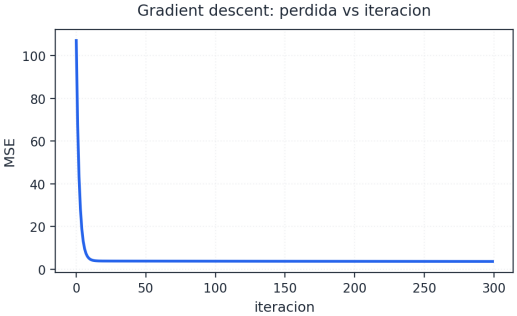

Convergencia estable con η razonable

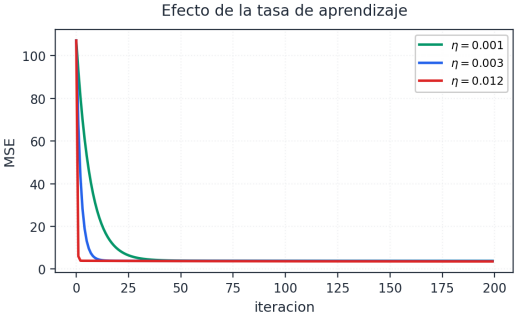

Efecto de la tasa de aprendizaje

¿Por qué aparece la regularización?

Mínimos cuadrados busca el mejor ajuste, pero la solución puede ser **inestable**.

Esto pasa cuando:

- hay features muy correlacionadas,
- hay muchas variables respecto al tamaño de muestra,
- el modelo empieza a capturar ruido,
- pequeños cambios en los datos producen cambios grandes en w.

La regularización añade una **penalización** para controlar la complejidad del modelo.

Ridge: penalización ℓ_2

Ridge agrega un término que penaliza coeficientes grandes:

$$J_{\text{Ridge}}(w) = \|y - Xw\|_2^2 + \lambda \|w\|_2^2.$$

- **Encoge** coeficientes (pero no los lleva a cero).
- Mejora **estabilidad numérica**.
- Ayuda especialmente con **multicolinealidad**.
- Reduce varianza a costa de introducir algo de sesgo.

Importante: normalmente **no** se penaliza el intercepto b.

Solución cerrada de Ridge

La solución también se escribe en forma cerrada:

$$\hat{w}_{\text{Ridge}} = (X^\top X + \lambda I)^{-1} X^\top y.$$

El término λI modifica el problema para hacerlo más estable.

- $\lambda = 0$: recuperamos OLS.
- λ grande: coeficientes tienden a encogerse hacia cero.

Ridge: OLS vs. coeficientes estabilizados

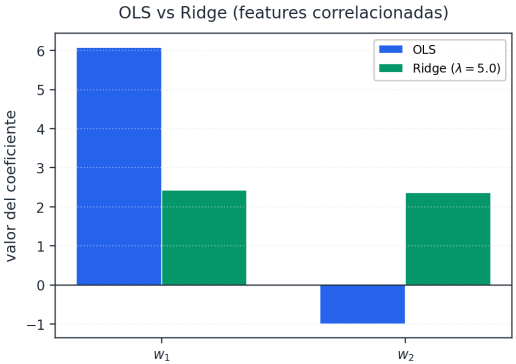

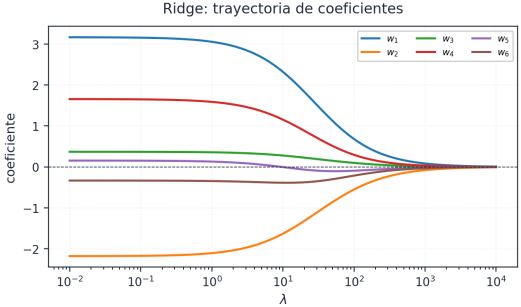

Al aumentar λ, los coeficientes se encogen

Con features correlacionadas, OLS explota; Ridge estabiliza

Elegir λ

La fuerza de regularización no se elige "a ojo".

En la práctica, λ se trata como un **hiperparámetro** y se elige con **validación cruzada**.

La idea es balancear dos cosas:

- ajustar bien los datos de entrenamiento,
- no hacer el modelo demasiado flexible.

Recorrer varios valores de λ en escala logarítmica y comparar desempeño en validación.

Lasso: penalización ℓ_1 y esparcidad

Lasso usa penalización ℓ_1 en lugar de ℓ_2:

$$J_{\text{Lasso}}(w) = \|y - Xw\|_2^2 + \lambda\|w\|_1, \qquad \|w\|_1 = \sum_{j=1}^{d} |w_j|.$$

La diferencia conceptual importante:

- **Ridge** encoge coeficientes.
- **Lasso** puede encogerlos **hasta cero**.

Esto vuelve a Lasso especialmente interesante cuando sospechamos que solo unas cuantas features son realmente relevantes.

¿Por qué Lasso puede producir ceros?

La penalización ℓ_1 tiene **esquinas** en los ejes. Geométricamente, cuando "crecemos" la bola ℓ_1 hasta que toque la superficie de nivel de la loss, es muy probable que el contacto ocurra en una esquina.

Las esquinas corresponden a **soluciones con algunos** $w_j = 0$.

- Ridge tiende a **repartir** el peso entre variables correlacionadas.
- Lasso tiende a **concentrarlo** y puede apagar variables.

Lasso: comparación de coeficientes (verdad dispersa)

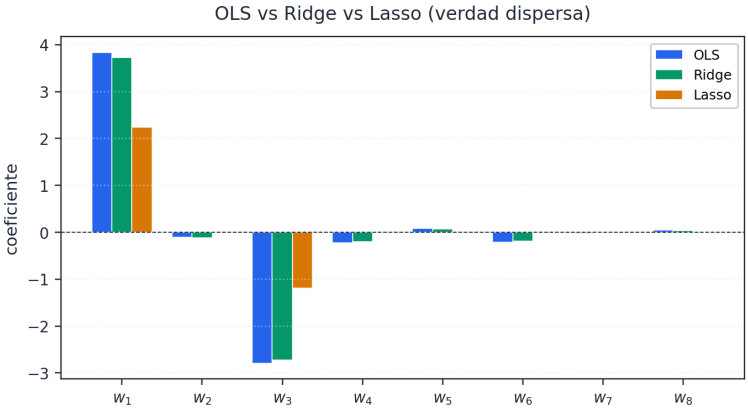

Solo w_1 y w_3 son relevantes. Lasso las identifica; OLS reparte ruido en todas.

Lasso desde cero: idea de subgradiente

A diferencia de OLS y Ridge, Lasso no tiene una fórmula cerrada general cómoda.

Para fines didácticos, basta una implementación simple con **subgradiente**: se modifica la regla de actualización añadiendo $\lambda \operatorname{sign}(w)$.

- En la práctica hay algoritmos más robustos (*coordinate descent*, *ISTA*/*FISTA*).
- Pero la versión simple ayuda a entender qué está cambiando en el objetivo.

Elastic Net

Elastic Net combina las dos ideas:

$$J(w) = \|y - Xw\|_2^2 + \lambda_1 \|w\|_1 + \lambda_2 \|w\|_2^2.$$

Es un punto intermedio entre Ridge y Lasso.

Útil cuando:

- queremos algo de esparcidad,
- pero también necesitamos estabilizar variables correlacionadas.

Mensaje corto: Elastic Net mezcla selección y estabilidad.

Bias–variance tradeoff

- Si el modelo es demasiado flexible: baja *bias*, alta *variance*.
- Si lo regularizamos mucho: reducimos *variance*, pero podemos subir *bias*.

La meta no es el modelo más complejo ni el más simple, sino el que mejor **generaliza**.

La regularización se entiende directamente desde este tradeoff: controlamos complejidad para mejorar desempeño fuera de muestra.

Intuición visual: complejidad y generalización

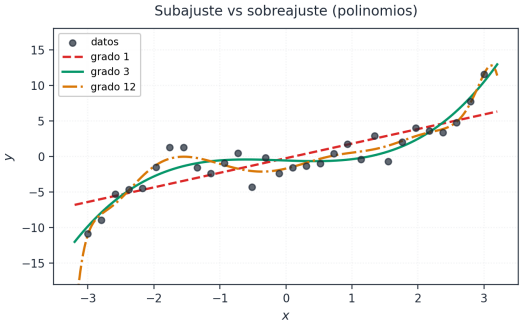

Poca complejidad: se queda corto.
Mucha: sobreajusta.

λ grande $\approx$ modelo más simple (más sesgo, menos varianza).

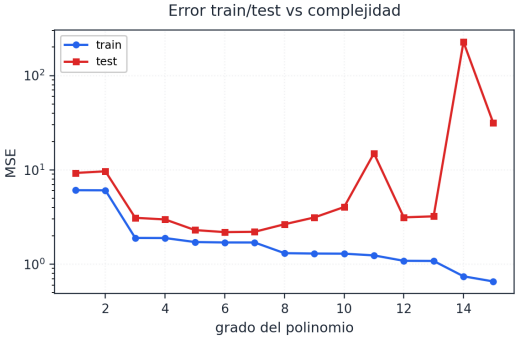

Error train/test vs. grado del polinomio

Resumen teórico (antes del laboratorio)

Ideas que deben quedar claras:

- OLS ajusta por mínimos cuadrados (proyección).
- La solución cerrada es útil pero puede ser numéricamente delicada.
- Gradient descent introduce la lógica de optimización iterativa.
- **Ridge** estabiliza mediante penalización ℓ_2.
- **Lasso** puede inducir esparcidad mediante penalización ℓ_1.
- **Elastic Net** combina ambas ideas.
- La regularización es **control de complejidad**, directamente ligado al tradeoff sesgo–varianza.

Semana 9 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab NumPy — Actividad 1: OLS con solución cerrada

Objetivo: implementar mínimos cuadrados desde cero.

- Generar un dataset lineal simple con ruido.
- Formar $\tilde{X}$ con columna de unos.
- Calcular $\hat{\theta}$ con la forma cerrada o con `lstsq`.
- Verificar que $\tilde{X}^\top r \approx 0$.
- Graficar puntos, recta ajustada y residuos.

Qué deben observar: los coeficientes estimados se acercan a los valores verdaderos; el residuo no desaparece si hay ruido.

Pseudocódigo — OLS cerrado

Pseudocódigo (guía conceptual)

1. Fijar semilla (`rng = np.random.default_rng(42)`).
2. Generar n puntos: $x \sim \mathrm{Uniform}(0, 10)$; $y = b_{\mathrm{true}} + w_{\mathrm{true}}\, x + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \sigma^2)$.
3. Construir $\tilde{X} = [\,\mathbf{1}_n \mid x\,] \in \mathbb{R}^{n \times 2}$.
4. Calcular:
$$\hat{\theta} = (\tilde{X}^\top \tilde{X})^{-1} \tilde{X}^\top y \quad \text{o bien} \quad \hat{\theta} = \texttt{np.linalg.lstsq}(\tilde{X},\, y).$$
5. Obtener $\hat{y} = \tilde{X}\hat{\theta}$, $r = y - \hat{y}$.
6. Verificar numéricamente que $\tilde{X}^\top r \approx 0$.
7. Graficar: scatter de (x, y) + recta $\hat{y}$ + segmentos verticales de residuos.
8. Comparar $(\hat{b}, \hat{w})$ con los valores verdaderos usados para generar los datos.

Lab NumPy — Actividad 2: OLS con gradient descent

Objetivo: resolver el mismo problema con entrenamiento iterativo.

- Inicializar θ en cero.
- Implementar pérdida y gradiente; actualizar por iteraciones.
- Guardar la pérdida a lo largo del entrenamiento.
- Explorar η: convergencia vs. divergencia.
- Estandarizar columnas y observar el efecto en η usable.

Qué deben observar: la pérdida baja cuando η es razonable; la solución final se acerca a la forma cerrada.

Pseudocódigo — Gradient descent para OLS

Pseudocódigo (guía conceptual)

1. Usar el mismo $\tilde{X}$ e y de la actividad anterior.
2. Inicializar $\theta \leftarrow \mathbf{0} \in \mathbb{R}^{d+1}$.
3. Elegir tasa de aprendizaje η y número de iteraciones T.
4. **Para** $t = 1, \ldots, T$:
    1. Calcular residuo: $r \leftarrow \tilde{X}\theta - y$.
    2. Calcular gradiente: $g \leftarrow \frac{2}{n}\tilde{X}^\top r$.
    3. Actualizar: $\theta \leftarrow \theta - \eta g$.
    4. Guardar la pérdida: $\mathcal{L}^{(t)} \leftarrow \frac{1}{n}\|r\|_2^2$.
5. Graficar $\mathcal{L}^{(t)}$ vs. t (curva de convergencia).
6. Comparar θ final con la solución cerrada de la actividad 1.
7. Repetir con η más grande y más pequeño; observar divergencia vs. convergencia lenta.

Lab NumPy — Actividad 3: Ridge en forma cerrada

Objetivo: ver el efecto estabilizador de la regularización ℓ_2.

- Construir dos features muy correlacionadas (x y $x + \varepsilon$).
- Ajustar OLS y Ridge.
- Barrer λ en escala log y comparar coeficientes.

Qué deben observar: OLS produce coeficientes grandes e inestables; Ridge los reduce.

Pseudocódigo — Ridge cerrado

Pseudocódigo (guía conceptual)

1. Generar $x_1 \sim \mathcal{N}(0,1)$ de tamaño n.
2. Crear feature casi idéntica: $x_2 = x_1 + \varepsilon,\ \ \varepsilon \sim \mathcal{N}(0, 0{,}05)$.
3. Construir target: $y = w_1^{\text{true}} x_1 + w_2^{\text{true}} x_2 + \text{ruido}$.
4. Centrar X e y (restar medias).
5. Calcular OLS: $\hat{w}_{\text{OLS}} = (X^\top X)^{-1} X^\top y$.
6. Para varios λ en `np.logspace(-2, 4, 50)`:

$$\hat{w}_{\text{Ridge}}(\lambda) = (X^\top X + \lambda I)^{-1} X^\top y.$$

7. Graficar trayectoria de $\hat{w}_j(\lambda)$ vs. λ (escala log en x).
8. Comparar barras de coeficientes: OLS vs. Ridge para un λ intermedio.

Lab NumPy — Actividad 4: Lasso con subgradiente simple

Objetivo: entender por qué ℓ_1 puede producir soluciones dispersas.

- Generar datos donde solo 1–2 variables sean relevantes (el resto ruido).
- Implementar descenso por subgradiente: gradiente cuadrático $+ \lambda \operatorname{sign}(w)$.
- Comparar patrón de coeficientes con OLS y Ridge.

Qué deben observar: Lasso deja coeficientes muy pequeños o nulos en variables irrelevantes; el escalado importa.

Pseudocódigo — Lasso con subgradiente

Pseudocódigo (guía conceptual)

1. Generar $X \in \mathbb{R}^{n \times d}$ con $d = 8$ features gaussianas.
2. Fijar verdad dispersa: $w^{\text{true}} = (4, 0, -3, 0, 0, 0, 0, 0)$.
3. Target: $y = Xw^{\text{true}} + \text{ruido}$. Centrar X e y.
4. Inicializar $w \leftarrow \mathbf{0}$. Elegir η pequeño, $\lambda > 0$, T iteraciones.
5. **Para** $t = 1, \ldots, T$:
   1. Gradiente cuadrático: $g_{\text{LS}} \leftarrow \frac{2}{n} X^\top (Xw - y)$.
   2. Subgradiente ℓ_1: $s \leftarrow \operatorname{sign}(w)$ (con $\operatorname{sign}(0) = 0$).
   3. Actualizar: $w \leftarrow w - \eta\,(g_{\text{LS}} + \lambda\, s)$.
6. Comparar $\hat{w}_{\text{Lasso}}$ con $\hat{w}_{\text{OLS}}$ y $\hat{w}_{\text{Ridge}}$ (gráfica de barras).
7. Observar qué coeficientes quedan cerca de cero en Lasso.

Semana 9 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Lab sklearn — Modelos y pipeline

Objetivo: llevar las ideas teóricas a herramientas estándar.

Modelos: `LinearRegression`, `Ridge`, `Lasso`, `ElasticNet`.

Flujo recomendado:

1. Separar train / validation / test.
2. Escalar features dentro de un `Pipeline` (`StandardScaler`).
3. Entrenar varios modelos.
4. Comparar métricas en validación (RMSE, MAE, R^2).

Importante: el escalado debe ajustarse **solo** con train para evitar fuga de información.

Lab sklearn — Selección de hiperparámetros

Aquí entra la **validación cruzada**.

- `RidgeCV`, `LassoCV`, `ElasticNetCV`.
- O `GridSearchCV` si se quiere más control.

La idea no es solo correr modelos, sino **justificar** la elección de `alpha` con un criterio claro de validación.

Pseudocódigo — Pipeline + CV con sklearn

Pseudocódigo (guía conceptual)

1. Cargar o generar un dataset con $d \geq 4$ features (ej. `make_regression`).
2. Dividir en train/test con `train_test_split`.
3. Definir un `Pipeline`:
   1. `StandardScaler` (ajustar solo en train).
   2. Modelo: `Ridge(alpha=...)` o `Lasso(alpha=...)`.
4. Para selección automática de α, usar `RidgeCV` o `LassoCV` con una rejilla:

$$\alpha \in \texttt{np.logspace(-3, 3, 50)}.$$

5. Entrenar con `pipe.fit(X_train, y_train)`.
6. Evaluar en test: calcular RMSE, MAE y R^2 con `sklearn.metrics`.
7. Repetir para `LinearRegression`, `Ridge`, `Lasso`, `ElasticNet`.
8. Construir una tabla comparativa de métricas por modelo.

Lab sklearn — Interpretación de coeficientes

Con features escaladas, las magnitudes de `coef_` se vuelven más comparables.

Comparar:

- ¿Qué hace OLS?
- ¿Qué hace Ridge?
- ¿Qué variables sobrevivieron en Lasso?
- ¿Qué efecto tuvo `alpha` en la estabilidad?

Opcional: contrastar `coef_` e `intercept_` con la solución NumPy en un toy pequeño.

Pseudocódigo — Comparación de coeficientes

Pseudocódigo (guía conceptual)

1. Tras entrenar los 4 modelos (OLS, Ridge, Lasso, ElasticNet) con features escaladas:
2. Extraer `model.coef_` e `model.intercept_` de cada uno.
3. Construir un `DataFrame` con columnas = features y filas = modelos.
4. Graficar barras agrupadas: una barra por feature, un color por modelo.
5. Observar:
   - ¿Cuáles features lleva Lasso a cero?
   - ¿Cuánto encoge Ridge respecto a OLS?
   - ¿Qué hace ElasticNet comparado con los otros dos regularizados?
6. En un toy pequeño ($d = 2$), verificar numéricamente que `model.coef_` coincide con la solución cerrada de NumPy.
7. Reportar el `alpha_` óptimo encontrado por `LassoCV` / `RidgeCV`.

Semana 9 — mapa del temario (progreso)

- **Teoría**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**

Entregable — qué debe incluirse

- **Notebook NumPy:** OLS cerrado + GD + Ridge + Lasso (subgradiente); figuras mínimas (pérdida, coeficientes).
- **Notebook sklearn:** pipelines + CV + tabla de métricas por modelo; `alpha` elegido con criterio claro.
- **Texto breve:** 5–8 oraciones enlazando inestabilidad OLS, efecto de λ y sesgo–varianza.

Cierre de la semana

La regresión lineal no solo sirve para ajustar una recta.

También sirve para entender:

- cómo se formula un problema de aprendizaje,
- cómo se optimiza una función objetivo,
- cómo aparece la inestabilidad,
- por qué regularizar puede mejorar generalización.

No se trata solo de reducir error en entrenamiento, sino de entender ***qué tipo de solución queremos*** *y por qué.*

Ref.: Kevin P. Murphy, *Probabilistic Machine Learning: An Introduction* (MIT Press; versión online 2025).

Semana 11 — Logistic Regression

De una recta de regresion a una frontera de decision probabilistica

Curso de Machine Learning — UAQ (Matematicas Aplicadas)

Libro base: *Probabilistic Machine Learning: An Introduction* (Kevin P. Murphy)

Semana 11

Mapa de la Semana 11

1. Por que regresion lineal no es ideal para clasificacion.
2. Clasificacion binaria y fronteras de decision.
3. Score lineal y funcion sigmoid.
4. Logistic regression como modelo probabilistico.
5. Cross-entropy como negative log-likelihood.
6. Optimizacion con gradient descent.
7. Regularizacion y estandarizacion.
8. Clasificacion multiclase con softmax.
9. Labs NumPy y sklearn.
10. Entregable.

Convencion de notacion

- $x_i \in \mathbb{R}^d$: vector de *features* de la observacion i.
- $X \in \mathbb{R}^{n \times d}$: matriz de diseno (una fila por observacion).
- $y_i \in \{0, 1\}$: *etiqueta* real; $y \in \{0, 1\}^n$.
- $w \in \mathbb{R}^d$: coeficientes; $b \in \mathbb{R}$: intercepto.
- $z_i = x_i^\top w + b$: *score lineal*.
- $\hat{p}_i = \sigma(z_i)$: *probabilidad predicha* para la clase 1.
- $\lambda \geq 0$: fuerza de regularizacion; $\eta > 0$: tasa de aprendizaje.

En Murphy suele aparecer N y D en lugar de n y d; las formulas son las mismas.

Semana 11 — mapa del temario (progreso)

- **Teoria**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**
- **Apendice**

¿Donde estamos en el curso?

En las semanas anteriores usamos **modelos lineales** para predecir una variable continua:

$$\hat{y} = x^\top w + b.$$

Ahora la variable objetivo ya no es un numero real cualquiera, sino una **clase**:

$$y \in \{0, 1\}.$$

Definicion

Clasificacion binaria: tarea supervisada en la que la variable objetivo toma solo dos valores.

Ejemplos: default / no default, fraude / no fraude, incendio / no incendio, spam / no spam.

Un dataset de clasificacion binaria en 2D

Cada punto es una observacion con dos features (x_1, x_2) y una etiqueta $y \in \{0, 1\}$.

Buscamos una regla que, dado un nuevo (x_1, x_2), decida si corresponde a clase 0 o clase 1.

La *frontera de decision* es la linea que separa las zonas donde el modelo predice una clase u otra.

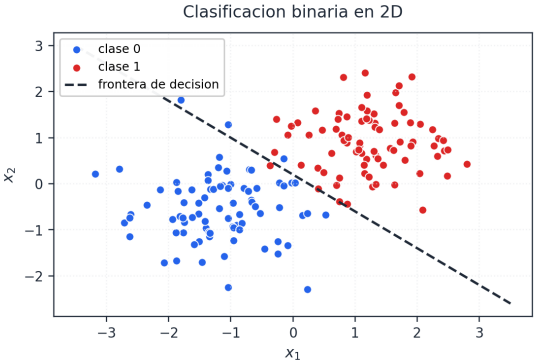

¿Y si usamos regresion lineal directamente?

Definicion

Regresion lineal para clasificacion: idea ingenua de ajustar $\hat{y} = x^\top w + b$ a las etiquetas $0/1$ y luego umbralizar a una clase.

Regla tentativa:

$$\hat{y} \geq 0{,}5 \Rightarrow \text{clase } 1, \qquad \hat{y} < 0{,}5 \Rightarrow \text{clase } 0.$$

Problema: $\hat{y}$ no esta restringido a $[0, 1]$. Puede valer $-0{,}3$ o $1{,}4$, y entonces no se puede interpretar como **probabilidad**.

Por que falla regresion lineal aqui

- La recta pasa por los puntos $0/1$ sin restriccion.
- Basta un grupo de observaciones con x grande para **empujar** la recta fuera de $[0, 1]$.
- Las zonas sombreadas muestran valores que ya no son probabilidades validas.

Queremos algo distinto: que la salida del modelo viva **naturalmente** en $[0, 1]$.

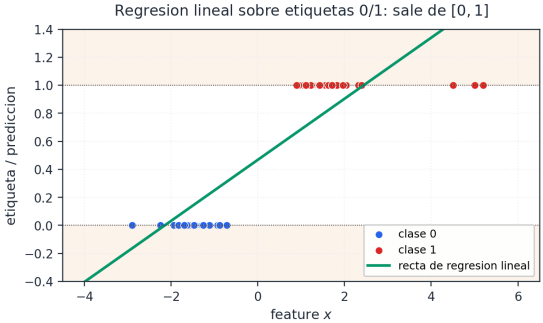

De score lineal a probabilidad

Definicion

Score lineal: combinacion lineal de las features de una observacion,

$$z = x^\top w + b.$$

¿Que significa cada simbolo?

- x: vector de features de la observacion.
- w: coeficientes (direccion e importancia de cada feature).
- b: intercepto (desplaza la frontera).
- z: score, un numero real (puede ser negativo, cero, positivo, muy grande, muy pequeno).

Mensaje: z vive en $\mathbb{R}$. Necesitamos **aplastar** z dentro de $[0, 1]$ para interpretarlo como probabilidad.

La funcion sigmoid

Definicion

Sigmoid (funcion logistica):

$$\sigma(z) = \frac{1}{1 + e^{-z}}.$$

Transforma cualquier $z \in \mathbb{R}$ en un valor en $(0, 1)$.

Propiedades:

- $\sigma(z) \in (0, 1)$ siempre.
- $\sigma(z) \to 1$ si $z \to +\infty$.
- $\sigma(z) \to 0$ si $z \to -\infty$.
- $\sigma(0) = 0{,}5$.
- Es **monotona creciente**: mas score $\Rightarrow$ mas probabilidad.

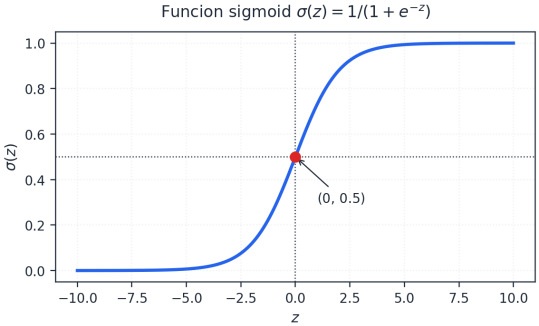

Logistic regression: definicion del modelo

Definicion

Regresion logistica binaria: modelo probabilistico que estima la **probabilidad** de que una observacion pertenezca a la clase 1, usando un score lineal pasado por sigmoid.

Modelo:

$$p(y = 1 \mid x) = \sigma(x^\top w + b), \qquad p(y = 0 \mid x) = 1 - p(y = 1 \mid x).$$

Idea central: el modelo **no** predice una clase directamente. Primero predice una probabilidad; la clase aparece despues, al aplicar una regla de decision.

Interpretacion de la salida

Definicion

Probabilidad condicional $p(y = 1 \mid x)$: probabilidad de que la clase sea 1, *dado* que observamos el vector de features x.

Ejemplo. Si para un cliente x obtenemos

$$p(y = 1 \mid x) = 0{,}82,$$

el modelo esta diciendo: *"segun lo que vi en los datos, este cliente tiene 82 % de probabilidad de estar en la clase 1"*.

Esa probabilidad no es solo un numero: contiene mas informacion que una clasificacion dura. Nos dice que tan **seguro** esta el modelo.

Threshold y regla de decision

Definicion

Threshold (umbral): valor de corte t que convierte una probabilidad en una clase.

Regla comun con $t = 0{,}5$:

$$\hat{y} = \begin{cases} 1 & \text{si } p(y = 1 \mid x) \geq 0{,}5, \\ 0 & \text{si } p(y = 1 \mid x) < 0{,}5. \end{cases}$$

Mensaje: 0,5 **no** siempre es el mejor umbral. En problemas con *costos asimetricos* (credito, fraude, salud) conviene mover el threshold.

Esto conecta con teoria de decisiones, matriz de perdidas y las curvas ROC / precision–recall de la Semana 5.

Frontera de decision

Definicion

Frontera de decision: conjunto de puntos donde el modelo es *indiferente* entre las dos clases.

Con $t = 0{,}5$, como $\sigma(0) = 0{,}5$:

$$p(y = 1 \mid x) = 0{,}5 \iff x^\top w + b = 0.$$

Mensaje clave: aunque la probabilidad se calcula con una funcion no lineal, la frontera de decision es **lineal** en el espacio de features originales.

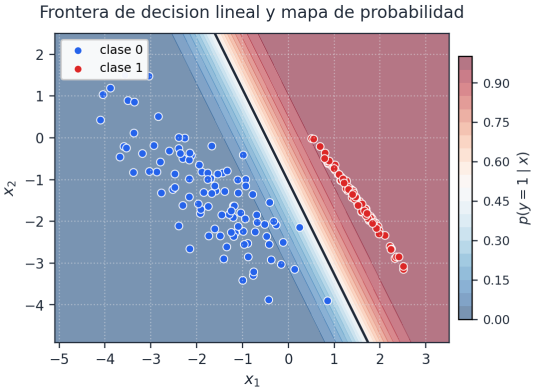

¿Que aprende el modelo?

Definicion

Parametros del modelo: valores que se ajustan durante el entrenamiento para que el modelo reproduzca bien los datos.

En logistic regression:

$$\theta = (w, b).$$

Interpretacion cualitativa:

- $w_j > 0$: subir x_j aumenta z y **tiende a aumentar** $p(y = 1 \mid x)$.
- $w_j < 0$: subir x_j disminuye z y tiende a **reducir** $p(y = 1 \mid x)$.
- b desplaza toda la frontera.

Aclaracion importante: la interpretacion *exacta* es lineal en *log-odds*, no en probabilidad. Lo formalizamos mas adelante.

Verosimilitud para clasificacion binaria

Definicion

Verosimilitud: funcion que mide que tan probables son los datos observados bajo ciertos parametros del modelo.

Para una observacion con etiqueta $y_i \in \{0, 1\}$ y probabilidad predicha $\hat{p}_i = p(y_i = 1 \mid x_i)$:

$$p(y_i \mid x_i, \theta) = \hat{p}_i^{\,y_i} \left(1 - \hat{p}_i\right)^{1-y_i}.$$

Lectura:

- Si $y_i = 1$: $p(y_i \mid x_i, \theta) = \hat{p}_i$.
- Si $y_i = 0$: $p(y_i \mid x_i, \theta) = 1 - \hat{p}_i$.

Notacion compacta porque y_i solo puede ser 0 o 1; uno de los dos exponentes "apaga" el otro factor.

Maximum Likelihood Estimation (MLE)

Definicion

MLE: elegir los parametros que hacen *maxima* la probabilidad de observar los datos de entrenamiento.

Objetivo:

$$\theta_{\mathrm{MLE}} = \arg\max_{\theta} \prod_{i=1}^{n} p(y_i \mid x_i, \theta).$$

En la practica se trabaja con el **log-likelihood**:

$$\theta_{\mathrm{MLE}} = \arg\max_{\theta} \sum_{i=1}^{n} \log p(y_i \mid x_i, \theta).$$

El logaritmo convierte productos en sumas y evita problemas numericos (desbordes/underflow).

Negative log-likelihood = binary cross-entropy

Definicion

Negative log-likelihood (NLL): $-\log$ de la verosimilitud. Minimizar NLL equivale a maximizar la verosimilitud.

Sustituyendo el modelo Bernoulli en el log-likelihood y cambiando el signo:

$$\mathcal{L}(\theta) \;=\; -\sum_{i=1}^{n} \Big[\, y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i) \,\Big].$$

Definicion

Binary cross-entropy: perdida que compara etiquetas binarias reales con probabilidades predichas; por construccion es exactamente la expresion de arriba.

Mensaje: en logistic regression, **minimizar binary cross-entropy = maximizar verosimilitud**. No son dos cosas distintas.

Interpretacion de la cross-entropy

La cross-entropy **penaliza fuerte** a predicciones que asignan baja probabilidad a la clase correcta.

Caso $y = 1$:

$$\ell = -\log(\hat{p}).$$

- $\hat{p} = 0{,}9$: perdida $\approx 0{,}11$.
- $\hat{p} = 0{,}1$: perdida $\approx 2{,}30$.
- $\hat{p} \to 0$: perdida $\to +\infty$.

Caso $y = 0$: igual pero usando $-\log(1 - \hat{p})$.

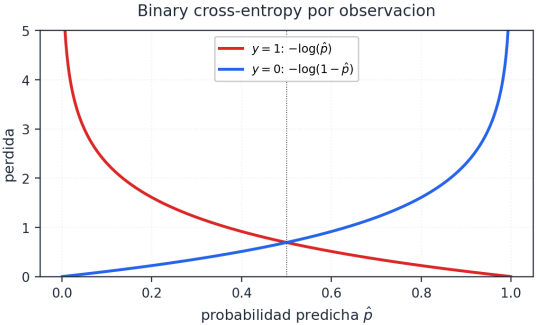

¿Por que no usamos error cuadratico aqui?

Definicion

Error cuadratico $(y - \hat{y})^2$: penaliza la diferencia al cuadrado entre etiqueta real y prediccion.

Se podria usar, pero:

- No surge del supuesto probabilistico correcto (Bernoulli).
- La superficie de perdida puede tener zonas casi planas donde el gradient descent se estanca.

Mensaje: cross-entropy no es una eleccion arbitraria. Sale **naturalmente** de la verosimilitud Bernoulli y esta alineada con el modelo.

Gradiente de logistic regression

Definicion

Gradiente: vector que indica como cambia la perdida al modificar cada parametro.

Para cada observacion: $z_i = x_i^\top w + b$, $\hat{p}_i = \sigma(z_i)$.

Resultado (perdida promedio sobre n observaciones):

$$\nabla_w \mathcal{L} = \frac{1}{n} X^\top (\hat{p} - y), \qquad \nabla_b \mathcal{L} = \frac{1}{n} \sum_{i=1}^{n} (\hat{p}_i - y_i).$$

Lectura:

- $\hat{p} - y$: vector de **errores probabilisticos**.
- $X^\top(\hat{p} - y)$: distribuye ese error entre las features.
- La forma recuerda al gradiente de regresion lineal ("prediccion menos real"), pero aqui la prediccion ya es una probabilidad.

La **derivacion paso a paso** esta en el apendice al final.

Gradient descent para logistic regression

Definicion

Gradient descent (GD): algoritmo iterativo que minimiza una funcion actualizando los parametros en direccion opuesta al gradiente.

Actualizacion:

$$w^{t+1} = w^t - \eta \nabla_w \mathcal{L}, \qquad b^{t+1} = b^t - \eta \nabla_b \mathcal{L}.$$

Definicion

Learning rate η: tamano del paso en cada actualizacion.

Efectos tipicos:

- η muy chico: convergencia **lenta**.
- η adecuado: convergencia estable.
- η muy grande: oscilaciones o **divergencia**.

Efecto de la tasa de aprendizaje

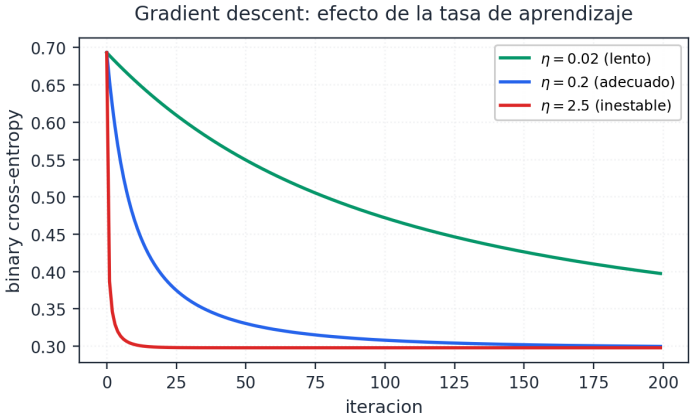

Misma logistic regression; solo cambiamos η. La curva inestable muestra el riesgo de un learning rate demasiado grande.

Stochastic Gradient Descent (SGD)

Definicion

SGD: variante de gradient descent que actualiza los parametros usando **una observacion** (o un *mini-batch*) en vez de todo el dataset.

Comparacion rapida:

- **Batch GD:** usa X completo $\Rightarrow$ curva de perdida suave, pasos costosos.
- **SGD:** usa 1 observacion $\Rightarrow$ pasos baratos, curva ruidosa.
- **Mini-batch SGD:** punto medio; es lo que se usa en la practica.

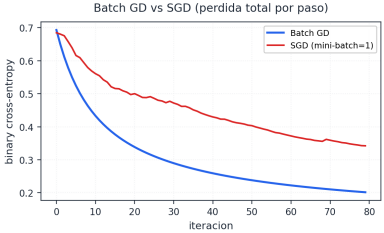

Regularizacion

Definicion

Regularizacion: agregar a la perdida una **penalizacion** sobre los parametros para controlar la complejidad del modelo.

Version con regularizacion ℓ_2:

$$\mathcal{L}_{\text{reg}}(\theta) = \mathcal{L}(\theta) + \lambda \, \|w\|_2^2.$$

Definicion

Regularizacion ℓ_2: penaliza la suma de cuadrados de los coeficientes, $\sum_j w_j^2$.

Mensaje: la regularizacion empuja al modelo a explicar los datos con coeficientes **mas pequenos y mas estables**, lo que normalmente mejora la generalizacion.

L1 vs L2

Definicion

Regularizacion ℓ_1: penaliza $\|w\|_1 = \sum_j |w_j|$. Puede producir soluciones *sparse* (coeficientes exactamente cero).

Definicion

Regularizacion ℓ_2: penaliza $\|w\|_2^2 = \sum_j w_j^2$. Encoge coeficientes, pero rara vez los vuelve cero.

Lectura rapida:

- L2 $\approx$ estabilidad.
- L1 $\approx$ seleccion automatica de variables.

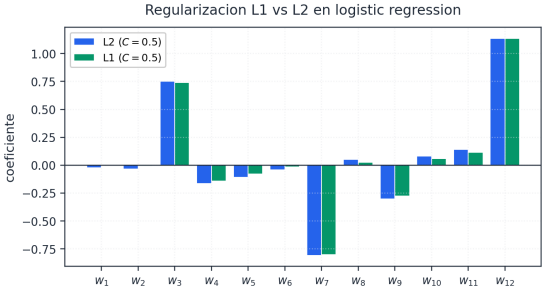

Mismo dataset, $C = 0{,}5$: L1 apaga mas coeficientes.

Estandarizacion

Definicion

Estandarizacion: transformar cada feature para que tenga media cero y desviacion estandar uno,

$$x_{ij}^{\text{std}} = \frac{x_{ij} - \mu_j}{\sigma_j}.$$

¿Por que importa con regularizacion?

- Si una feature esta en $ y otra en millones de dolares, sus coeficientes no son comparables.
- La penalizacion $\|w\|_2^2$ trata a todos los w_j por igual: penaliza mas a las features con escalas grandes solo por el **tamano numerico**, no por su importancia real.

Regla practica: con logistic regression regularizada, casi siempre **estandariza** las features numericas antes de entrenar.

Odds y log-odds

Definicion

Odds: razon entre la probabilidad de que ocurra un evento y la probabilidad de que no ocurra,

$$\text{odds} = \frac{p}{1-p}.$$

Definicion

Log-odds: $\log\left(\frac{p}{1-p}\right)$.

Para logistic regression se cumple la identidad:

$$\log\left(\frac{p(y=1 \mid x)}{1-p(y=1 \mid x)}\right) = x^\top w + b.$$

Mensaje clave: los coeficientes son **lineales en log-odds**, no directamente en probabilidad.

Ejemplo interpretativo (riesgo crediticio)

Supongamos un modelo para predecir *default*:

$$z = -2 + 0{,}8\,x_1 - 0{,}5\,x_2, \qquad p(y = 1 \mid x) = \sigma(z),$$

con:

- x_1: volatilidad de ingresos (features ya estandarizada).
- x_2: meses con ingresos estables recientes.

Lectura cualitativa:

- Subir $x_1 \Rightarrow$ suben los log-odds $\Rightarrow$ **mas riesgo** de default.
- Subir $x_2 \Rightarrow$ bajan los log-odds $\Rightarrow$ **menos riesgo**.

Siempre bajo el supuesto "manteniendo las demas variables constantes".

Clasificacion multiclase

Definicion

Clasificacion multiclase: la variable objetivo puede tomar mas de dos clases,

$$y \in \{1, 2, \ldots, K\}.$$

Ejemplos tipicos:

- Riesgo: bajo / medio / alto.
- Especie: A / B / C.
- Imagenes: perro / gato / caballo.

Idea: para dos clases usamos sigmoid; para K clases usamos **softmax**.

La funcion softmax

Definicion

Softmax: transforma un vector de scores $z = (z_1, \ldots, z_K)$ en un vector de probabilidades,

$$p(y = k \mid x) = \frac{e^{z_k}}{\sum_{j=1}^{K} e^{z_j}},$$

donde $z_k = x^\top w_k + b_k$.

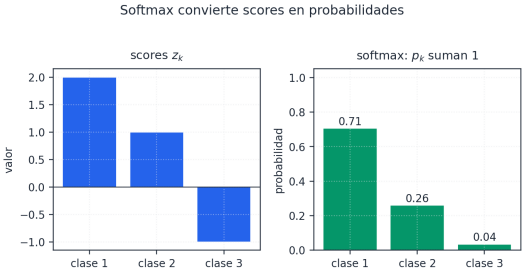

Propiedades:

- $0 < p(y = k \mid x) < 1$ para todo k.
- $\sum_{k=1}^{K} p(y = k \mid x) = 1$.
- Clase con mayor $z_k \Rightarrow$ mayor probabilidad.

Multinomial logistic regression

Definicion

Multinomial logistic regression: extension a K clases usando softmax.

Modelo:

$$p(y = k \mid x) = \mathrm{softmax}_k(W^\top x + b),$$

con una fila de pesos w_k **por cada clase**.

Mensaje: en lugar de un solo vector de pesos, aprendemos un conjunto de pesos para comparar varias clases entre si.

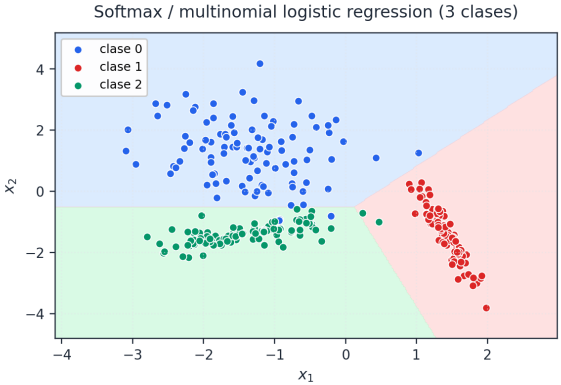

Evaluacion del modelo

Ya entrenado el modelo, medimos su desempeno con metricas de clasificacion (Semana 5).

- **Accuracy:** proporcion de predicciones correctas.
- **Precision:** de los predichos como positivos, cuantos *realmente* lo son.
- **Recall:** de los positivos reales, cuantos *encontro* el modelo.
- **F1:** media armonica entre precision y recall.

Mensaje: un buen modelo no solo acierta mucho. Tambien importa **que tipo** de errores comete, sobre todo en datasets desbalanceados.

Threshold tuning

Definicion

Threshold tuning: elegir un umbral t distinto de 0,5 para optimizar una metrica o minimizar un costo concreto.

Ejemplo en credito:

- Falso positivo: rechazar a un buen cliente.
- Falso negativo: aprobar a un mal cliente.

El mejor t depende del **costo del error**, no solo del valor de la probabilidad.

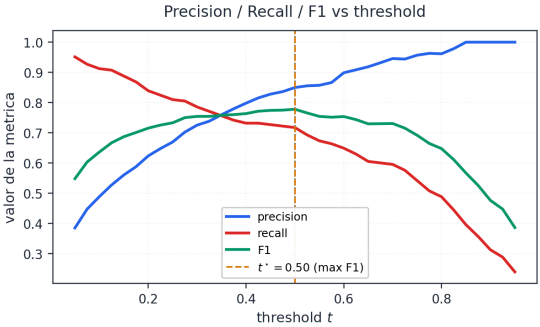

Errores conceptuales comunes

- **Error 1:** pensar que logistic regression predice una clase directamente.
  Correccion: predice una *probabilidad*; la clase aparece al aplicar una regla de decision.
- **Error 2:** interpretar w_j como cambio directo en probabilidad.
  Correccion: los coeficientes son lineales en *log-odds*.
- **Error 3:** confiar en accuracy con clases desbalanceadas.
  Correccion: revisar precision, recall, F1 y matriz de confusion.
- **Error 4:** regularizar sin estandarizar.
  Correccion: la penalizacion depende de la escala de las features.

Cierre conceptual

Logistic regression combina tres ideas:

1. Un **score lineal**: $z = x^\top w + b$.
2. Una **transformacion probabilistica**: $p(y = 1 \mid x) = \sigma(z)$.
3. Una **perdida basada en verosimilitud**:

$$\mathcal{L} = -\sum_i \left[y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i) \right].$$

Mensaje final

Es un modelo **simple, interpretable y muy competitivo como baseline** para problemas de clasificacion. Muchos modelos complejos (incluidas redes neuronales) terminan usando esta misma logica en su ultima capa.

Semana 11 — mapa del temario (progreso)

- **Teoria**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**
- **Apendice**

Lab NumPy — Objetivos

Meta: implementar logistic regression binaria **desde cero**, sin sklearn (salvo para generar datos o hacer split).

- Ver que las ecuaciones de teoria realmente funcionan al programarlas.
- Conectar el gradiente con la actualizacion.
- Visualizar la curva de perdida y la frontera de decision aprendida.

Pseudocodigo — Logistic regression desde cero

Pseudocodigo (guia conceptual)

1. Fijar semilla (`rng = np.random.default_rng(42)`).
2. Generar dataset sintetico 2D (`make_classification` o muestreo manual).
3. Construir $\tilde{X} = [\mathbf{1}_n \mid X]$.
4. Implementar `sigmoid(z) = 1 / (1 + np.exp(-z))`.
5. Implementar `bce(y, p_hat)` con `np.clip` para evitar log(0).
6. Implementar el gradiente: $\nabla = \frac{1}{n}\tilde{X}^\top(\hat{p} - y)$.
7. **Para** $t = 1, \ldots, T$:
   1. $z \leftarrow \tilde{X}\theta$, $\hat{p} \leftarrow \sigma(z)$.
   2. Guardar $\mathcal{L}^{(t)} \leftarrow \mathrm{bce}(y, \hat{p})$.
   3. $\theta \leftarrow \theta - \eta\, \frac{1}{n}\tilde{X}^\top(\hat{p} - y)$.
8. Graficar $\mathcal{L}^{(t)}$ vs. t.
9. Graficar puntos + frontera $\tilde{x}^\top\theta = 0$.

Lab NumPy — Que deben observar

- La perdida **decrece** al ajustar η correctamente.
- La frontera aprendida es lineal en (x_1, x_2).
- Con η muy grande la perdida oscila o explota; con η muy chico converge muy lento.
- Si se cambian los datos, los coeficientes cambian pero el **patron general** (forma del gradiente, forma de la frontera) se mantiene.

Esta es la misma logica que luego usan librerias y frameworks modernos; solo cambian los detalles numericos.

Semana 11 — mapa del temario (progreso)

- **Teoria**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**
- **Apendice**

Lab sklearn — Objetivos

Meta: llevar las ideas teoricas a la herramienta estandar y comparar con la implementacion NumPy.

Modelo principal: `LogisticRegression` de `sklearn.linear_model`.

Flujo recomendado:

1. `train_test_split` para separar entrenamiento y prueba.
2. `StandardScaler` dentro de un `Pipeline` (solo se ajusta con train).
3. Entrenar `LogisticRegression` con distintos valores de `C`.
4. Evaluar con `classification_report` y `confusion_matrix`.
5. Explorar thresholds distintos a 0,5.

Parametro `C` en sklearn

En `LogisticRegression`, el argumento `C` es el **inverso** de la fuerza de regularizacion:

$$C \approx \frac{1}{\lambda}.$$

Lectura practica:

- `C` grande (ej. 100) $\Rightarrow$ **poca** regularizacion, coeficientes parecidos a OLS.
- `C` pequeno (ej. 0,01) $\Rightarrow$ **mucha** regularizacion, coeficientes pequenos.

Detalle importante para no confundirse: cuando Murphy habla de λ y sklearn habla de `C`, van en **direcciones opuestas**.

Pseudocodigo — Pipeline + evaluacion

Pseudocodigo (guia conceptual)

1. Cargar o generar dataset binario (`make_classification`).
2. `X_tr, X_te, y_tr, y_te = train_test_split(...)`.
3. Definir un `Pipeline`:
   1. `StandardScaler()`.
   2. `LogisticRegression(C=...)`.
4. Entrenar con `pipe.fit(X_tr, y_tr)`.
5. Obtener probabilidades: `probs = pipe.predict_proba(X_te)[:, 1]`.
6. Calcular metricas con distintos thresholds: `precision`, `recall`, `f1`, `confusion_matrix`.
7. Repetir para varios `C` (ej. $0{,}01, 0{,}1, 1, 10, 100$) y comparar coeficientes.
8. (Opcional) Ajustar `LogisticRegression(multi_class='multinomial')` en un dataset con 3 clases.

Lab sklearn — Que deben observar

- Los coeficientes de sklearn (con `C` grande) se parecen a los de su implementacion NumPy.
- Al bajar `C`, los $|w_j|$ se **reducen** de forma sistematica.
- La matriz de confusion cambia visiblemente al mover el threshold.
- El threshold "optimo" por F1 casi nunca es exactamente 0,5.

La meta no es buscar el mejor numero, sino entender **por que** cambia y en que direccion.

Semana 11 — mapa del temario (progreso)

- **Teoria**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**
- **Apendice**

Entregable — que debe incluirse

Notebook `week11_logistic_regression.ipynb` con:

1. **Implementacion NumPy** de logistic regression binaria + entrenamiento con gradient descent.
2. **Grafica de la perdida** por iteracion.
3. **Visualizacion de la frontera de decision**.
4. **Comparacion con sklearn**: coeficientes y metricas.
5. **Experimento de regularizacion**: al menos 3 valores de `C`, con features estandarizadas.
6. **Evaluacion**: matriz de confusion, precision, recall, F1 y analisis de threshold.
7. **Reflexion breve** (5–8 oraciones) respondiendo las preguntas guia.

Entregable — preguntas guia

En la reflexion, responder con claridad:

- ¿Que cambia cuando movemos el threshold?
- ¿Que cambia cuando agregamos regularizacion?
- ¿Que variables parecen mas importantes segun los coeficientes?
- ¿En que situaciones accuracy puede ser **enganosa**?

La reflexion se evalua por claridad de la idea, no por longitud del texto.

Cierre de la semana

Logistic regression conecta varias piezas del curso:

- **Modelos lineales** (Semanas 7 y 9).
- **Probabilidad condicional** (Semanas 2 y 3).
- **Maximum likelihood estimation** (Semana 4).
- **Cross-entropy** e informacion (Semana 6).
- **Gradient descent** (Semana 9).
- **Evaluacion de clasificadores** (Semana 5).

El mismo score lineal $x^\top w + b$ que usabamos para predecir un numero ahora, pasado por sigmoid y una regla de decision, sirve para ***separar clases con probabilidades interpretables****.*

Secciones recomendadas (PML = Murphy)

- **Cap. 10 — Logistic Regression**
  - **10.1** Introduction.
  - **10.2** Binary logistic regression.
  - **10.2.3** Maximum likelihood estimation.
  - **10.2.4** Stochastic gradient descent.
  - **10.2.8** Standardization.
  - **10.3** Multinomial logistic regression.
- **Cap. 2: 2.4.2** Sigmoid function; **2.5.2** Softmax function.
- **Cap. 4: 4.2** Maximum likelihood estimation.
- **Cap. 5: 5.1.3–5.1.4** ROC y precision–recall.

Lectura opcional: **10.2.7** MAP estimation (no se cubre en estas slides).

Semana 11 — mapa del temario (progreso)

- **Teoria**
- **Lab NumPy**
- **Lab sklearn**
- **Entregable**
- **Apendice**

Apendice — Objetivo de la derivacion

Queremos deducir el gradiente de la perdida de logistic regression **paso a paso**.

Para una observacion i:

$$z_i = x_i^\top w + b, \qquad \hat{p}_i = \sigma(z_i) = \frac{1}{1 + e^{-z_i}}.$$

Perdida binary cross-entropy por observacion:

$$\ell_i = -\big[\, y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i) \,\big].$$

Meta: obtener $\dfrac{\partial \ell_i}{\partial w}$ y $\dfrac{\partial \ell_i}{\partial b}$.

Apendice — Derivada respecto a $\hat{p}_i$

Partimos de

$$\ell_i = -\big[\, y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i) \,\big].$$

Derivamos respecto a $\hat{p}_i$:

$$\frac{\partial \ell_i}{\partial \hat{p}_i} = -\frac{y_i}{\hat{p}_i} + \frac{1 - y_i}{1 - \hat{p}_i}.$$

Origen termino a termino:

- $\frac{\mathrm{d}}{\mathrm{d}\hat{p}_i}\big[- y_i \log \hat{p}_i \big] = -\frac{y_i}{\hat{p}_i}$.
- $\frac{\mathrm{d}}{\mathrm{d}\hat{p}_i}\big[- (1 - y_i) \log(1 - \hat{p}_i) \big] = +\frac{1-y_i}{1-\hat{p}_i}$.

Apendice — Derivada de sigmoid

Para $\hat{p}_i = \sigma(z_i) = \dfrac{1}{1+e^{-z_i}}$:

$$\frac{\partial \hat{p}_i}{\partial z_i} = \hat{p}_i\,(1-\hat{p}_i).$$

Idea rapida: derivando directamente,

$$\sigma'(z) = \frac{e^{-z}}{(1+e^{-z})^2} = \frac{1}{1+e^{-z}} \cdot \frac{e^{-z}}{1+e^{-z}} = \sigma(z)\,(1-\sigma(z)).$$

Importancia: esta identidad es la que va a hacer que el gradiente final tenga una forma **muy simple**.

Apendice — Regla de la cadena sobre z_i

Por regla de la cadena:

$$\frac{\partial \ell_i}{\partial z_i} = \frac{\partial \ell_i}{\partial \hat{p}_i} \cdot \frac{\partial \hat{p}_i}{\partial z_i}.$$

Sustituyendo:

$$\frac{\partial \ell_i}{\partial z_i} = \left(-\frac{y_i}{\hat{p}_i} + \frac{1 - y_i}{1 - \hat{p}_i} \right) \hat{p}_i \, (1 - \hat{p}_i).$$

Distribuyendo $\hat{p}_i(1 - \hat{p}_i)$:

$$\frac{\partial \ell_i}{\partial z_i} = -y_i(1 - \hat{p}_i) + (1 - y_i)\hat{p}_i.$$

Expandiendo:

$$= -y_i + y_i\hat{p}_i + \hat{p}_i - y_i\hat{p}_i = \hat{p}_i - y_i.$$

Resultado clave

$$\frac{\partial \ell_i}{\partial z_i} = \hat{p}_i - y_i.$$

Apendice — Gradiente respecto a w y b

Como $z_i = x_i^\top w + b$:

$$\frac{\partial z_i}{\partial w} = x_i, \qquad \frac{\partial z_i}{\partial b} = 1.$$

Por regla de la cadena:

$$\frac{\partial \ell_i}{\partial w} = (\hat{p}_i - y_i)\, x_i, \qquad \frac{\partial \ell_i}{\partial b} = \hat{p}_i - y_i.$$

Usando la perdida **promedio** sobre n observaciones $\mathcal{L} = \frac{1}{n}\sum_i \ell_i$:

$$\nabla_w \mathcal{L} = \frac{1}{n}\sum_{i=1}^{n}(\hat{p}_i - y_i)\, x_i = \frac{1}{n} X^\top(\hat{p} - y),$$

$$\nabla_b \mathcal{L} = \frac{1}{n}\sum_{i=1}^{n}(\hat{p}_i - y_i).$$

Mensaje final: el gradiente tiene la forma **"error probabilistico"** $(\hat{p} - y)$ **multiplicado por las features**.